

DNA, 计算, 生物数学

分离, 抽取, 切割

学科与专题介绍

③

DNA 计算：生物数学的来临

202-209

LiLa Kari

Kari, LL

Q-332

Q523

“走进世间万物，让大自然教会你一切。”

(Wordsworth[53])

数学生物学是数学和生物学的一个交叉学科。这方面的典型例子有，利用随机过程和统计方法来解决遗传和流行病学上的问题。正如其名字揭示的那样，“生物学”是主体，而“数学”是修饰词，这两个学科间的联系历来都是单向的，即数学为生物学服务。（可参看 [24] 中的综述）。

与此相反，Leonard Adleman [1] 通过操纵 DNA 串成功的解决了一个有向哈密尔顿路径 (Directed Hamilton Path) 问题。这是这两个学科间联系首次反向的标志：数学问题成了目标，而生物学成了工具。为保证语义上正确，我们不应把 DNA 计算再归类于数学生物学，而应当使用这个词的反像，生物数学，来表示这一诞生于 1994 年 11 月的新学科。

尽管生物数学中的技术非常复杂，但其思想却是基于一个简单的发现，即生物和数学的相似性：

(1) 生物体异常复杂的结构是对由 DNA 序列表示的初始信息执行简单操作 (复制, 剪接) 的结果；

(2) 可计算函数 $f(w)$ 的结果可以通过在 w 上执行一系列基本的简单函数而获得。

如果仅了解到这种相似性就可以进行 DNA 计算的话，那我们早就可以在 DNA 便携机上玩电脑游戏了。事实上，要把这两个表面上无关的过程结合在一起，需要多种因素的成熟和一种如 Adleman 那样创新性的思维。Adleman 是一个精通生物学的数学家，他意识到这两个过程不仅相似，而且由于分子生物学技术的发展，人们还可以利用生物过程来模拟数学过程。更精确的说，DNA 串可用于表示信息，酶可用于模拟简单的计算。其方式如下所述 (对分子生物学术语更详细的解释见于 [29])

DNA (脱氧核糖核酸) 见于所有细胞组织中，是遗传信息的存贮介质。DNA 由称

原题：DNA Computing: Arrival of Biological Mathematics. 译自：The Mathematical Intelligencer 19(1997), No. 2, 9-22.

作核苷酸的一些单元组成。这些核苷酸随附着在其上的化学组或基的不同而不同。共有四种基：腺嘌呤、鸟嘌呤、胞嘧啶和胸腺嘧啶，分别简称为 *A*、*G*、*C* 和 *T*，而且这些名字也常用于表示相应的核苷酸。一些单个的核苷酸顺序连在一起形成 DNA 链。一个短的单链核苷酸串，常常小于 30 个核苷酸那么长，称作一个寡核苷酸。DNA 序列有极性：一个 DNA 序列与其逆向是不同的。DNA 序列两个不同的端分别称作 3' 端和 5' 端。核苷酸 *A* 和 *T*、*C* 和 *G* 可以配成对，因而称之为互补的。两个互补而极性相反的单链 DNA 可以在基配对或退火过程中结合在一起而形成双螺旋结构。其逆过程，即双螺旋分解成两个连续的单链，称作溶解（图 1）。




图 (1) DNA 溶解和退火

单链 DNA 可以看作是由四个符号 *A*、*G*、*C*、*T* 组成的字符串。从数学上讲，这意味着我们可以用一个含有四个字符的字符集 $\Sigma = \{A, G, C, T\}$ 来为信息编码。这实际上有些奢侈，因为为了同样的目的，电子计算机仅使用 0 和 1 两个数字。

DNA 序列上的一些简单操作需要酶的协助。这些酶各自完成一些基本的任务，而且可以方便的得到。有一种酶，称为限制性内切酶，它可以识别一种特定的 DNA 短序列，该短序列称为限制性位点。任何包含这个限制性位点的双链 DNA 都可以被限制性内切酶在该位置上切开。（图 2）另一种酶叫 DNA 连接酶，它可以将一个 DNA 链的端点同另一个链捆绑或连接在一起。DNA 聚合酶具有好几个功能，其中包括 DNA 的复制。复制反应需一个称为模板的向导 DNA 单链和一个称为引物的更短的寡核苷酸。在这些条件下，DNA 聚合酶将促进 DNA 的合成，其方法是往引物的一端依次追加核苷酸。这样引物将沿着一个方向一直扩展下去，直到与模板互补为止（图 3）。我们最后要介绍的酶是外切酶。利用外切酶，可以有选择地破坏双

链或单链 DNA 分子. 它们可以从内端对 DNA 分子进行扭曲, 有些针对单链, 有些则针对双链. 除上述四种之外, 还有许多其它种类的酶, 但对于我们的计算模型而言, 这已经足够了.





图 2: DNA 切割

图 3: DNA 复制

[1] 中利用了 DNA 序列中对信息编码和执行简单生物操作的实际可能性解决了一个七结点的有向哈密尔顿路径问题. 称标有顶点 v_{in} 和 v_{out} 的有向图 G 中存在一条哈密尔顿路径, 当且仅当存在一个互连的单向边的序列 $e_1, e_2, \dots, e_n$ (即一条路径) 使得其始于 v_{in} 而终于 v_{out} , 而且恰经历其余顶点各一次.

下述 (非确定) 算法解决了这个问题:

- 步骤 1. 生成图中的随机路径.
- 步骤 2. 仅保留那些从 v_{in} 开始, 到 v_{out} 结束的路径.
- 步骤 3. 如果图中有几个顶点, 仅保留那些恰经过几个顶点的路径.
- 步骤 4. 仅保留那些经过图中所有顶点至少一次的路径.
- 步骤 5. 如果还有路径留下, 回答“是”; 否则回答“否”.

为实现步骤 1, 将图中每个顶点用一个长为 20 的随机核苷酸链 (20 个字符长的序列) 表示. 对图中每一条 (有向) 边, 用如下的 DNA 序列表示: 源点 DNA 序列的后半部分和目标点 DNA 序列的前半部分. 然后在反应条件下, 将边的 DNA 序列和顶点补 DNA 序列混合. 后者的作用就象夹板, 将各边的 DNA 序列以头尾相接的方式连接起来. 这样, 经过连接反应, 就会生成表示随机路径的 DNA 分子.

为实现步骤 2, 要将步骤 1 中的结果通过聚合酶链式反应来放大 (参见下节及图 3). 在这个过程中, 只有那些从 v_{in} 开始, 到 v_{out} 结束的路径的 DNA 分子被放大.

为实现步骤 3, 需要使用一种称为凝胶电泳的技术, 它可以按长度分离 DNA 链 (图 4). 首先将 DNA 分子置于凝胶的顶部, 然后对之施加电场, 这样就可以将这些分子施至凝胶底部. 分子越大, 其移动速度越慢, 经过一段时间以后, 这些分子就会按大小分布在凝胶的不同区段里.

步骤 4 要通过多次利用“亲和纯化”过程来完成. 这个过程可以使含有给定序列 v (表示图中一个顶点) 的单链从含有其它链的异构池中过滤出来 (图 5). 经与 v 的互补链合成并将之附于珠上之后, 将这个含有不同溶质的溶液滤过珠. 这样包含 v 的链与其互补序列结合在一起而被留下来, 其他的链则被滤掉了.

为实现步骤 5, 需要检查是否存在一个哈密尔顿回路的 DNA 分子. 为此可以利用聚合酶链式反应将步骤 4 的结果放大, 然后再判定放大过的 DNA 分子的序列.




图 4 凝胶电泳法




图 5 亲和纯化法

Adleman 结果中引人注目的一点是, 它不仅解决了一个数学问题, 而且该问题在以下所述的意义上讲还是一个难解问题 (参见 [17] 和 [19]).

我们可以按照难度对问题分类, 这里难度由该问题的最佳算法在单个计算机上的运行时间而定. 如果算法的运行时间是输入的多项式 (指数) 级函数, 该算法就属于“多项式时间”类 P (指数时间”类 EXP). 如果一个问题不存在多项式时间的算法, 该问题就称为难解的.

有一类看来是难解的问题, 它包含 P 但包含于 EXP , 称为非确定性多项式时间类 (NP). 各类间的包含关系是:

$$P \subseteq NP \subseteq EXP \subseteq \text{所有}$$

NP 中的问题, 还没有发现其多项式时间算法, 但利用非确定性计算机可在多项式时间内解决 (非确定性计算机是指可并行完成无限个搜索的计算机). 有向哈密尔顿路径问题属于 NP 类中的一种, 称为 NP 完全问题. NP 类中的任何问题都可在多项式时间内归约为一个 NP 完全问题, 因此在某种意义上讲, NP 完全问题是 NP 类中最难的问题.

有一个问题是, NP 完全问题是否是难解的? 数学上可以表示为 “ $P = NP?$ ” 它被认为是当代数学和计算机科学中最吸引人的问题之一. 由于有向哈密尔顿问题已知是 NP 完全问题, 看起来利用电子计算机还没有有效的 (即多项式时间的) 算法来解决它.

在 [1] 之后, [32] 中描述了解决另一个 NP 完全问题——可满足性问题的 DNA 实验. 可满足性问题是指给定一个布尔表达式, 是否存在对其中变量的一种赋值, 使得表达式的值为真. 迄今为止, DNA 算法已经用于许多问题, 如符号决定性 [31], 道路染色问题 [25], 矩阵乘法 [36], 加法 [20] 以及超标量计算机代数问题 [50] 等等.

[10] 中给出了一个 “分子程序”, 它可以破解美国政府的数据加密标准 (DES). DES 使用 56 位的密码对 64 位的信息进行加密. 破解 DES 意味着, 给定一个 (明文, 密文) 对, 我们要找到将明文变换为密文的密码. 常规攻击方法是穷尽搜索 2^{56} 个密码. 这样, 如果每秒执行十万次操作, 就需要一万年. 但是据估计, 如果使用分子计算机来破解 DES 的话, 仅需要四个月的时间.

上述问题表明, 分子计算机具备起过现有计算机的潜力. 其原因之一是 DNA 计算在速度, 能源利用率以及经济信息存贮方面具有极大的优势. 例如, 在 Aldeman 模型 [2] 中, 每秒可执行 1.2×10^{18} 次操作, 比当前最快的超级计算机要高出一百二十万倍. 现有的超级计算机利用每焦耳的能量可执行 10^9 次操作, 而 DNA 计算机可执行 2×10^{19} 次, 即 DNA 计算机的能源效率要高出 10^{10} 倍. 最后, 根据文献 [1], 在 DNA 分子中信息的存贮密度可达 $1\text{bit}/\text{立方纳米}$, 而现有的存贮介质存贮一个 bit 需要 10^{12} 立方纳米. [6] 中估计, 单个 DNA 存贮器的容量要超过迄今所生产出的所有存贮器的总和.

DNA 什么都可以计算么?

在有向哈密尔顿路径问题, 可满足性问题, 破解 DES 等例子中, DNA 计算与电子计算相比, 其优势是很明显的. 但它们仅仅是利用分子技术解决的特定问题, 是为解决特定问题而进行的一次性实验. 这立即会引出两个根本性的问题, 它们已在 [1] 和 [19] 中提出:

(1) DNA 计算可解决哪些种类的问题？

(2) 是否有可能设计出可编程的 DNA 计算机，哪怕仅仅在原理上？

更精确地说：

(1) DNA 计算模型是完备的么？即通过操纵 DNA 能完成所有的可计算函数（或任意图灵机的计算功能）么？

(2) 是否存在通用 DNA 系统？通用 DNA 系统是指能够接受可计算函数的编码，并对该函数的任何参数均可模拟该函数动作的系统。这里函数与程序的意义是一致的，即参数 w 是程序的输入，而 $f(w)$ 是程序的输出。存在通用 DNA 系统就等于是存在可以运行程序的 DNA 计算机。

至于这两个问题的答案是否相关，人们有不同的看法。[11] 中认为，从实践角度看用 DNA 计算装置来模拟图灵机并不是那么重要。确实，人们不应该企图将 DNA 模型置于传统计算模型的框架中，而应当另辟蹊径，重新考虑计算的意义。但是，DNA 模型的计算完备性与设计算法的实际努力是相关的。无论何时，总会又有一个 Godel 宣称，通过操纵 DNA 来解决某个问题在原理上就是行不通的，或者你一直在构造的 DNA 计算机在理论上就是不可能的。存在性的理论证明至少会驱散象这样的埋伏在暗处的威胁。

现有的大多数 DNA 计算模型都考察了 DNA 计算设备的计算完备性和通用性问题。它们都建立在下述几个基本的生物操作之上：




图 6 DNA 合成

- 合成一个预期的，长度为多项式级的链，该操作用于所有模型中（图 6）。一个 DNA 分子是在支撑粒子上依次对核苷酸配对而成的。例如，将一个核苷酸（单体）。

不失一般性, 设它为 A , 置于杯中. 往杯中注入含有 C 的溶液, A 和 C 反应生成两个核苷酸的链 AC (二聚物). 冲洗去多余的 C 溶液之后, 可使 AC 中的 C 和 T 再结合生成三聚物的链, 等等.

- **混合:** 将两个试管的内容注入到第三个试管中将其合并. 如果试管内容不处于溶液状态, 可先将其水合 (图 2).

- **退火:** 如图 1 所示, 通过冷却溶液, 将两个互补的单链 DNA 序列结合在一起 (参见 [11,15]). 体外的退火亦称为杂交.

- **溶解:** 如图 1 所示, 通过加热溶液, 将一个双链 DNA 分解为两个互补的单链 (参见 [11,51]). 体外的溶解亦称为变性 (denaturation).

- **放大 (复制):** 如图 3 所示, 通过聚合酶链式反应 (PCR) 制作 DNA 链的复制品 (参见 [2,5,31]). PCR 是一种体外方法, 它靠 DNA 聚合酶快速放大溶液中特定的 DNA 序列. PCR 包括多个温度周期, 每个周期由三个阶段组成: 分解向导模板 DNA 的链, 而后将其冷却以使之与引物寡核苷酸模板结合, 这些引物寡核苷酸是特别安排在需要放大的 DNA 周围的. 最后一个阶段是利用 DNA 聚合酶来扩展引物. 每个反应周期中目标 DNA 分子的数目却会翻番, 这样, 放大反应使得 DNA 分子的数目以指数级增长.

- **分离:** 如 Aldeman 实验的第三步以及图 4 所示, 可以利用凝胶电泳法按长度分离 DNA 分子.

- **抽取:** 如 Aldeman 实验中第四步以及图 5 所示, 利用亲和净化法将含有作为子串的特定模式的链提取出来.

- **切割:** 如图 2 所示, 利用限制性酶在特定位置上切割双链 DNA.

- **连接:** 利用 DNA 连接酶将 DNA 链与相容的粘性末端粘在一起 (参见 [22,15]).

- **替换:** 如图 7 所示, 利用 PCR 特定位点上的寡核苷酸诱变方法来替换、插入或删除 DNA 序列. 该过程是 PCR 的一个变种, 在其中可以通过修改引物来诱导模板的改变, 即我们可以利用仅与模板片段部分互补的引物. (修改后的引物应当包含足够多的与模板互补的基, 以便可以融合). 引物被聚合酶扩展后, 新得出的链由模板的补构成, 但其中有少数寡核苷酸象是被别的给替换掉了.

- **通过杂交 标记 单链:** 将互补的序列附贴在链上, 使之成为双链结构. 其逆操作你为双链的去标, 方式是通过变性或移去互补链. 被标记的序列是双链的, 而去标的序列是单链的.

- **破坏 被标记的链:** 方式有两种, 其一是使用外切酶, 其二是利用限制性酶来切割所有被标记的链, 然后采用凝胶电泳法来移去那些完整的链.

- **检测和阅读:** 给定一个试管的内容, 如果其中至少有一个 DNA 链, 回答 “是”, 否则回答 “否” [1],[2]. 可以利用 PCR 将结果放大, 然后利用一个称为序列化的过程来实际读取该溶液. 最长用序列化方法的基本思想是采用 PCR 和凝胶电泳法. 假设我们有一种同质的溶液, 即这种溶液包含的主要是我们要序列化的链, 而只有很少的杂质 (其它链). 为检测 A 在目标链中的位置, 可以使用封闭剂防止在 PCR 中模

板在 A 上扩展. 经过这种修改过的 PCR, 可以得到一批子序列, 每个子序列对应 A 在原链中在不同位置. 通过凝胶电泳法将它们按长度分离, 就可以得出 A 在原链中的位置. 对 C, G, T 重复上述过程, 就可以产生链的序列. 最近有种方法是使用四种荧光染色剂, 每种染色剂对应一种基, 这样就可以并行地处理四种基. 当加上荧光的分子通过贴在凝胶底部的检测器时, 数据就可直接输出到电子计算机中.

上述生物操作, 可能还需要另外的一些, 被用来编写程序. 这些程序把含有 DNA 链的试管作为输入, 而输出 “是”, “否” 或另一些含有 DNA 链的试管. 计算过程由包含 DNA 链的试管序列组成.

操作组合模型各有千秋. 使用类似于 Aldeman 操作的模型有一种明显的优势, 即它们已经可以在实验室中成功地实现. 将这种过程进行大规模自动化的障碍是多数生物操作都易于出错, 而且主要依赖于对试管的手工处理. 与此相反, Head 提出了一种模型 [22], 其目的提构造一个 “单管” 计算机, 该模型中所有操作在原理上都是由酶执行的, 而且它还具有作为数学模型的理论优势: 其中所有断言都有数学证明支持. 其缺点是仅靠目前的生物技术, 还不能将其付诸实施. 在建造基于 DNA 的实际计算机之前, 我们的思维应当跨越多种模型, 吸取各自的长处: 在这个初级阶段, 每出现一个模型都是一种鼓励, 而不应当看作是浪费.

在本文的后半部分, 我们将把注意力放在重组 DNA 的剪接模型上, 该模型出现在 1987 年 Head 的讨论班文章中 [22]. 剪接操作 (切割和粘贴的组合) 的形式化定义可用作实施计算的主要原语, 对此我们将在下节介绍. 其后将讨论基于剪接的 DNA 模型的证明, 以对在本节开始时提出的两个问题给出肯定的回答.

(待续)