

信息检索系统, 算法, 软件

SIAM 潜在语义检索系统

学科与专题介绍

② SIAM 99' 年会组织者运用数学 24-30 为数学界服务 9354.4

原文提要：在亚特兰大召开的 SIAM 99' 年会的组织者要求研制者运用他们在开发名为 LSI (Latent Semantic Indexing, 潜在语义检索系统) 的自动检索系统模型的算法和软件中的经验, 使可能是令人沮丧又费时的工作—将会议论文进行分组—得到了迅速解决。

如果你曾在大型会议的组委会中工作过, 你一定知道组织者在会前、会议中以及会议后感受到的欣慰和沮丧。这里要讲的与之有关的就是 5 月分在亚特兰大举行的 SIAM 99' 年会会前的一个了不起的经验, 它可能成为今后组织会议的一种标准的程序。

组委会的会前例行工作之一为向会议投稿的论文组织分组会。这项工作包括阅读摘要并试图把相关的论文分成一组。我们已经花了几年的时间来研制名为 LSI 的自动检索系统的算法和软件, 我们决定要把论文报告分组的工作自动化, 特别是因为已经接近日程规定的截止日期了。

信息检索的研究遵循着若干种并行但类似的开发路子。潜在语义检索系统 (LSI) —由于它在检索词 - 文件空间中表示检索词和文件的方式—被认为是一种向量信息检索模型。LSI 是可以用来对以语义为基础的检索中的术语 (关键词) 和文件进行编码的许多候选方法之一, 所谓以语义为基础的检索, 是指被检索到的有关信息与信息需求 (查询) 不一定具有共同使用的术语。

潜在语义检索系统 (LSI)

潜在语义检索系统 (LSI) 这个信息检索模型依靠的是信息检索的较早的研究工作和矩阵分解, 诸如利用奇异值分解来降低检索词 - 文件空间的维数。高维子空间 (例如, 在一种收录中所有建立了索引的检索词的顺序) 有助于对使用共同检索词的文件进行编码或聚类, 而不管这些文件相关与否。降低维数 (或降秩) 是一种试图解决困扰着自动信息检索系统中的同义词辩异和一词多义现象的方法 (见 [2])。这些问题包括检索词的含义可能会随着文件的不同而改变—例如, bank 这个字有时指一个金融单位 (银行), 而在另一些地方是指计算机存储的分区 (存储体)。对于以词汇匹配为基础的系统同义词辩异也会出现问题—sprout (〈美口〉小伙子, 小孩), toddlers (学步小儿童), rugrats

原题: Atlanta Organizers Put Mathematics to Work for the Math Sciences Community,
译自: SIAM NEWS, v. 32(1999), no. 6, pp. 1, 10 - 11.

(〈美哩〉小孩)和 kids (〈口〉小孩, 〈美口〉年青人)都是在不同的情景下用来表示儿童的检索词。LSI 以更为适中的维数显式地表示检索词和文件致使检索词和文件的(或二者潜在的)语义关系可能既确切又有效地为查询匹配所利用。

LSI 依赖于构成一个文件的能使人联想到文件内容的检索词。但是, LSI 模型把文件中的检索词看成是包含在文件中的概念的多少有点不可靠的指示器。该模型假定用词选择的可变性部分地模糊了文件的语义结构。通过降低检索词 - 文件空间的维数, LSI 揭示了文件之间的基本的语义关系, 并消除了许多噪声(词的用法上的差别, 无助于区分文件的检索词等等)。LSI 统计地分析了贯穿整个文件集中词的用法模式, 把具有相似的词的用法模式的文件置于检索词 - 文件空间中互相靠近的位置, 并允许语义相关的文件互相靠近, 即使它们可能没有共享的检索词。

LSI 与利用信息检索中约化空间模型的先前的做法有如下几个方面的不同。最值得注意的是, LSI 可以在由用户指定的顺序的高维空间中表示文件。其次, 检索词和文件都可以在同一个空间中表示出来。第三, 并不试图去解释维数的含义。只假定每个维数代表了检索词 - 文件空间中的一个或多个语义关系。最后, (主要是)由于信息检索的向量 - 空间方法在计算要求上所叠加的限制, 先前的做法只能考虑相对小的文件集。LSI 则能表示和巧妙地处理大的数据集, 并使之对实际应用切实可行。

与其他的信息检索方法相比较, LSI 完成得出人意外地好。在一个测试 ([5]) 中, 在对标准的信息录入装置 (Message Entry Device 缩写为 MED) 的文件集进行搜索时, LSI 给出了比标准的以词为基础的检索方法更多的相关文件。在对五个标准文件集的测试中, 同样的研究指出, 平均说来 LSI 比词汇信息检索要完成得好。此外, LSI 完全是自动的而且易于使用, 为表示查询要求, 它不需要复杂的表示式或语法。因为检索词和文件在该空间中是显式地表示出来的, 关联性反馈可以天衣无缝地集成到 LSI 模型中去, 甚至能提供更好的总体检索性能。

在 LSI 模型中检索词和文件是由一个关联矩阵(或检索词 - 文件矩阵) A 来表示, 其中 $A = (a_{ij})$ 。对文件集中 m 个彼此不同的检索词指定了矩阵的一行与之对应, 而文件集中每个文件对应矩阵的一列。非零元素 a_{ij} 不仅指出了检索词 i 在文件 j 中出现, 还给出了检索词 i 在文件 j 中出现的次数。因为在一给定文件中检索词的数目远比整个文件集中的检索词要少, 因而 A 通常是非常稀疏的。

一旦建立了 $m \times n$ 矩阵 A 并且适当加了权, 那么一种名为奇异值分解 (SVD) 的正交分解就可用来计算 A 的秩为 k 的近似 $A_K (K \ll \min(m, n))$ 。加权的意思指的是实际的矩阵中的元素 a_{ij} 通常都取由 $a_{ij} = l_{ij} * g_i$ 定义的有理值, 其中 l_{ij} 是文件 j 中的检索词 i 的局部检索词权重, 而 g_i 是检索词 i 在整个文件集的整体权重。局部和整体检索词权重通常是用来强调或不予强调在文件中和贯穿整个文件集中的检索词的作用。对于我们 SIAM 年会的摘要(译注: 即文件), 我们采用了对数局部加权和熵整体

$$l_{ij} = \log(f_{ij} + 1),$$

加权 (见 [5]) :

$$g_i = 1 + \sum [p_{ij} \log 2(p_{ij})] / [\log(n)],$$

$$p_{ij} = f_{ij} / f_i$$

其中 f_{ij} 是检索词 i 在文件 j 中的出现频率, 而 f_i 是检索词 i 在有 n 个文件的文件集中的整体频率 (全部的计数数目)。

矩阵 A 的 SVD 定义为如下三个矩阵之积

$$A = U S V^T$$

其中 U 和 V 的列分别称为 A 的左和右奇异向量, 它们对应于在数值上按单调递减顺序




图 1 奇异值分解的图示。 U 和 V 的阴影区域和对角矩阵 Σ 表示了原来的检索词 - 文件矩阵 A 的约化表示

排列的对角阵 S 的对角元, 这些对角元称为矩阵 A 的奇异值。如图 1 所示 U, V 矩阵的前 k 列以及 A 的前 k 个 (最大的) 奇异值通过 $A_K = U_K S_K V_K^T$ 构造了一个 A 的秩为 k 的近似。 U 和 V 的列都是正交的, 并使 $U^T U = V^T V = I$ 。图中 r 是矩阵 A 的秩。从 A 的 k 个最大的奇异值三重组 (奇异值及其相应的左、右奇异向量合称奇异三重组) 构造出来的 A_K 是最靠近 A 的秩为 k 的 A 的近似矩阵 (在最小二乘意义下)。

关于 LSI, A_K 是由关联矩阵 A 表示的原来的检索词 - 文件空间的最靠近的 k 维近似。如早先说过的, A 的降维可以消去造成很差的信息性能的噪声。因此, 尽管对好的检索性能来说似乎需要高维表示, 还是一定要小心地避免 A 的重构。如果 A 几乎重构了, 由于词的选择以及张成或几乎张成文件集的检索词的可变性造成的噪声就不可能消去, 从而检索性能就会很差。

在 LSI 中, 左、右奇异向量指定了检索词和文件在约化检索词 - 文件空间中的位置。奇异值常用来度量检索词和文件向量, 以使检索词和文件的聚类更易识别。在约化空间中, 语义相关的检索词和文件大概都会互相靠近, 因为 SVD 试图导出检索词 - 文件空间中的基本的语义结构。

查询投影和匹配

在 LSI 模型中, 查询形成为准文件, 它们规定了查询在约化的检索词 - 文件空间中的位置。给定向量 q , 其非零元素包含了 (由用于正在搜索的文件集的同样的局部的和整体的加权格式给出的) 出现在查询中的检索词的加权的检索词 - 频率记数, 则准文件 $\underline{q}$ 可由

$$\underline{q} = q^T U_k S_k^{-1}$$

来表示。

因此, 准文件由对应于由奇异值的逆 (S_k^{-1}) 标度的查询中规定的检索词的检索词向量 ($q^T U$) 之和构成。奇异值是用来对检索词 - 文件空间中的每个维数个别地加权的。

一旦查询被投影到检索词 - 文件空间, 几种相似性度量中的一种就可用来在约化检索词 - 文件空间中比较准文件的位置和检索词和文件的位置。一种通行的度量是余弦相似性度量, 它只是在约化空间中求准文件和检索词或文件间的夹角; 其结果是: 可能影响到空间中准文件和文件间的距离的所有的文件长度被归一化了。一旦计算出了准文件和空间中所有的检索词和文件间的距离, 按照相似性度量的结果检索词和文件被排了名次, 而且名次最高的检索词或文件, 或者超过某个门槛值的所有的检索词和文件就被返回到用户手中。

把投稿论文进行会议分组

为了对 SIAM 年会的投稿论文进行分组, 我们按照提交的 128 论文构造了一个 1149×128 阶的检索词 - 摘要矩阵 A 。用 SVDPACKC (见 [3]) 来产生检索词和文件 (摘要) 向量的表示从而生成了秩为 $k = 44$ 的约化 LSI 模型 (A_{44})。会议预通知确定的 19 个主题中的每个主题都作为向量 - 空间模型中的一个查询 (q)。 (按照对 q 的余弦相似性) 10 个排名最前面的摘要被记录下来。在最受欢迎主题中有组合优化, 高性能计算, 数值线性代数, 偏微分方程和偏微分方程控制, 以及数学生物学。

正如 Bertly Browne [1] 中所讨论的, 不能指望自动检索会得到和人工检索同样的结果。某些裁决是在把文章最后指定组别时作出的, 但是整个投稿论文的程序是在两天中完成的 (是的, 没错!) 我们曾被要求逐字逐句阅读每篇摘要, 如果要这样做肯定要用更长的时间来完成。

用 LSI 作为这种类型的一个练习的一个额外的好处就是, 我们很快得到一种感觉: 投稿论文和公布的主题匹配得有多好。与所提出的任何主题 (查询) 不能匹配得很好的摘要就进行互相比 (即要计算文件向量间的余弦), 以便对内容相似的文章创立新的分组。在这一阶段, 为控制所配置的分组会的整个数目, 某些人为的干预还是需要的。为平衡指派到个别的分组会中去的论文数目, 也需要类似的干预。在这个意义下, 整个过程并非完全自动化的; 但是应用数学 (或者, 在这种情形, 数值线性代数) 的运用, 使我们赶在截止日期前完成 SIAM 交给我们的任务起了主要作用。运用数学来组织数学 (会议) 看起来是有点在艺术上令人高兴的事, 不是吗?

感谢: 作者要感谢 Tammy Kolda 有关 LSI 及其应用的富有启发性的讨论。

进一步选读: 关于 LSI 的进一步的细节以及有关信息检索的计算模型, 我们推荐由 SIAM 出版的丛书 “软件、环境和工具” 之一的由 Bertly 和 Browne 写的一本新书

[1] 和 SIAM Review 最近发表的由 Berry, Drmac, Jessup 写的文章 [2].

参考文献

- [1] M. W. Berry and M. Browne, *Understanding Search Engines: Mathematical Modeling and Text Retrieval*, SIAM, Philadelphia, 1999.
- [2] M. W. Berry, Z. Drmac, and E. R. Jessup, *Matrices, vector spaces, and information retrieval*, SIAM Rev., 41:2, 1999, 335–362.
- [3] M. Berry, T. Do, G. O'Brien, V. Krishna, and S. Varadhan, *SVDPACKC: Version 1.0 User's Guide*, Tech. Report CS93-194, University of Tennessee, Knoxville, October 1993.
- [4] S. Deerwester, S. Dumais, G. Furnas, T. Landauer, and R. Harshman, *Indexing by latent semantic analysis*, J. Amer. Soc. for Inform. Sc., 41, 1990, 391–407.
- [5] S. T. Dumais, *Improving the retrieval of information from external sources*, Behavior Res. Meth., Instru., & Comp., 23, 1991, 229–236

附录 (译自 [2], pp. 340–342)

图 2.2 展示了由 6 个检索词描述的 5 篇文章标题的集合怎样导至一个 6×5 阶的检索词对文件矩阵。因为一个文件的内容是由检索词的相对频率而不是由特定的检索词出现的次数来决定的。该例子的矩阵中的元素被度量以使每列的欧氏距离为 1. 即对列向量 $a_{ij}, i = 1, 2, \dots, 5$, 有 $\|a_{ij}\|_2 = 1$. 以这样的方式, 我们采用检索词频率作为局部权 l_{ij} 而不用整体加权 (即, $g_i = 1$).

用来描述数据库的术语的选取不仅决定了数据库的大小而且还决定了它的效用。在我们的例子中, 我们只采用与烹调直接有关的检索词, 即对法国烹调特别有兴趣的读者将无法检索到相关的文件。在这种情形, 加进 French 和 Viennese 来描述所覆盖的国家将以一种有帮助的方式来扩展数据库的语义表示。另一方面, 把像 to 或 the 这样很普遍的检索词包括进来几乎不会改进检索词对文件矩阵的质量。将这种高频率出现的词排除的过程称为列入省略词语表 (Stoplisting). (参见 图 2.2)

在构造检索词 - 文件矩阵时, 检索词通常是由其词干来识别的 [33]. 在我们的例子中, 词 pastries 认为是检索词 pastry. 而词 baking 认为是检索词 bake. 在信息检索中利用词干要追溯到 1960 年代 [40]. 利用词干, 减少需要保留的词数目, 因而降低了存储的要求 [48]




图 2.2 检索词对文件矩阵 A 的构造

T1: 烤、焙, T2: 食谱, T3: 面包, T4: 蛋糕, T5: 油酥面团, T6: 馅饼 D1: 没有食谱怎样烤面包, D2: 维也纳式馅饼的经典艺术, D3: 数值方法: 科学计算的艺术; D4: 面包、油酥面团、馅饼和蛋糕: 定量焙烤食谱, D5: 油酥面团: 最佳法国食谱

2.3 查询匹配

利用图 2.2 的小标题集合, 我们可以来说明基于 6 维空间中的角度的查询匹配。假设一个在搜索烹调信息的用户开始搜索烤面包的图书。相应的查询将被写作向量

$$q^{(1)} = (101000)^T$$

其中非零项对应检索词 **baking** 和 **bread**。相关文件的搜索是通过计算查询向量 $q^{(1)}$ 和由 (2.1) 给出的文件向量 a_i 间的夹角 θ_j 的余弦来实现的。仅当一个文件和查询向量间的夹角的余弦大于某个阈值或截断值时该文件才作为相关文件返回。具体实现时可采用诸如 0.9 那样严格的截断值, 但在我们的例子中, 我们采用的余弦阈值为 0.5。

对于查询 $q^{(1)}$, 仅有的非零余弦是 $\cos \theta_1 = 0.8165$ 和 $\cos \theta_4 = 0.5774$ 。因此, 所有有关烤面包的文件 (第一个和第四个文件) 作为相关文件返回。与烤面包无关的第二、三和五这些文件被正确地略去了。

然而, 如果用户仅仅要查有关焙烤的图书, 那么结果将会明显地不同。这时, 查询

向量为

$$q^{(2)} = (100000)^T.$$

而查询向量和五个文件向量间夹角的余弦依次为 0.5774, 0, 0, 0.4082, 0。只有第一个文件, 有关烤面包的一本书, 其余弦大于余弦门值。第四个文件, 事实上是一个有关烘焙的更广泛的参考文献, 没有作为相关文件返回。

信息检索界已经研制了各种各样的方法来处理向量空间模型的这种缺陷。这些方法的典型特征是改变数据在检索词-文件矩阵的表示方式。有关的例子包括检索词加权的方法, 利用一个得到控制的词汇表(特定的一组容许检索词 [33]), 以及用低秩的近似来替代确切的检索词-文件矩阵。后者这种方法就是 LSI 方法的基础 [9, 19], 也是本文所述的新方法(译注: 指本附录)的基础。本文的 § 3 到 § 6 中, 我们将会做降秩的整个过程, 首先用 OR 因子分解, 然后继续做在 LSI 中用到的也许不太熟悉的 SVD。两种情形中, 我们都用因子分解来说明查询匹配的几何并解释什么可以构成检索词对文件矩阵的合理的近似。后者是重要的, 因为 LSI 的支持者争辩说: 降秩这一步对从数据库表示中去掉噪声有用。

附录作者介绍: Michael Berry 是 University of Tennessee, Knoxville 的计算机科学副教授, Jack Dongarra 是该校的计算机科学教授也是 Oak Ridge 国家实验室的科学家。

(叶其孝 译 雷功炎 校)

简讯: Avi Wigderson 成为 IAS 的终身教授

美国普林斯顿高等研究院 (Institute For Advanced Study) 宣布, 任命理论计算机科学领域的专家 Avi Wigderson 为该院数学部的终身教授。

Wigderson 于 1956 年生于以色列, 在普林斯顿大学获博士学位(计算机科学)后, 曾在美国加州大学 Berkeley 分校教书(1983-1984); 在 IBM 研究部任访问科学家(1984-85); 此后在耶路撒冷的希伯来大学工作八年, 历任资深讲师、副教授和教授(1991)。1990-92 年是普林斯顿大学计算机科学系的访问副教授; 1995-96 为高等研究院的访问成员, 1999 年 7 月 1 日成为该院数学部的终身教授。他在 1994 因在理论计算机科学方面的杰出工作获国际数学联盟颁发的 Nevanlinna 奖。

高等研究院院长 P. A. Griffiths 说: “Wigderson 在计算理论(theory of computing)方面的工作, 再一次在研究院开始了 Von Neumann 当年在这里任教授时探索的研究领域”。

——袁向东摘译自 IAS 的 Letter(1999 年冬)