

进展简介

图像处理的变分偏微分方程模型 (I)

Tony F. Chan Jianhong(Jackie) Shen Luminita Vese

在过去的 20 年里传统上属于工程领域的图像处理吸引了许多数学家的注意. 从视觉和认知科学的观点来看, 图像处理是用来从二维 (2-D) 图像重建三维 (3-D) 世界的相对次序、几何学、拓扑学、模式和动力学的基本工具. 所以, 在这个数字技术时代数学一定会触及图像处理不可能仅仅是历史的偶然.

图像处理在当代科学和技术中的广泛应用也决定了数学的角色. 这些应用包括天文学和空间探索、医学成像、分子成像、计算机图形学、人和机器视觉、电信、自动驾驶、监视录像以及生物统计安全识别 (例如指纹和面部识别). 所有这些极不相同的专业领域使得有必要研究共同的数学基础以及图像分析和处理的各种方案. 必须引进所有水平上的数学以处理这个新时代所要求的极其重要的准则 —— 通用性、适定性、精确性和计算的有效性, 我们在这里只列举几个. 作为回报, 图像处理也为数学建模、分析和计算创造了巨大的机会.

本文通过最新而且非常成功的方法之一 —— 变分偏微分方程方法 —— 来给出数学图像处理的范围广阔的描述. 我们首先讨论图像处理中两个极其重要的组成成份: 图像建模或图像表示以及处理器建模. 然后我们集中介绍变分偏微分方程方法. 本文的主要成分由我们个人曾经研究过图像处理中的两个主要问题组成: 不显示 (不画出, inpainting) 和分割. 但是我们绝不企图对图像处理的整个领域作全面的评述. 与本文主题有关的作者的论文和预印本可以从我们小组的主页 [11] 在线找到, 那里也有广泛的参考文献可供利用.

1. 作为一种输入 – 输出系统的图像处理

图像处理和当代计算机科学是两个双重互补的领域 —— 计算机视觉和计算机图形学 —— 直接相关. (无论是计算机或人的) 视觉都试图从观察到的 2-D 图像来重建 3-D 世界, 而图形学则从相反的方向进行研究, 设计适当的 2-D 情景图像来模拟 3-D 世界. 图像处理就是连接两者的极其重要的中介途径.

抽象地说, 图像处理可以看作一个输入 – 输出系统

$$Q_0 \rightarrow \boxed{\text{图象处理器 } I} \rightarrow Q,$$

原题: Variational PDE Models in Image Processing. 译自: Notices of the AMS, Vol.50 (2003), No.1. p. 14-26. 本文是根据 Tony F. Chan 在 2002 联合数学会议上的大会报告写成的.

这里 $\mathcal{I}$ 表示一个典型的图像处理器：例如，降噪、去模糊、分割、压缩或者不显示。输入数据 Q_0 可能表示观察到的或测量得到的单个图像或者图像序列，而输出 $Q = (q_1, q_2, \dots)$ 包括所有的目标图像的特征。

例如，可以把人类视觉系统看作是一个复杂的多层次的图像处理器 $\mathcal{I}$ 。输入 Q_0 表示不断投射到视网膜上的图像序列，输出向量 Q 包括对我们的日常生活来说是重要的所有主要特征，从诸如相对次序、形状以及组群规则的低层次到有助于分类或识别各种模式和对象的高层次的特征参数。

表 1 列出了一些典型的图像处理问题。

$\mathcal{I}$	Q_0	Q
降噪 + 去模糊	$u_0 = Ku + n$	使 u 清洁并轮廓鲜明
不画出	$u_0 _{\Omega \setminus D}$	完整的图像 $u _{\Omega}$
分割	u_0	“对象” $[u_k, \Omega_k], k = 1, 2, \dots$
尺度 - 空间	u_0	多尺度图像 $(u_{\lambda_1}, u_{\lambda_2}, \dots)$
运动估计	$(u_0^{(1)}, u_0^{(2)}, \dots)$	光学流 $(\vec{v}^{(1)}, \vec{v}^{(2)}, \dots)$

表 1 典型的图像处理器及其输入和输出。符号表示 (1) K : 模糊核，而 n : 增加的噪声，在本文中为简单起见假设它们都是线性的；(2) u_0 : 给定的噪声或变模糊的图像；(3) Ω : 完整的图像域，而 D : 图像信息缺损或达不到的子区域；(4) $[u_k, \Omega_k], \Omega_k$ 是所分割的单个“对象”，而 u_k 是它们的亮度值；(5) λ_k 是不同的尺度，而 u_{λ} 可以粗略地理解为输入图像在尺度 λ 下的投影；(6) $u_0^{(n)}$ 表示连续的“电影” $u_0(x, t)$ 的 (具有某个小时间步长 h 的) 离散的样本而 $\vec{v}^{(n)}$ 是在每个时刻估计的光学流 (即，速度场)

图像处理的两个主要组成部分就是输入 Q_0 和处理器 $\mathcal{I}$ 。因此，一直在推动有关图像处理的主流数学研究的两个关键问题是 (a) 输入可视数据 Q_0 的建模和表示，以及 (b) 处理算子 $\mathcal{I}$ 的建模。尽管这两个问题是独立的，但它们经由数学的普遍规律互相紧密相连：算子 $\mathcal{I}$ 的结构和性能极大地依赖于输入函数是怎样建模或表示的。

2. 图像建模和表示

为有效地掌握并处理图像，我们首先需要了解图像在数学上实际上是什么，以及怎样去表示它们。例如，是否把它们当作一般的 L^2 函数或者 L^2 中具有适当正则性约束的子集来处理就够了？这里我们简要地概述一下 3 类主要的图像建模和表示。

随机域建模 一个观察到的图像 u_0 建模为随机域中的样本。例如，统计力学中的 Ising 自旋模型可以用来建模二元图像。更一般地，图像可以用某些 Gibbs/Markov 随机域来建模 [10]。这些域的统计性质常常是通过滤波技术和学习理论来建立的。随机域建模是描述具有诸如树和山那样丰富的纹理模式的自然图像的理想方法。

小波表示 图像常常是从一组数字或生物的微型传感器 (或摄影感受器) 的响应获得的。在过去的 20 年里，人们逐渐认识到 (而且得到实验的支持) 这种局部的响应可以用小波来很好地近似。这种新的表示工具革新了我们关于图像的概念以及它们的多尺度结构 [12]。新的 JPEG2000 图像编码协议以及 FBI 指纹数据库的成功压缩就是它的两个最

有影响的应用. 理论还在由新一代的诸如曲线波 (curvelets) (Candés and Donoho) 和杆波 (beamlets) (Pennec Mallat) 那样的几何小波积极地推向前进.

正则空间 在传统的数字图像处理的线性滤波理论中, 图像 u 是作为 Sobolev 空间 $H^1(\Omega)$ 中的函数来研究的. Sobolev 模型对均匀的区域做得很好, 但是作为整体图像模型来说它是不够的, 因为它“抹掉了”最重要的关于边缘的可见的暗示. 为识别边缘的存在性引进了两个著名的模型. 一个就是 Mumford 和 Shah [13] 的“对象-边缘”模型, 另一个是 Rudin, Osher 和 Fatemi [15] 的 BV 图像模型. 对象-边缘模型假设理想图像 u 由不相交的均匀对象补片 $[u_k, \Omega_k]$ 组成, 其中 $u_k \in H^1(\Omega_k)$ 而且具有 (由一维 Hausdorff 测度表征的) 正则边界 $\partial\Omega$. BV 图像模型假设理想图像有有界的全变差 $\int_{\Omega} |Du|$. 以正则性为基础的图像模型通常可应用于具有低纹理模式以及没有快速振荡组成部分的图像.

3. 图像处理器的建模

图像是怎么被建模和表示的, 在很大程度上决定了我们对图像处理器的建模方式. 我们将通过降噪的例子 $u = \mathcal{I}u_0 : u_0 = u + n$ 来说明这种观点, 为简单起见假设白噪声 n 是可加和均匀的, 而且没有模糊的作用介入.

当图像是用小波表示时, 降噪处理器 $\mathcal{I}$ 在某种意义下被“对角化”了, 而且相当于个别小波分量的简单设计. 这是 Donoho 和 Johnstone 基于阈值的降噪方案的著名结果.

在图像的统计 / 随机域建模的情形, 降噪处理器 $\mathcal{I}$ 变为最大后验 MAP (Maximum A Posteriori) 估计. 由 Bayes 公式, 由观察 u_0 给出的后验概率为

$$p(u|u_0) = p(u_0|u)p(u)/p(u_0).$$

降噪处理器 $\mathcal{I}$ 是由求解 MAP 问题 $\max_u p(u|u_0)$ 来完成的. 所以, 重要的是不仅要知道随机域图像模型 $p(u)$ 而且还要知道从理想图像 u 生成 u_0 的机制 (所谓的生成数据模型). 这两者对于成功地实现 Bayes 降噪是至关重要的.

最后, 如果理想图像 u 被建模为诸如 $H^1(\Omega)$ 或 $BV(\Omega)$ 那样的正则函数空间中的元素, 那么降噪处理器 $\mathcal{I}$ 可以通过变分优化来实现. 例如, 在 BV 图像模型中, $\mathcal{I}$ 是由

$$\min_u \int_{\Omega} |Du| \quad \text{满足} \quad \frac{1}{|\Omega|} \int_{\Omega} (u - u_0)^2 dx \leq \sigma^2$$

来实现的, 其中假设白噪声可以用标准的 Gauss 分布 $N(0, \sigma^2)$ 很好地近似. 首先由 Rudin, Osher 和 Fatemi 提出的众所周知的降噪模型属于更一般的正则化数据-拟合模型类.

恰如描述单个的物理对象的不同的坐标系是互相联系着的一样, 同一个图像处理器的不同的公式阐述也是互相紧密联系着的. 再次以降噪作为例子. 已经证明小波技术等价于在某种 Besov 空间中的近似最优正则化 (Cohen, Dahmen, Daubechies 和 DeVore). 另一方面, Bayes 处理和以正则性为基础的变分方法也可以由统计力学中的 Gibbs 公式 (至少形式地) 联系起来 (见下节 (3)).

4. 变分偏微分方程方法

在简要介绍了数学图像处理的一般情况后, 现在我们把注意力集中于通过两个处理

器：不显示和分割的变分偏微分方程方法。

至于图像和视觉分析中的历史以及变分和偏微分方程方法当前发展的详细叙述，参见在 IEEE Trans. Image Processing [7(3), 1998] 和 J. Visual Comm. Image Rep. [13(1/2), 1998] 上的两期特刊，还有两本新专著 [1], [18].

在变分模型或以“能量”为基础的模型中，当人们要导出形式的 Euler-Lagrange 方程或者试图用梯度下降法定位局部或整体极小时非线性偏微分方程就出现了。有些偏微分方程可以用粘性解方法 [8] 来研究，而其他许多偏微分方程问题仍有待进一步的理论研究。

与其他的方法相比较，变分偏微分方程方法在理论和计算两方面都具有显著的优点。首先，它能使人们直接掌握和处理诸如梯度、切线、曲率以及水平集那样视觉上重要的几何特征。它还能够有效地模拟若干诸如线性和非线性扩散以及信息转移机制那样的视觉上有意义的动力学过程。其次，就计算而言，它能从已有的有关数值分析和计算偏微分方程大量的文献中大大获益。例如，计算流体动力学 (Computational Fluid Dynamics, 缩写为 CFD) 中各种设计很好的俘获激波 (shock-capturing) 的格式可以方便地改写为图像中的边缘计算。

变分图像不显示和插值法

不显示 这个词是图像插值法的艺术同义词；它一开始是在博物馆里手工修复破裂的古代绘画的修复艺术家之间流传。数字不显示的概念是最近在 Bertalmio, Sapiro, Caselles 和 Ballester 的一篇文章中引入数字图像处理的。当前，数字不显示技术在图像处理、视觉分析和诸如图像恢复、分开闭合 (disocclusion)、感知图像的编码、缩放和图像超分辨率、无线图像传输中的误差隐藏等方面 [2], [4], [9] 找到了广泛的应用。图 1 展示了误差隐藏的一个例子。



丢失 80 个数据包的模糊图像

通过全变差不显示的去模糊和误差隐藏

图 1 一张模糊图像的误差隐藏的全变差不显示

现在我们来讨论在变分不显示技术背后的数学概念和方法论。贯穿本节 u 表示 2-D 区域 Ω 上原来的完整的图像，而 u_0 则表示 u 的观察或测量到的部分，它在一个子域或一般的子集 D 上是伴有噪声或模糊的。不显示的目的就在于从 D 上可利用的数据 u_0 尽可能忠实地复原整个图像区域 Ω 上的 u 。

1. 从 Shannon 定理到变分不显示

插值法是逼近论、数值分析以及信号和图像处理的经典论题。成功的插值式包括多项式、调和波、径向对称函数、有限元、样条和小波。尽管有各种不同的文献，但是有一个最广泛认同的属于 Shannon 的结果，称为 Shannon 样本定理。

定理 (Shannon 定理) 如果信号 $u(t)$ 是带宽限制在 $(-\omega, \omega)$ 的，那么¹⁾

$$u(t) = \sum_{n=-\infty}^{\infty} u\left(n\frac{\pi}{\omega}\right) \operatorname{sinc}\left(\frac{\omega}{\pi}t - n\right).$$

即，如果一个 (具有有限能量或等价地属于 $L^2(\mathbb{R})$ 的) 模拟信号 $u(t)$ 不包含任何高频，那么它就可以完全由它的适当选取样本的离散序列 $u_0[n] = u(n\pi/\omega)$ 插值得到 (其中 ω/π 称为 Nyquist 频率)。

所有的插值问题都具有这种“如果 - 那么”结构。“如果”规定了所求的目标信号 u 所在的空间，而“那么”给出了基于离散样本 (或者更一般地，任何有关该信号的部分信息) 的重建或插值步骤。

不幸的是，在大多数信号和图像处理的实际应用中，人们不可能期望有像 Shannon 定理中那样简洁干净的封闭形式的公式。这至少有两方面的因素。首先，在视觉分析和通讯中，因为有边缘 (或 Heaviside 型奇性) 的存在，像图像那样的信号本质上不是带宽有限的。其次，在大多数实际应用中给定的不完全数据往往是带噪声的而且在成像和传输过程中变得模糊了。所以，就 Shannon 定理的情况而言，我们要处理的是一类带有“不可靠”样本 u_0 的“坏”信号 u 。

很自然，对图像不显示，Shannon 定理中的“如果”和“那么”陈述都需要小心地建模。结果表明有两种能完成这项任务的强有力而且互相依赖的架构：一个是变分方法，而另一个就是 Bayes 架构 [10]。

在 Bayes 方法中“如果”陈述既明确说明了所谓的先验模型也规定了数据模型。先验模型明确说明图像是怎样先验地分布的，或者等价地说，哪些图像比其他图像更频繁地出现。用概率论的话来说，它明确说明了先验概率 $p(u)$ 。设 u_0 表示观察到、测量得到的或作为样本的不完全数据。于是“如果”陈述的第 2 部分就是怎样从 u 对 u_0 建模，或明确说明条件概率 $p(u_0|u)$ 。最后，如前面所指出的 Bayes 方案中 Shannon 的“那么”陈述由 Bayes 公式

$$\max_u p(u|u_0) = p(u_0|u)p(u)/p(u_0) \quad (1)$$

给出的最大后验 (MAP) 的最优化所替代。(这相当于最大化先验模型和数据模型的乘积，因为 u_0 一旦给定，分母就是一个固定的正则化常数。) 总结一下，Bayes 不显示的意思就是对给定了一张图像的不完全和可能变形了的观察去求该图像的最可能的图像。

变分方法类似于 Bayes 方法，但是现在每件事都是确定性地表示的。Bayes 先验模型 $p(u)$ 变成了图像 u 的正则性规定，而数据模型 $p(u_0|u)$ 现在是要测量如果原先的图像确实是 u 的话那么观察数据 u_0 与之拟合得有多好。正则性是通过“能量”泛函来实施

1) 函数 $\operatorname{sinc}(x)$ 的定义为：若 $x = 0$, $\operatorname{sinc}(x) = 1$; 若 $x \neq 0$, $\operatorname{sinc}(x) = \sin x/x$ 。——译注

的: 例如, Sobolev 范数 $E[u] = \int_{\Omega} |\nabla u|^2 dx$, Rudin, Osher 和 Fatemi 的全变差 (TV) 模型 $E[u] = \int_{\Omega} |Du|$, 以及 Mumford-Shah 的自由边界模型 $E[u, \Gamma] = \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx + \beta H^1(\Gamma)$, 其中 H^1 表示一维 Hausdorff 测度. 数据拟合 $u \rightarrow u_0$ 的质量常常是由误差度量 $E[u_0|u]$ 来判定的. 例如, 归功于 Gauss 型噪声的一般性以及中心极限定理的最小二乘度量 $E[u_0|u] = \frac{1}{|D|} \int_D (Tu - u_0)^2 dx$ 盛行于文献之中, 其中 D 是 u_0 在其上取样本或测量的区域, $|D|$ 是其面积 (或离散情形的基数). T 表示线性或非线性图像处理器 (例如去模糊和扩散). 在这种变分框架下, Shannon 的“那么”陈述变成一个约束优化问题:

$$\text{在使得 } E[u_0|u] \leq \sigma^2 \text{ 成立的所有 } u \text{ 上取 } \min E[u],$$

这里 σ^2 表示白噪声的方差, 按照适当的统计估计器假设它是已知的. 利用 Lagrange 乘子该模型等价于求解下面的无约束问题 (例如, 见 Chambolle 和 Lions):

$$\min_u E[u] + \lambda E[u_0|u]. \quad (2)$$

一般说, λ 表示正则性和拟合之间的平衡. 总结一下, 变分不显示搜索能最佳拟合给定观察的最“正则”的图像.

Bayes 方法在允许一般的统计先验模型和数据模型的意义下更为通用, 而且对于恢复人工图像和自然图像 (或纹理) 来说该方法是强有力的. 但是要学习先验模型和数据模型通常其代价会相当昂贵. 就处理正则性和几何问题来说变分方法是理想的而且对人为的室内和室外场景和具有低纹理的图像往往会做得很好. 这两种方法 (1) 和 (2) 至少可以在统计力学中的 Gibbs 公式下形式地统一起来:

$$E[\cdot] \propto -\beta \log p(\cdot) \quad \text{或} \quad p(\cdot) \propto e^{-E[\cdot]/\beta}, \quad (3)$$

其中 $\beta = kT$ 是 Boltzmann 常数和温度之积, 而 $\propto$ 的意思是在至多乘一常数或加一常数的意义下相等. (然而, 由于图像的多尺度性质在“所有的”图像上的严格的概率测度的可定义性是极其非平凡的. 最新的努力可以在 Mumford 和 Gidas 的工作中找到.)

2. 基于几何图像模型的变分不显示

在典型图像不显示问题中, u_0 表示在整个图像区域 Ω 上的一张清晰的“好的”图像 u 的不完全的观察到或测量得到的部分. 在各种数字应用中的一个简化的但早已成为强有力数据模型就是经过噪声降低和空间限制后得到的模糊:

$$u_0|_D = (Ku + n)_D,$$

其中 K 是连续模糊核, 常常假设它是线性的甚至是移位不变的, 而 n 是一个可加白噪声域, 为简单计假设它近似于 Gauss 分布. 信息 $u_0|_{\Omega \setminus D}$ 是丢失的或不能收到的信息. 不显示的目标就是从 $u_0|_D$ 尽可能忠实地重建 u .

数据模型是由

$$E[u_0|u, D] = \frac{1}{|D|} \int_D (Ku - u_0)^2 dx \quad (4)$$

显式给出的. 所以, 从变分的观点来看, 不显示模型的质量决定性地依赖于先验模型或正则能量 $E[u]$.

全变差先验模型 $E[u] = \int_{\Omega} |Du|$ 首先是由 Rudin, Osher 和 Fatemi[15] 引入图像处理的. 不像 Sobolev 图像模型 $E_2[u] = \int_{\Omega} |\nabla u|^2 dx$, 全变差模型能识别最重要的视觉特征之一, “边缘”. 例如, 展示带有明亮的满月 ($u = 1$) 的夜空 ($u = 0$) 的卡通图像 u , Sobolev 能量爆破了 (blow up), 而全变差能量 $\int_{\Omega} |Du|$ 等于月亮的周长, 是有限的. 所以, 与数据模型 (4) 相结合, 变分全变差不显示模型极小化了

$$E_{TV}[u|u_0, D] = \alpha \int_{\Omega} |Du| + \lambda \int_D (Ku - u_0)^2 dx. \quad (5)$$

容许空间是 $BV(\Omega)$, 由所有的有界变差函数组成的 Banach 空间. 这和 Rudin, Osher 和 Fatemi[15] 著名的全变差复原模型非常相似. 事实上, 该模型的优美和力量正好在于它提供了一种把降噪、去模糊以及从不完整数据重建图像统一起来的框架. 图 1 展示了该模型应用于由于网络传输故障造成的模拟的随机信息包丢失的一张模糊图像的计算结果.

第 2 个众所周知的先验模型就是 Mumford 和 Shah[13] 中的对象-边缘模型. 不像全变差模型, 现在边缘集 Γ 被明显地单独挑出来了, 而且图像 u 理解为几何特征 Γ 和在 $\Omega \setminus \Gamma$ 的所有连通分量 Ω_i 上的分段光滑“对象” u_i 这两者的结合. 因此就 Bayes 语言和变分语言这两种语言来说, 先验模型包括两部分 (对概率和“能量”之间的转移应用 (3)):

$$p(u, \Gamma) = p(u|\Gamma)p(\Gamma) \quad \text{以及} \quad E[u, \Gamma] = E[u|\Gamma] + E[\Gamma].$$

在 Mumford-Shah 模型中边缘的正则性是由一维 Hausdorff 测度 $E[\Gamma] = H^1(\Gamma)$ 规定的, 或者在大多数计算应用中假设了 Γ 是 Lipschitz 的, 那么 $E[\Gamma] = \Gamma$ 的长度. “对象”的光滑性自然由通常的 Sobolev 范数 $E[u|\Gamma] = \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx$ 来表征. 所以, 与数据模型 (4) 结合, 基于 Mumford-Shah 先验的变分不显示模型由

$$\inf_{u, \Gamma} E_{ms}[u, \Gamma|u_0, D] = \alpha \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx + \beta H^1(\Gamma) + \lambda \int_D (Ku - u_0)^2 dx \quad (6)$$


给出. 图 2 展示了这个模型对去除文本的一个应用. 注意边缘保留下来了而且光滑的区域仍然是光滑的.

众多的应用已经表明对于降噪、去模糊和分割中的经典应用来说, 即使按照人类视觉的高标准, 全变差和 Mumford-Shah 模型两者都表现得足够地好. 但是不显示确实有其特别的特征. 我们在 [2], [4], [9] 中已经证明对于大尺度的不显示问题, 为得到更忠实的视觉效果融入曲率信息的高阶图像模型就变得必要了.

高阶几何图像模型的关键就是 Euler 的弹性曲线模型:

$$e[\gamma] = \int_{\gamma} (a + b\kappa^2) ds, \quad a, b > 0,$$

其中 κ 表示数量曲率. 在逼近论中 Birkhoff 和 de Boor 称之为“非线性样条”模型. 这首



要去显示的图像

哈罗！我们是企鹅 A 和 B。你们这些家伙一定认为那么多的字造成大量图像信息的丢失。真是这样吗？我们有不同的意见。我们则更为乐观。

去显示的区域（或屏蔽区域）



去显示后的结果

图 2 Mumford-Shah 对文本去除的不显示

先由 Mumford 引入计算机视觉。和直线 ($b = 0$) 不同，由于有曲率项弹性模型允许光滑曲线，对于计算机视觉和计算机图形学来说这是重要的。

把这个弹性能量加到 u 的每个个别的等高线上去（至少是象征性地或假设 u 足够正则），我们得到所谓的弹性图像模型：

$$E_{el}[u] = \int_{-\infty}^{\infty} e[u \equiv \lambda] d\lambda = \int_{-\infty}^{\infty} \int_{u \equiv \lambda} (a + b\kappa^2) ds d\lambda = \int_{\Omega} (a + b\kappa^2) |\nabla u| dx. \quad (7)$$

在最后一个被积函数中曲率由 $\kappa = \nabla \cdot [\nabla u / |\nabla u|]$ 给出。（注意在没有曲率项时，上面的公式正好是光滑函数的余 - 面积 (co-area) 公式（例如，参看 Giusti）。对于不显示的这个弹性先验模型首先由 Masnou 和 Morel 以及 Chan, Kang 和 Shen [2] 进行了研究，而且如所预期的那样改进了全变差不显示模型。

类似地，Mumford-Shah 的图像模型 E_{ms} 可以通过用 Euler 的弹性能量来代替长度能量得到改进：

$$E_{mse}[u, \Gamma] = \alpha \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx + e[\Gamma].$$

这首先由 Esedoglu 和 Shen [9] 应用于图像不显示。图 3 展示了把这种图像先验模型应用于一个闭锁的圆盘的不显示的一个例子。全变差和 Mumford-Shah 不显示模型两者都能完成具有直线边缘的插值，同时作为结果引进了可见的角。弹性模型复原了光滑的边界。

基于曲率的模型所改进的性能来自理论和计算两方面所付出的很大代价。全变差和 Mumford-Shah 不显示模型的存在性和唯一性可以用类似于经典的复原和分割问题的方式来研究。但是对高阶模型的理论研究只是刚刚开始。困难在于涉及到曲率的二阶几何特征以及对研究这些模型的适当的函数空间的识别。其次，就计算方面讲，带曲率项的变分法导致四阶高度非线性的偏微分方程，其快速而且有效数值解法提出了极大的挑战。

我们就计算，特别是对全变差和 Mumford-Shah 不显示的计算作简短讨论来结束本节。




图 3 由 Mumford-Shah-Euler 模型产生的光滑不显示 (部分)

对全变差不显示模型 E_{TV} , Euler-Lagrange 方程形式地 (或假设 u 属于 Sobolev 空间 $W^{1,1}$) 由

$$-\nabla \cdot \left[\frac{\nabla u}{|\nabla u|} \right] + \mu K^* \chi_D(Ku - u_0) = 0 \quad (8)$$

给出. 这里 K^* 表示线性模糊核 K 的伴随核, 乘子 $\chi_D(x)$ 是 D 的指示器, 而 $\mu = 2\lambda/\alpha$. 为了在分部积分过程中消去所有的边界贡献, 沿 $\partial\Omega$ 的边界条件为 Neumann 绝热边界条件. 可以利用冻结技巧迭代地求解这个偏微分方程: 如果 $u^{(n)}$ 表示第 n 步的当前不显示, 那么最新的不显示是 $u^{(n+1)}$ 线性偏微分方程

$$-\nabla \cdot \left[\frac{\nabla u^{(n+1)}}{|\nabla u^{(n)}|} \right] + \mu K^* \chi_D(Ku^{(n+1)} - u_0) = 0$$

的解. 在实践中, 中间的扩散系数 $1/|\nabla u^{(n)}|$ 常常被修改为对某个小的条件参数 ε 或在 ε 和 $1/\varepsilon$ 之间的强制的最高和最低限度的 $1/\sqrt{|\nabla u^{(n)}|^2 + \varepsilon^2}$. 这种算法的收敛性在文献中得到了很好的研究 (例如, Chambolle 和 Lions, 以及 Dobson 和 Vogel). 在文献中还有求解 (8) 的许多其他可能的方法 (例如, Vogel 和 Oman, 以及 Chan, Mulet 和 Golub). 我们只需要把 (8) 和常规的全变差复原情形联系起来就行了.

Mumford-Shah 不显示模型的计算也是很有趣的. 不显示和分割不同, 人们的直接兴趣只是在 u 而不在 Γ . 这种理解使得 Γ -收敛逼近论对不显示是理想的工具. 根据 Ambrosio 和 Tortorelli 的做法, 通过引进一个边缘识别特征 (signature) 函数 $z(x) \in [0, 1]$, $x \in \Omega$, 并且用 $E[u|z] = \alpha \int_{\Omega} z^2 |\nabla u|^2 dx$ 来代替 $E[u|\Gamma] = \alpha \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx$, 人们就能用关于 z 的二次积分 (至多差一个常数乘子) 来近似 Mumford-Shah 模型中的长度能量:

$$E_{\varepsilon}[z] = \beta \int_{\Omega} \left(\frac{\varepsilon |\nabla z|^2}{2} + \frac{(z-1)^2}{2\varepsilon} \right) dx, \quad \varepsilon \ll 1.$$

因此 Mumford-Shah 不显示模型由

$$E_{\varepsilon}[u, z|u_0, D] = E[u|z] + E_{\varepsilon}[z] + \lambda E[u_0|u, D]$$

近似, 这是一个关于 u 和 z 都是二次积分! 这就导致了关于 u 和边缘识别特征 z 的耦合线性椭圆型偏微分方程组, 它可以利用任何数值椭圆求解器来有效地求解. 图 2 中的例子就是用这个方案来计算的.

最后, 我们要提一下前面研究过的不显示和几何图像插值模型的某些主要应用. 这些应用包括数字缩放、基于初始简图的知觉图像编码、无线图像传输的误差隐藏以及在计算机视觉中的累进不闭合 [2],[4], [9]. 推广到彩色或更一般的超光谱图像以及非平坦的图像特征 (即, 在 Riemann 流形上的图像) 目前也在文献中得到研究. 对不显示问题的其他方法可以在 Bertalmio, Sapiro, Caselles 和 Ballester, 以及 Bertalmio, Bertozzi 和 Sapiro 的文章中找到. 特别是在后者的文章中会有趣地发现由 Ballester, Bertalmio, Caselles, Sapiro 和 Verdera 早先提出的偏微分方程和流体动力学中的流函数-旋度方程有密切的联系.

(叶其孝 译 吴庆宝 校)