

马尔可夫链蒙特卡洛方法的演变 (II)

Matthew Richey

3. 模拟淬火法与组合优化: KIRKPATRICK 等人, 1983 年

尽管在统计物理学中米特罗波利斯算法颇受欢迎, 而且黑斯廷斯也注意到了它作为一种通用抽样工具潜力, 但是在 1980 年以前, 圈外的人很少了解该算法. 情况随着 Scott Kirkpatrick (柯克帕特里克), C. D. Gelatt, M. P. Vecchi 1983 年的文章“采用模拟淬火法的优化 (Optimization by Simulated Annealing)” [45] 的出现而发生改变. 几乎同时, 捷克应用数学家 V. Černý 在他 1985 年的论文“流动推销员问题的热力学方法: 一个有效的模拟算法 (Thermodynamical Approach to the Traveling Salesman Problem: An Efficient Simulation Algorithm)” [9] 中独立地开发了同样的想法. 柯克帕特里克等人的工作更为人所知而且理应如此; 因为他们更为深入地发展了淬火法的数学原理, 并且将它应用到了一大类问题中. 尽管我们将主要侧重于他们的工作, 然而, 由于其本身的内容, Černý 的论文是重要的, 值得为更多的人所了解.

柯克帕特里克等人是 IBM 托马斯沃森研究中心的成员. 他们那时正在研究组合优化相关的问题, 对于这一类确定性问题, 米特罗波利斯算法出人意料地有效. 组合优化问题主要有两个特点:

1. 一个目标 (费用) 函数, 要求其全局最小值.
2. 一个离散 (常为有限, 但巨大) 的搜索空间, 在其中需求全局最小值. 实际上, 全局最小值的近似就是可以接受的最好结果了.

一个典型的组合优化问题就是流动推销员问题 (TSP), 目的是最小化遍历所有节点的旅行距离. 搜索空间由可能的旅行路线组成, 而目标函数是总旅行距离. 正如其他组合优化问题一样, TSP (当重述为一个判定问题时) 是 NP 完全的.

柯克帕特里克和其他作者是作为统计物理学家受训的, 他们很自然地把目标函数当作一个能量函数. 在了解到自然界总是寻找低能量构形之后, 他们就考虑利用米特罗波利斯算法去选择搜索空间中的低能构形的方法. 他们发现挑战在于, 寻找合理使用温度参数 T 的方法, 而在组合优化框架中它没有一个明显的对应量. 对于较大的 T , 米特罗波利斯算法基本上产生一个一致分布, 因而这与随机搜索无异. 对于较小的 T , 米特罗波利斯算法动辄陷于局部极小值, 而与所期望的全局最小值相差甚远. 对于如何正确利用 T 的理解需要来自统计力学的洞察力. 我们将构建柯克帕特里克及其他作者最初的论证, 看看他是如何处理这个难题的.

译自: The Amer. Math. Monthly, Vol.117 (2010), No.5, p.383–413, The Evolution of Markov Chain Monte Carlo Methods, Matthew Richey, figure number 5. Copyright ©2010 the Mathematical Association of America. Reprinted with permission. All rights reserved. 美国数学协会授予译文出版许可.

3.1. 电路设计与自旋玻璃

激起柯克帕特里克等人当初论文的问题，并不是 TSP，而是如何有效地在电脑芯片上布置电路元件（例如晶体管）。位于同一块芯片上的电路容易沟通，但是不同芯片之间的电路之间的信号沟通则会有重大的障碍。我们的目标是如何分配电路元件，使得在总通信费用最小的情况下，每个芯片上具备（大体）相当的元件数目。

为了从数学上叙述这个问题，假设要在两块芯片上布 N 个元件。一个构形 ω 由以下 N 数组表示：

$$\omega = (\omega_1, \omega_2, \dots, \omega_N),$$

其中 $\omega_i = \pm 1$ 表示第 i 个元件是位于哪块芯片上。而 a_{ij} 表示元件 i 和 j 之间的信号线（连接线）数目。

柯克帕特里克及其合作者定义芯片间的通信费用为

$$\sum_{i>j} \frac{a_{ij}}{4} (\omega_i - \omega_j)^2. \quad (12)$$

而每两块芯片之间的电路数目不同导致的不均衡代价可表示为：

$$\lambda \left(\sum_i \omega_i \right)^2, \quad (13)$$

其中 $\lambda > 0$ 表示不均衡“惩罚”。

将 (12) 展开，并将其与 (13) 组合，去掉所有常数项，产生了目标函数

$$C(\omega) = \sum_{i>j} \left(\lambda - \frac{a_{ij}}{2} \right) \omega_i \omega_j. \quad (14)$$

1980 年代早期，IBM 的研究者开发了多种算法用以（近似）最小化 $C(\omega)$ 。随着晶体管数目 N 从几百增至上千（乃至更多）时，这些方法都变得越来越不适用。正如柯克帕特里克回忆，

以前的方法很神秘，如果你仔细查看这些算法，他们包含着解决一个接一个相互冲突的目标。我们知道我们可以做得好些。（S·柯克帕特里克，个人通信）

幸运的是，柯克帕特里克等人知道在统计力学中有一个模型，其能量函数与 (14) 极其相似。这个模型被称为 自旋玻璃。

自旋玻璃很像伊辛模型，只不过能量函数稍有差别

$$E(\omega) = \sum_{i>j} (U - U_{ij}) \omega_i \omega_j.$$

与 (14) 类似这一点是显而易见的。 U_{ij} 表示的是相邻状态间的局部吸引力（铁磁力）。这些力与用 U 表示的远距抗力（抗铁磁力）对抗。自旋玻璃被称作 受抑的（frustrated）是因为它们不具备同时满足吸引与排斥要求的构形。因而，低能基态不能填满纯对称区域。

对于自旋玻璃以及其它受抑系统，柯克帕特里克知道必须仔细考虑米特罗波利斯算法的应用以便识别低温基态。如果系统 熄火，即降温过于迅速，则它会停在任何一个非

基态的状态上. 一个较好的方法是 淬火, 也就是缓慢地降低温度, 使系统逐渐演变到一个基态. 基于这一观察, 柯克帕特里克等人得出 模拟淬火算法.

对于一个给定的优化问题, 以费用函数替换能量函数, 并由一组参量 $\{x_{ij}\}$ 定义构形, 米特罗波利斯算法可直接生成在某些有效温度时的所有构形. 温度与费用函数一样也是控制参数. 模拟淬火过程由首先在一个高的有效温度时“熔化”待优化的系统, 然后缓慢地逐步降低温度直到系统“冻结”, 并且不再有更进一步的变化发生这样两步组成. 在每一个温度, 必须进行足够长时间的模拟以便系统能够达到稳定状态. 试图在每个温度达到平衡状态的一系列温度以及参数 $\{x_{ij}\}$ 重排的次数可以被考虑为一个淬火程序. [45]

柯克帕特里克等人将这个新技术应用到几个电路设计实际问题中, 同时也以 TSP 为例证明了它的有效性. 结果令人印象深刻——显然模拟淬火法成功了. 并且几乎在同时, Černý 将他的版本的模拟淬火法应用于 TSP 得到了类似的结果.

3.2. 柯克帕特里克等人之后

从 1983 年起, 模拟淬火法就成了应用数学家工具箱中的一件标准工具. 应用此方法的问题的范围是令人吃惊的. 在某种程度上, 对于离散情形和连续情形它都是有效的. 它被用于几乎所有应用数学的领域中, 包括运筹学, 生物学, 经济学以及电子工程. 组合优化领域充斥着仅能解决特别的问题甚至特别的问题的特殊情形有效的算法. 但是它们中大多是对手头特定问题量身定做以适应其细微之处的. 模拟淬火法的流行则在于其有效性和便于实施的结合: 给定一个目标函数与一个请求转移, 几乎总是都能应用模拟淬火法.

可能是由于缺乏坚固的数学框架, 经过了相当的时间模拟淬火法才被应用数学界接受. 第一个模拟淬火法的彻底的实证分析出现在 1989 年, 由 Johnson, Aragon, McGeoch, Schevon 的一系列论文构成 [41, 42]. 一些理论问题的精彩讨论, 模拟淬火法 (特别是由柯克帕特里克等人所考虑的那种模拟淬火法) 应用的综述, 以及相较于其它相关算法性能的更多分析可参见 [66, 65]. 对于模拟淬火法的易于为初学者理解的描述和一些简单应用的例子, 可参见文献 [1].

模拟淬火法的计算效率取决于请求转移与能量函数之间的关系. 一个好的请求转移应当——通常以一种与问题规模无关的方式——尽可能小地改变能量函数, 即 ΔE 便于计算. 在最初电路设计的问题中, 请求转移由随机选择一个电路, 并把它移到另一块芯片上组成. 因而计算能量改变的成本与问题规模无关. 这一高效的, 局部改变的优点在 Geman 兄弟的工作中也得到了论证, 他们用了米特罗波利斯算法与模拟淬火法中的一些思想, 用以解决数字图像重构的一些问题.

3.3. 模拟淬火法的一个应用

模拟淬火法的一个应用是流动推销员问题, 从中可以看出局部改变思想的重要性. 在这个情形, 构形 ω 是一个通过 n 个顶点的旅行, 他用 $(1, 2, \dots, n)$ 的一个置换表示.

一个简单的请求转移由随机地选择两个顶点 $1 \leq i < j \leq n$, 并逆转它们之间路的方

向。这意味着如果

$$\omega = (a_1, \dots, a_{i-1}, a_i, a_{i+1}, \dots, a_{j-1}, a_j, a_{j+1}, \dots, a_n),$$

则

$$\omega' = (a_1, \dots, a_{i-1}, a_j, a_{j-1}, \dots, a_{i+1}, a_i, a_{j+1}, \dots, a_n).$$

可以容易地计算旅行距离 (能量) 的变化:

$$\Delta E = (|a_{i-1} - a_j| + |a_i - a_{j+1}|) - (|a_{i-1} - a_i| + |a_j - a_{j+1}|).$$

图 2 作为一个例子说明了模拟淬火法对于一个 TSP 图的实现, 其中 TSP 图由单位正方形内随机放置的 500 个顶点构成.




图 2 模拟淬火法应用于由 500 个随机顶点构成的 TSP. 左图为初始 ($T = 4.0$) 构形, 总长度约为 253. 中间的构形经过几百次的迭代 ($T = 0.04$), 总长度约为 50. 右边的构形总长度接近全局最小值 17 ($T = 0.002$)

4. 吉布斯抽样与一种贝叶斯视角: GEMAN 兄弟, 1984 年.

我们故事的下一章发生在 1984 年, 那时 Donald 和 Stuart Geman 兄弟在文章“随机松弛, 吉布斯分布, 和贝叶斯图像复原 (Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images)” [28] 中证明了, 米特罗波利斯算法的一种变体可以用于数字图像复原问题. 这篇文章引入了一种新的 MCMC 方法, 吉布斯抽样.

4.1. 贝叶斯的数字图像

一个简单的数字图像模型由 N 个格点的矩形网格上的像素组成. 每一个像素从强度级 (例如, 灰度或彩色值) 集合 $\mathcal{S} = \{1, 2, \dots, K\}$ 中取其值. 一个构形 (图像) $\omega \in \Omega$ 为对 N 个格点强度值的一个分配方式, 即对于 $i = 1, 2, \dots, N$, $\omega_i \in \mathcal{S}$. 即便是中等大小的图像都会导致一个极大的构形空间; 对一个 100×100 二值图像, $|\Omega| = 2^{10000}$.

图像可通过多种方法降质. Geman 兄弟考虑的模型由模糊, 非线性变换, 和噪声组合而成. 我们只关注加噪声这种方法, 可以 N 个服从独立同分布 (IID) 随机值 $\mathcal{N} = \{\eta_1, \eta_2, \dots, \eta_N\}$ 为模型. “白噪声” 是常见的; 在这种情形, η_i 服从均值为 0 方差为 σ^2 的分布 (即 $\eta_i \sim N(0, \sigma^2)$). 令 ω^{blurred} 表示降质 (加噪声) 图像, 我们有

$$\omega^{\text{blurred}} = \omega + \mathcal{N}.$$

注意, ω^{blurred} 为实数; 最终图像由把每一个值取整到 $\mathcal{S}$ 中最接近的值所确定. 图 3 中的两个图像展示了 200×200 的双色图像以及通过添加 $N(0, 1.5^2)$ 白噪声降质后的图像.

原始图像与降质后的图像之间的关系本质上是由概率决定的；给定任一个 ω ，存在某个概率使得一个特别的 ω^{blurred} 为 ω 的降质形式。图像重构则反之；给定 ω^{blurred} ，存在某个概率使 ω 为原始图像。这就导致贝叶斯规则¹⁾的一个应用，以及对 ω 在 ω^{blurred} 上加条件的所谓 后验分布 的公式：

$$\text{Prob}(\omega | \omega^{\text{blurred}}) = \frac{\text{Prob}(\omega^{\text{blurred}} | \omega) \text{Prob}(\omega)}{\text{Prob}(\omega^{\text{blurred}})}. \quad (15)$$

目的是找到构形 ω ，它最大化 $\text{Prob}(\omega | \omega^{\text{blurred}})$ ，这通常称为 最大后验估计。



图 3 一个 200×200 的双色图像 ω ，和一降质图像 ω^{blurred} ，通过加 $N(0, 1.5^2)$ 的白噪声得到

尽管贝叶斯形式具备优雅的数学表达，但是寻找最优的 $\omega \in \Omega$ 对于计算而言仍是一个特别的挑战，正如在统计物理学和组合优化中遇到的困难一样。Geman 兄弟的回答是构造一种新型的米特罗波利斯算法——吉布斯抽样。

要理解吉布斯抽样与统计力学的联系，我们首先来看 Geman 兄弟是如何构造后验分布 (15) 的。考虑 (15) 右端的 3 个概率。

- $\text{Prob}(\omega^{\text{blurred}} | \omega)$: 似然 函数。
- $\text{Prob}(\omega)$: ω 的所谓的 先验 分布。
- $\text{Prob}(\omega^{\text{blurred}})$: 分母。

其中分母由下式给出

$$\text{Prob}(\omega^{\text{blurred}}) = \int_{\omega \in \Omega} \text{Prob}(\omega^{\text{blurred}} | \omega) \text{Prob}(\omega) d\omega,$$

其中积分 (或和) 施行于所有 $\omega \in \Omega$ ，因此与 ω 无关。回忆分拆函数，以及我们所知道的有关米特罗波利斯算法 (和模拟淬火法) 的知识，我们可以安全地忽略它。

似然函数 $\text{Prob}(\omega^{\text{blurred}} | \omega)$ 很容易处理。由于

$$\omega_i^{\text{blurred}} = \omega_i + \eta_i,$$

1) 我们这里不区分概率函数与概率密度函数，希望这一点不会导致混淆。——原注

其中 $\eta_i \sim N(0, \sigma^2)$, 因而

$$\text{Prob}(\omega^{\text{blurred}} | \omega) \propto \prod_{i=1}^N e^{-\frac{(\omega_i^{\text{blurred}} - \omega_i)^2}{2\sigma^2}} = e^{-\frac{1}{2\sigma^2} \sum_{i=1}^N (\omega_i^{\text{blurred}} - \omega_i)^2},$$

式中的比例常数将被上面提及的分母吸收.

确定先验分布 $\text{Prob}(\omega)$ 是一个微妙的问题, 也是贝叶斯方法的核心所在. 从概率上说, 什么是图像? 任何像素值的集合都可被称作图像, 但有些说法更能解释为图像. 大体来说, 图像具有一定的模式, 即, 类似像素值的相邻区域. 另一方面, 如果相邻像素值不具备相关性, 则结果视觉上等价于白噪声. 这使我们想起伊辛模型. 例如, 考虑图 1 中处于均衡态的伊辛网格. 左边的图像由于过于“嘈杂”而不认为是图像的原型. 相反, 右边的图像具备图像类的属性, 即远距像素间的高度相关性.

这一观察提醒 Geman 兄弟, 其中用了伊辛模型能量函数 (9) 的玻尔兹曼分布 (4) 可以当作图像的先验分布, 即,

$$\text{Prob}(\omega) \propto e^{-E_{\text{ising}}(\omega)/kT}.$$

为了维持像素值的相关性这一想法, 他们令 $kT/J = 1 < T_c$, T_c 为临界温度, 相变发生在温度低于 T_c 时.

把 (15) 的所有部分放在一起, 后验分布 $\text{Prob}(\omega | \omega^{\text{blurred}})$ 可以写为:¹⁾

$$\begin{aligned} \text{Prob}(\omega | \omega^{\text{blurred}}) &\propto e^{-\frac{1}{2\sigma^2} \sum_{i=1}^N (\omega_i^{\text{blurred}} - \omega_i)^2} e^{-E_{\text{ising}}(\omega)} \\ &\propto e^{-\left(\frac{1}{2\sigma^2} \sum_{i=1}^N (\omega_i^{\text{blurred}} - \omega_i)^2 + E_{\text{ising}}(\omega)\right)}. \end{aligned} \quad (16)$$

从统计力学的角度看 (16) 导致一种类似的能量函数

$$\begin{aligned} E_{\text{image}}(\omega | \omega^{\text{blurred}}) &= \frac{1}{2\sigma^2} \sum_{i=1}^N (\omega_i^{\text{blurred}} - \omega_i)^2 + E_{\text{ising}}(\omega) \\ &= \frac{1}{2\sigma^2} \sum_{i=1}^N (\omega_i^{\text{blurred}} - \omega_i)^2 + \sum_{\langle i, j \rangle} \omega_i \omega_j, \end{aligned} \quad (17)$$

其中 $\langle i, j \rangle$ 表示节点 i 和 j 是最近邻的.

给定 ω^{blurred} , 寻找最有可能的原始图像 ω 等价于最小化 $E_{\text{image}}(\omega | \omega^{\text{blurred}})$. (17) 的第 1 项是离数据 ω^{blurred} 过远的补偿, 第 2 项则表示相邻像素值的联合, 即使它们符合一个通用图像的先验概念. 最优解是这两个相互冲突的约束条件间的均衡.

对比柯克帕特里克及其合作者和 Geman 兄弟的方法会更有趣, 他们都从统计力学中获得灵感. 柯克帕特里克等从目标函数着手, 将其理解为能量函数, 最终使用的是物理学家的概率概念. Geman 兄弟则从概率问题出发, 引入贝叶斯结构, 最终导出能量函数.

4.2. 吉布斯抽样

吉布斯抽样是 Geman 兄弟版本的米特罗波利斯算法. 对于一个图像节点 ω_i , 我们把其所有最近邻节点看作它的近邻系统. ω_i 的条件加在所有其它节点上的概率仅取决于近

1) 下式第一行右端 $\frac{1}{2\sigma^2}$ 之前原文缺少“-”号.——校注

邻系统的那些节点. 简化关于 ω^{blurred} 的条件依赖性, 这意味着

$$\begin{aligned}\text{Prob}(\omega_i | \omega_j, \text{使得 } j \neq i) &= \text{Prob}(\omega_i | \omega_j, \text{使得 } \langle i, j \rangle) \\ &\propto e^{-E_i(\omega_i | \omega_j, \text{使得 } \langle i, j \rangle)} \\ E_i(\omega_i | \omega_j, \text{使得 } \langle i, j \rangle) &= \frac{1}{2\sigma^2}(\omega_i^{\text{blurred}} - \omega_i)^2 + \sum_{\langle i, j \rangle} \omega_i \omega_j.\end{aligned}$$

通常, 当一概率分布的条件概率仅依赖于近邻系统的取值时, 此分布被称作 贝叶斯分布, 同时也是所谓 马尔可夫随机场 结构的一部分, 这一概念由俄罗斯统计物理学家 R. L. Dobrushin [18] 引入. 节点 i 状态的条件加在所有其它节点上的概率仅依赖于一个小邻域中的节点, 这一事实对于吉布斯抽样的计算有效性极其重要.

为了实现吉布斯抽样, 可利用任一种方法, 只要保证所有节点都被无穷多次地遍历到. 例如, 对节点使用光栅扫描 (按行和列的次序) 就可以了. 在选定节点 i 处, 按下式概率使 $\omega_i = k$:

$$\text{Prob}(\omega_i = k) \propto e^{-\frac{1}{2\sigma^2}(k - \omega_i^{\text{blurred}})^2 - k \sum_{\langle i, j \rangle} \omega_j}. \quad (18)$$

这就是吉布斯抽样. 重复足够多次的光栅扫描, 最终会生成趋近后验分布 (16) 抽样的图像序列.

这一方法似乎与米特罗波利斯 (— 黑斯廷斯) 算法不同: 没有请求转移. 实际上, 吉布斯抽样非常适合黑斯廷斯对米特罗波利斯算法所作的推广, 那里的请求转移概率由 (18) 给出. 在米特罗波利斯 — 黑斯廷斯算法的第 2 步, (11) 中的概率 α_{ij} 全部为 1. 因此, 吉布斯抽样可以生成表示 $\text{Prob}(\omega | \omega^{\text{blurred}})$ 的抽样的一个序列.¹⁾

降质图像的贝叶斯表示早在 Geman 兄弟的工作之前就有了. 例如, 1972 年 Richardson [53] 使用贝叶斯规则定义一种新的方法作为图像重构的标准傅立叶变换方法的替代. 他的方法预示了 Geman 兄弟开发得更加充分的迭代思想. 同一时代其他人以不同方式使用了贝叶斯的这一观点 [38, 33, 51]. 并且早先我们注意到, 到 1980 年为止, 贝叶斯型算法 (通常也被称作 “旋转 — 翻转 (spin-flip)” 算法) 已成为统计力学中的标准工具. 与此同时, 米特罗波利斯算法被用来生成数字纹理 (digital textures) [14].

Geman 兄弟的洞察在于融合贝叶斯表示 —— 它提供了丰富的模型来描述原始图像与降质图像间的关系 —— 与米特罗波利斯算法的强大功能. 而计算高效性的关键在于局部的近邻系统, 即, 局部特性. 这意味着 ΔE 的计算与图像大小无关.

... 利用下述关键的观察解决了计算问题: 后验分布也服从吉布斯分布, 且具备与原始图像大致相同的局部近邻系统 ... [28]

Geman 兄弟的吉布斯抽样中还有一个第 2 部分几乎被历史所遗忘. 它们包含了一个

1) 因为转移不再与时间无关 (由于它们依赖于节点的选择), 因此证明过程比黑斯廷斯等人最初直接的代数处理方法更为复杂一些. 该吉布斯抽样形式的收敛性证明可参见 [34, 25, 27, 8]. — 原注

“温度”参数 T , 并且使用了一个模拟淬火法的简单形式.¹⁾ 最后的概率分布为

$$\text{Prob}(\omega | \omega^{\text{blurred}}) \propto e^{-E(\omega | \omega^{\text{blurred}})/T}.$$

Geman 兄弟所用的淬火程序对每一温度 T 仅进行一步吉布斯抽样. 他们不仅严格证明了当 $T \rightarrow 0$ 时这个算法收敛到后验概率 (15) 的最大值, 并且他们也提供了有关 MCMC 方法收敛率第一个定量的结果.

定理 4.1 (Geman and Geman [28]) 考虑具备 N 个像素的图像. 令 T_k 为递减的温度序列, 使得

- 当 $k \rightarrow \infty$ 时 $T_k \rightarrow 0$.
- 对于所有充分大的 k 和常数 Δ , 有 $T_k \geq N\Delta/\ln k$.

则, 以 $\omega^0 = \omega^{\text{blurred}}$ 开始, 吉布斯抽样序列 $\omega^k (k = 0, 1, \dots)$ 依分布一致地收敛到如下分布: $E_{\text{image}}(\omega)$ 的最小值, 其余为 0.

换言之, 采用既定的淬火程序, 吉布斯抽样从理论上必定生成 $\text{Prob}(\omega | \omega^{\text{blurred}})$ 的一个最大后验估计.

虽然这个结果保证了收敛到最有可能的图像, 收敛速率却极其缓慢. 对一个 100×100 的格点 ($N = 10^4$ 节点) 图像, 根据定理从 $T = 4$ 到 $T = 0.5$ 需要 e^{20000} 步. 实际中, Geman 兄弟发现只需 300—1000 次光栅扫描就可生成能够接受的结果.

吉布斯抽样的一个应用可见图 4 所示的双色图像. 对一个双色图像, 吉布斯抽样 (包括淬火) 是直接实施的. 在像素 ω_i 处, 定义

$$E^k = \frac{1}{2\sigma^2} (k - \omega_i^{\text{blurred}})^2 + k \sum_{\langle i,j \rangle} \omega_j. \quad (19)$$

按下式概率选择 $\omega_i = k$:

$$\frac{e^{-E^k/T}}{e^{-E^0/kT} + e^{-E^1/kT}}.$$



图 4 应用吉布斯抽样对添加 $N(0, 1.5^2)$ 噪声的降质 200×200 双色图像进行图像复原.

最左边的图像是原始图像, 最右边的是复原后的图像

在图 4 中, 左图为原始的双色 200×200 图像. 中间的图像是添加 $N(0, 1.5^2)$ 噪声后的结果. 右边是应用吉布斯抽样之后的结果, 淬火程序由 $T_k = 3/\ln(1+k)$, $k = 1, 2, \dots, 300$

1) Geman 兄弟意识到模拟淬火法的想法与柯克帕特里克等人的工作是无关系的. (Stuart Geman, 个人通信).——原注

确定。在每一个淬火程序温度值上都对图像进行一次完全的光栅扫描。

尽管理论和实际收敛速率上存在着差异，吉布斯抽样已经到来。在一个严格的理论框架中，它的高效性以及易于实现的特点，极大地促进了 MCMC 方法被应用数学的其它领域，尤其是计算统计学所接受。

Geman 兄弟还考虑了同色毗邻区域间存在边界的模型。相对于“可观测”的像素，边界是“不可观测”量。这类模型之所以引起用贝叶斯方法的统计学家的兴趣，是因为它们都与分层模型有关，我们将在下一节深入讲解分层模型。

5. MCMC 方法进入统计学：盖尔范德和史密斯，1990 年

我们故事的最后一章发生在 1990 年，A·盖尔范德和 A·史密斯的论文“基于抽样方法计算边缘密度 (Sampling-Based Approaches to Calculating Marginal Densities)” [25] 的面世，预示着 MCMC 方法进入统计学。表面上看，盖尔范德和史密斯的目的是比较 3 种基于抽样的方法：吉布斯抽样，Tanner 和 Wong 的数据增广，¹⁾ 以及 Robin 的重要性抽样算法 (最初在 Tanner 和 Wong 工作的讨论中提出) [62]。即便早在 1970 年，黑斯廷斯就预见到米特罗波利斯算法是一种通用的抽样工具，但直到 20 年之后，才由盖尔范德和史密斯使统计学界认识到 MCMC 方法的强大。

5.1. 从吉布斯到盖尔范德

吉布斯抽样在统计学界中的出现可追溯到一个会议——皇家统计学会 1986 年会议。在会议中，Julian Besag 提出了题目为“脏图像的统计分析 (On the Statistical Analysis of Dirty Pictures)” [4] 的论文，在这篇论文中他讨论了降质图像 (即脏图像) 重构的研究前沿的状况，而听众为顶尖统计学家，包括 Geman 兄弟在内的众多贝叶斯领域的领军人物。他不仅描述了贝叶斯抽样的优点，更包含了相对于其他图像重构技术的比较。有趣的是，当时 Besag 对吉布斯抽样的简洁有效赞不绝口，但却对其计算需求加以指责。

在密切跟随这篇论文的热烈讨论中，大家一致认为计算统计学的新时代即将到来。其中一个参与者说，“...作为统计学家，我们除了沿着 Geman 兄弟所开创的有巨大计算能力的道路上前进外，别无选择” [4]。Stuart Geman 曾针对吉布斯抽样的通用性做过一个特别生动的评论，不禁使人想起米特罗波利斯等人早期所做的关于他们最初算法潜在的通用性的评论。

我们可以使用一个单独的计算机程序就可应对任何新的问题，仅仅通过改变计算后验分布的吉布斯表示中能量函数这一子程序。 [4]

与此同时，个人计算机变得普遍了，作用于计算速度与存储能力的 Moore (摩尔) 定律²⁾ 的影响也明显了。Besag 对于吉布斯抽样计算需求的担忧也将会被一扫而光。

在 1986 年会议之外，盖尔范德和史密斯很快就注意到了 Geman 兄弟的工作。他们

1) Tanner 和 Wong 的工作对于吉布斯抽样进入统计学界也起了重要的作用。在 [62] 中，他们将吉布斯抽样作为数据增广的一种方法，但是却未发现其在生成任意概率分布抽样方法中的潜力。——原注

2) 摩尔定律是由 Intel 创始人之一的 Gordon Moore 于 1965 年在《Electronics Magazine》上提出的。其内容为：当价格不变时，集成电路上可容纳的晶体管数目约每隔 12 个月 (1975 年，摩尔将其改为 18 个月) 便会增加一倍，性能也将提升一倍。——校注

发现吉布斯抽样可以“映射”到统计模型中多种常见的概率分布模型，尤其是那些从贝叶斯方式导出的分布。他们的工作基本上重现了 Geman 兄弟的吉布斯抽样，只不过没有淬火步骤。而他们文章的重要性则在于清晰地论证了吉布斯抽样作为一种统计学方法的高效性。

盖尔范德和史密斯吉布斯抽样的统计学版本可以描述如下。我们考虑联合概率分布 $f(x_1, x_2, \dots, x_N)$ ，其中每一个变量都代表统计模型中的一个参数。我们的目的是获取这些参数的（点和区间）估计。

为了套用吉布斯抽样框架，假定所有单变量条件概率密度

$$f(x_i | x_j, j \neq i)$$

都是可用的，即，这些密度属于可通过标准的算法获得抽样的类型。可用的概率分布包括均匀分布，正态分布， Γ 分布，Poisson（泊松）分布，以及任意一种有限分布。按 Geman 兄弟的观点，这些都是吉布斯分布，最多可能存在较大的局部近邻。为了生成一个抽样序列，任意选择 $\bar{x}^0 = (x_1^0, x_2^0, \dots, x_N^0)$ ，然后按如下步骤生成 $\bar{x}^1 = (x_1^1, x_2^1, \dots, x_N^1)$ ：

从 $f(x_1 | x_2^0, x_3^0, \dots, x_N^0)$ 生成抽样 x_1^1 。

从 $f(x_2 | x_1^1, x_3^0, x_4^0, \dots, x_N^0)$ 生成抽样 x_2^1 。

从 $f(x_3 | x_1^1, x_2^1, x_4^0, x_5^0, \dots, x_N^0)$ 生成抽样 x_3^1 。

$\vdots$

最后，从 $f(x_N | x_1^1, x_2^1, \dots, x_{N-1}^1)$ 生成抽样 x_N^1 。

一个循环（对图像进行光栅扫描）生成新的 $\bar{x}^1$ 。重复这一过程 M 次可生成

$$\bar{x}^0, \bar{x}^1, \bar{x}^2, \dots, \bar{x}^M,$$

如通常一样，它近似于联合概率分布 $f(x_1, x_2, \dots, x_N)$ 的一个抽样。

用这些抽样，几乎可以分析任何概率分布的性质。例如，针对每个 $\bar{x}^k$ 的第一个分量，可生成第一个分量边缘概率分布的一个抽样：

$$x_1^0, x_1^1, x_1^2, \dots, x_1^M, \quad (20)$$

边缘概率分布可由下面的积分表示

$$f(x_1) = \int_{x_2} \cdots \int_{x_N} f(x_1, x_2, \dots, x_N) dx_N \cdots dx_2.$$

从这个角度，吉布斯抽样也可当作多维数值积分算法。第一个分量 x_1 的期望值

$$E[x_1] = \int_{x_1} x_1 f(x_1) dx_1,$$

可由抽样 (20) 的平均来估计。从抽样中可直接获得关于 x_1 的 95% 的置信区间。

盖尔范德和史密斯在 [25] 以及它的直接的后续文 [24] 中，将吉布斯抽样应用到了丰富多样的统计模型中。这些模型中大多为贝叶斯分层模型，与 Geman 兄弟考虑边界加权的图像模型在结构上类似。

一个简单的三级层模型使用贝叶斯规则将数据 X , 一个待估计的参数 λ , 以及一个额外的超参数 β 结合在一起. λ 和 β 都可为向量.

- 第 1 级, X 由其似然函数 $f(X|\lambda)$ 描述, 即, 在条件 λ 下观测到数据 X 的概率.
- 第 2 级, λ 由条件加在参数 β 上的概率密度函数 $g(\lambda|\beta)$ 建模.
- 第 3 级, 超参数 β 由另一个密度函数 $h(\beta)$ 建模. $h(\beta)$ 的选择取决于建模者对于 β 可能取值的先验置信度.

这 3 个密度函数由贝叶斯规则所关联, 生成在数据 X 条件下 λ 与 β 的概率密度函数:

$$F(\lambda, \beta | X) \propto f(X|\lambda)g(\lambda|\beta)h(\beta). \quad (21)$$

其中比例常数是下式的倒数

$$\int_{\lambda} \int_{\beta} f(X|\lambda)g(\lambda|\beta)h(\beta) d\beta d\lambda, \quad (22)$$

它与参数 λ 和 β 无关, 但依赖于数据 X . 积分 (或和, 在离散分布情形) 是对所有 λ 与 β 进行的. 大多数情况下 (22) 不可能被估值. 回忆一下到现在为止所看到的, 我们可以简单地忽略这个貌似吓人的表达式并不令人吃惊.

分层贝叶斯模型早在 1990 年前就为统计学家所知. 他们自然地描述了数据, 可观测参数, 以及其它一些不可观测参数 (或称做潜变量) 之间的微妙联系. 它们的作用被它们在解析上难以驾驭所限制. 即使分层模型准确地表述了数据与参量之间的相互作用, 但若想获得诸如点估计或区间估计这类重要量的解析表达, 如果并非不可能的话, 也是极其困难的. 盖尔范德和史密斯指出大多这类分层模型可以很好归结为一种适当的贝叶斯抽样的形式.

为了观察贝叶斯抽样的实际应用, 我们考虑一种水泵故障率模型, 该模型最早由 Gaver 和 O'Muircheartaigh [23] 所描述, 盖尔范德和史密斯在 [25] 中使用了它. 数据 X , 由成对的 (s_i, t_i) , $i = 1, 2, \dots, 10$ 给出. 每一对都代表对某一水泵的故障信息. 对于每一个水泵, 假定时间 t_i 内的故障次数 s_i 服从泊松 $(\lambda_i t_i)$ 分布, 即,

$$f_i(s_i | \lambda_i) = \frac{(\lambda_i t_i)^{s_i} e^{-\lambda_i t_i}}{s_i!}, \quad i = 1, 2, \dots, 10.$$

假定故障的发生是相互独立的, 乘积给出了 $\vec{\lambda} = (\lambda_1, \lambda_2, \dots, \lambda_{10})$ 的似然函数:

$$f(X | \vec{\lambda}) = \prod_{i=1}^{10} \frac{(\lambda_i t_i)^{s_i} e^{-\lambda_i t_i}}{s_i!}.$$

传统的“频率”方法是用 $\bar{\lambda}_i = s_i/t_i$ 作为 λ_i , $i = 1, 2, \dots, 10$ 的点估计. 而贝叶斯方法则是假定所有 λ_i 都由一个共同的分布联系起来. 在此情形的一个自然的选择, 也是盖尔范德和史密斯所使用的, 是包含参量 α, β 的 Γ 分布, 因此对于第 i 个参数的密度是

$$g_i(\lambda_i | \alpha, \beta) = \frac{\lambda_i^{\alpha-1} e^{-\lambda_i/\beta}}{\beta^{\alpha} \Gamma(\alpha)}, \quad i = 1, 2, \dots, 10.$$

盖尔范德和史密斯从使用矩方法的数据估计“形状”参数 α , 而将 β 当作超参数.

$g_i(\lambda_i | \alpha, \beta) (i = 1, 2, \dots, 10)$ 的乘积给出分层模型中第 2 级密度:

$$g(\vec{\lambda} | \beta) = \prod_{i=1}^{10} \frac{\lambda_i^{\alpha-1} e^{-\lambda_i/\beta}}{\beta^\alpha \Gamma(\alpha)}.$$

而余下的超参数 β 由含参数 γ, δ 的逆 Γ 分布表示, 因而

$$h(\beta) = \frac{\delta^\gamma e^{-\delta/\beta}}{\beta^{\gamma+1} \Gamma(\gamma)}.$$

参数 γ, δ 的选择应保证顶层逆 Γ 分布合理扩散.¹⁾

对于参数 $\lambda_1, \lambda_2, \dots, \lambda_{10}$ 及缩放参数 β 所得到的后验联合密度 (21) 为²⁾

$$F(\lambda_1, \dots, \lambda_{10}, \beta | X) \propto \left[\prod_{i=1}^{10} \frac{(\lambda_i t_i)^{s_i} e^{-\lambda_i t_i}}{s_i!} \right] \left[\prod_{i=1}^{10} \frac{\lambda_i^{\alpha-1} e^{-\lambda_i/\beta}}{\beta^\alpha \Gamma(\alpha)} \right] \left[\frac{\delta^\gamma e^{-\delta/\beta}}{\beta^{\gamma+1} \Gamma(\gamma)} \right]. \quad (23)$$

这个看似复杂的联合密度具备应用吉布斯抽样的必要结构. 对 $i = 1, 2, \dots, 10$, 在条件加于其它参数上的情形, λ_i 的密度正比于

$$\lambda_i^{s_i + \alpha - 1} e^{-\lambda_i(t_i + 1/\beta)}. \quad (24)$$

比例常数可通过消去所有与 λ_i 无关的因子得到. (24) 的形式表明 $\text{Prob}(\lambda_i | \lambda_j, j \neq i, X, \beta)$ 是一个参数为 $s_i + \alpha$ ³⁾ 和 $1/(t_i + 1/\beta)$ 的 Γ 分布. 由于 Γ 分布属于可用分布, 因此在这一步可以应用吉布斯抽样.

对于条件加在其它参数上的情形, β 的密度正比于

$$\frac{e^{(\sum_{i=1}^{10} \lambda_i + \delta)/\beta}}{\beta^{10\alpha + \gamma + 1}},$$

说明 $\text{Prob}(\beta | \lambda_1, \dots, \lambda_{10}, X)$ 是一个参数为 $\gamma + 10\alpha$ 和 $\sum_{i=1}^{10} \lambda_i + \delta$ 的逆 Γ 分布. 同样, 这也是一个可用分布.

盖尔范德和史密斯将吉布斯抽样用于水泵模型的后验概率分布上, 获得了关于所有 $\lambda_i (i = 1, 2, \dots, 10)$ 和 β 的边界后验分布. 结果令人印象深刻: 经过相对而言极少的几步迭代, 后验抽样重现了以往需要其它更为复杂的积分方法才能获得的结果.

应用吉布斯抽样于水泵模型的一些结果见图 5. 直方图显示的是对于参数 $\lambda_2 (s_2 = 1, t_2 = 15.72, \bar{\lambda}_2 = s_2/t_2 = 0.0636)$ 与 $\lambda_8 (s_8 = 1, t_8 = 1.048, \bar{\lambda}_8 =$




图 5 盖尔范德和史密斯的水泵模型中参数 λ_2 和 λ_8 抽样的直方图. 对这些抽样, 均值的估计与 95% 的置信区间可以很容易地得到. 对 λ_2 估计均值为 0.1541, 95% 置信区间为 (0.0294, 0.3762), 对 λ_8 这些特征量分别为 0.8246 与 (0.1459, 2.1453)

- 1) 扩散分布试图尽可能少地传递参数的先验信息. 在极端情形, 一个分布可能是“无信息量的”. 此类分布的一个常见的例子是参数空间的一致分布.——原注
- 2) 原文式 (23) 中右端第 1 个中括号分子中 $(\lambda_i t_i)$ 缺少指数 s_i .——译注
右端第 3 个中括号分母中 β 的指数原文误为 $\delta + 1$.——校注
- 3) 原文误为 $s_i + \alpha - 1$.——译注

$s_8/t_8 = 0.9542$) 的抽样. 对这些抽样我们可以估计均值与 95% 置信区间. 对 λ_2 均值的估计为 0.1541, 95% 置信区间为 (0.0294, 0.3762), 对 λ_8 这些特征量分别为 0.8246 与 (0.1459, 2.1453).

水泵模型是 共轭 分层模型的一个例子, 即, 其中间分布 (在例子中诸 λ_i 和 β 的分布) 与分层模型中的原始分布相似. 所有分布都是可用的这一点满足吉布斯抽样的要求. 贝叶斯学派已确定了众多共轭模型, 所有这些都适于吉布斯抽样.

盖尔范德和史密斯也将吉布斯抽样 (也包括另外两种他们研究的算法) 应用于其他情形, 包括多元正态模型, 方差分量模型, 以及正态均值模型. 他们的结论为吉布斯抽样进入计算统计学 “注入活力”.

[这些算法]... 在多个常见的实际情形中直接地实现了, 因而避免了复杂的数值或者解析近似运算 (这些通常需要仔细地关注重新参数化 (reparametrization) 以及其它需要对逐个情形分别考虑的技巧). 就因为这个原因 —— 如果没有别的原因的话, 这些算法也值得去更好地理解, 并且将其应用到更广泛的问题上去. [25]

盖尔范德和史密斯认为吉布斯抽样以及 Tanner 和 Wong 的数据增广优于 Rubin 的重要性抽样算法. 因为有证据表明数据增广可能在计算上效率更高, 他们并没有认定吉布斯抽样在整体上是最佳的. 对吉布斯抽样的有效性, 他们后续的论文给出了强得多的结论.

在先前的文章中, 我们讨论了这些基于抽样方法的计算有效性的注意事项, 但是我们进一步的研究表明, 由吉布斯抽样所得出的适应的, 迭代的抽样方法 (Geman and Geman, 1984), 对于大多数问题, 实际上出人意料地有效, 且收敛迅速. [24]

在接下来的几年, 这一 “出人意料地有效” 的算法由于计算机能力瞩目的进展而更高效.

吉布斯抽样的一个重要影响是将贝叶斯方法引入主流统计学. 最后, 它能够处理优雅, 但是在解析上难驾驭的贝叶斯后验分布. 盖尔范德和史密斯 (以及其他) 展示了大多数贝叶斯分层模型都极好地适用于吉布斯抽样框架. 即便条件概率密度不可用, 该算法也可以工作. 在这些情况下, 统计学家很快就发现更为通用的米特罗波利斯 – 黑斯廷斯算法工作得好极了. 很快 MCMC 方法就被统计学家应用在了更多更为重要的问题上.

5.2. 盖尔范德和史密斯之后统计学中的 MCMC 方法

很难公平地评判 1990 年以来吉布斯抽样与 MCMC 方法在统计学中所做工作的广度, 深度和质量. 一个好的起点是 The Journal of the Royal Statistical Society, Series B 55 No.1, 1993 中 Smith and Roberts [59], Besag and Green [5], Gilks et al. [29] 的 3 篇系列讨论论文. 这些文章试图总结盖尔范德和史密斯的论文之后短短时间内吉布斯抽样对统计学界的影响.

在研发应用与拓展理论的同时, 出现了大量论文, 侧重于简单地解释这个 “新” 理论. 值得注意的早期阐释吉布斯抽样的论文有盖尔范德和史密斯的文章 “轻松的贝叶斯统计学: 一个抽样 – 重抽样方法 (Bayesian Statistics Without Tears: A Sampling-Resampling Approach)” [26] 与 Casella 和 George 的 “解释吉布斯抽样 (Explaining the Gibbs Sampler)”

[8]. 有关米特罗波利斯 – 黑斯廷斯算法非常精彩的概述是 Greenberg 和 Chib 的“了解米特罗波利斯 – 黑斯廷斯算法 (Understanding the Metropolis-Hastings Algorithm)” [10], 其中包含了米特罗波利斯 – 黑斯廷斯的算法与理论部分的极佳讨论. 对于米特罗波利斯 – 黑斯廷斯算法更为一般的, 可能有些独特的概述, 是 Diaconis 和 Saloff-Coste 的“关于米特罗波利斯算法我们知道些什么? (What Do We Know About the Metropolis Algorithm?)” [17]. 对于那些有兴趣对统计学中的 MCMC 方法进行深入了解的人来说, 所有这些论文都包含着充足的文献.

1990 年代也见证了有关 MCMC 方法与贝叶斯统计学的一些书籍的面世. 其中最好的早期综述之一是《实践中的马尔可夫链蒙特卡洛方法 (Markov Chain Monte Carlo Methods in Practice)》[30], 由 Gilks 等人编辑, 书中包含着大量 MCMC 方法在诸如分层建模, 图像分析, 纵向建模 (longitudinal modeling), 遗传学, 以及考古学这些领域中问题的应用实例, 其中也附带着一些相关理论问题的讨论. 一本比较新的书是 Casella 和 George 的《蒙特卡洛统计方法 (Monte Carlo Statistical Methods)》[54]. Tanner 的《统计推断的工具 (Tools for Statistical Inference)》[61] 在介绍与应用 MCMC 方法 (也包括期望最大化和数据增广) 方面的表现是极佳的. 对于包括 MCMC 方法的贝叶斯方法的综述, 可参见 Gelman 等人的《贝叶斯数据分析 (Bayesian Data Analysis)》[27] 与 Carlin 和 Louis 的《数据分析的贝叶斯和经验贝叶斯方法 (Bayes and Empirical Bayes Methods for Data Analysis)》[7].

6. 尾声

1990 年代中期以来, MCMC 方法几乎出现在自然与社会科学的每一领域, 同时也引起了数学家, 尤其是统计学家的极大兴趣. MCMC 方法创造性的应用常常出现在计算机科学, 生物学 (尤其是遗传学), 化学, 物理学, 心理学, 神经科学, 和经济学, 政治学, 社会学, 以及几乎所有人们可以想象到的所有领域中.¹⁾ 甚至也有在纯数学中的应用 —— 例如, 从对称群中抽样 —— MCMC 方法很有效.

随着应用的暴涨, 也在理解 MCMC 方法的收敛性上取得了理论上的进步. 对于统计学界理解收敛性具有最早影响力的文章是 Tierney 于 1994 年发表的论文“探索后验分布的马尔可夫链 (Markov Chains for Exploring Posterior Distributions)” [63]. 在文中, 他对 MCMC 方法, 也包括吉布斯抽样, 米特罗波利斯 – 黑斯廷斯算法以及其它一些混合方法 (某些步骤用吉布斯抽样, 另一些步骤使用米特罗波利斯 – 黑斯廷斯算法), 提供了强有力的理论框架. Tierney 讨论了方方面面的诸多问题, 包括米特罗波利斯 – 黑斯廷斯算法中不同类型的请求转移的影响. 他同时证明了有关链的遍历本质的一些强的结果, 尤其是一些有助于算法实践者确定马尔可夫链运行长度的结果. 几乎是在同时, Rosenthal [56] 提出了一种方法 (称作 弱化法), 它给出了为了保证满意的收敛性所需要的迭代次数的明确的先验多项式界.

在计算机科学领域对理解 MCMC 方法的收敛特性做了许多工作. 值得注意的是 Jer-

1) 用 google 对 MCMC “area of interest” 进行简单检索, 无疑都会返回数以百计的结果. —— 原注

rum 和 Sinclair 对于米特罗波利斯算法应用于伊辛模型 [39], 包括 [37] 以及矩阵的积和式 [40] 的混合次数给出了多项式时间界的结果. 他们于 1996 年获得了计算机科学领域的 Gödel (哥德尔) 奖, 他们工作的奠基性本质也因此得到认可.

Diaconis [16] 针对米特罗波利斯算法在不同设定下的收敛性的研究现状, 结合自己的研究工作与他人的工作, 提供了最新的综述. 例如, Diaconis 将最初的硬壳上的米特罗波利斯算法推广到高维 Lipschitz (利普希茨) 域. 在这个情形, 对于一个域 $\Omega \subset \mathbb{R}^d$ 上的目标分布 $p(x) = \bar{p}(x)/Z$, 米特罗波利斯算法定义了一个转移核 $P(x, dy)$, 它在 $L^2(p)$ 空间上是一有界自伴算子. 对于最大步长 h , 他指出

$$\left| P_x^k(A) - \int_A p(y) dy \right| \leq c_1 e^{c_2 k h^2}$$

对 $x \in \Omega$ 以及 $A \subset \Omega$ 是一致的. 常数 c_1 由显式给出.

尽管出现了这类理论结果, MCMC 方法的许多应用并没有给出收敛时间的先验估计. 在统计学中, 例如, 重点是收敛性的判断, 即, 一些有助于确定一个特别的 MCMC 方法生成的序列是否足够接近目的分布的方法. 通常, 这些判断是建立对不同的初始条件运行算法多次, 然后检验对于各次运行其输出是否一致这种想法上的. 有关这些方法的更多信息, 可参见 Cowles 和 Carlin 有关 MCMC 判断的综述性文章 [12].

在统计学之外的应用中 (有很多), 对收敛性的认识就更少见了. 正如 Diaconis 提到: 我相信随便从科学中选定任一领域, 从硬科学到社会科学, 都会发现为这一领域专门定制的越来越多的 MCMC 文献. 我注意到这些应用都基本上没有附带任何形式的实际有用的运行时间分析. [16]

7. 结论

现在是结束马尔可夫链蒙特卡洛方法的演变过程的适当时候了. 对于这个算法, 难免会变得诗意起来. 它像数学中任何知识那样接近于普适. 它既优雅且有效. 它来自新墨西哥的沙漠中, 因一群人, 一个问题, 一台机器的幸运交汇而诞生. 它随着计算机的进展而不断成长, 对于数学和自然科学产生了巨大的影响. 对于它为什么有效以及提前预测需要多长时间才有效仍存在疑问. 即便如此, 它的确有效而且相当有效. 在观测了模拟淬火法应用于流动推销员问题的有效性之后, 可能正如 Čerňý 所说.

在先前描述的例子中, 我们简单的算法如此有效有些出人意料. 可以认为这是由于我们的算法模拟了大自然寻求复杂系统平衡的作为, 而大自然总能把自己的工作做得极其有效. [9]

致谢、参考文献 (略)

(刘本源 译 陆柱家 校)