

MMDS 2008: 现代大规模数据集分析中的算法和统计方面的挑战

Michael W. Mahoney Lek-Heng Lim Gunnar E. Carlsson

于 2008 年 6 月 25—28 日在斯坦福大学举行的现代海量数据集的算法研讨会 (MMDS¹⁾ 2008) 有两个目标: 首先是探索海量、高维和结构非线性的科学和互联网数据集的建模和分析的新方法, 其次是把计算机科学家、统计学家、数学家和数据分析的实际工作者邀请到一起以促进集思广益的交叉交流. 研讨会是由美国科学基金会 (NSF)、美国国防先进研究项目局 (DARPA²⁾)、雅虎 (Yahoo!) 和 LinkedIn³⁾ 资助的.

MMDS 2008 源自我们对如下看法的讨论: 即从现在开始的一代对大规模、复杂数据集的算法、数学和统计的分析应该是什么样子的讨论. 这些讨论是紧随 MMDS 2006⁴⁾ 之后进行的, 讨论得到了数值线性代数和理论计算机科学界带来的在现代信息学应用中对组合、数值和随机化算法方面的补充观点的启发 (参见 www.siam.org/news/news.php?id=1019). 和 2006 的会议一样, MMDS 2008 的活动安排具有强烈的跨学科性质, 有近 300 名与会者表明会议内容覆盖了现代大规模数据分析研究中的广大领域.

1. 现代数据问题的不同处理方法

通常的方法是用相互作用的图模型 $G = (V, E)$ 对大规模社交或信息网络进行建模, 这时顶点集 V 中的结点表示“实体”而边集 E 中的边 (无论是有向或无向的, 加权的或不加权的) 表示一对实体之间的“相互作用”. 另外, 因为 $m \times n$ 实值矩阵 A 为 m 个对象, 每个对象都有 n 个特征来描述的编码信息提供了一种自然的结构, 这些和其他的数据集都可以用矩阵来建模. 由于数据集规模大、极端稀疏以及复杂且常常是抗噪声的性质, 现代信息学应用中出现的数据图和数据矩阵, 为跨学科研究提供了大量的挑战和机会. 研究算法、统计和数学的挑战就是 MMDS 2008 的重点.

译自: SIAM News, Vol.42 (2009), No.1, No.2, MMDS 2008: Algorithmic and Statistical Challenges in Modern Large-Scale Data Analysis, Part I and Part II, Michael W. Mahoney, Lek-Heng Lim, and Gunnar E. Carlsson. Copyright ©2009 Society for Industrial and Applied Mathematics. Reprinted with permission. All rights reserved. 美国工业和应用数学学会与作者授予译文出版许可.

1) Modern Massive Data Sets 缩写为 MMDS.——译注

2) Defense Advanced Research Projects Agency.——译注

3) LinkedIn 是一家面向商业客户的社交网络 (SNS) 服务网站, 成立于 2002 年 12 月并于 2003 年启动, 总部在美国加州山景城 (Mountain View). 网站的目的是让注册用户维护他们在商业交往中认识并信任的联系人, 俗称“人脉 (Connections)”. 用户可以邀请他认识的人成为“关系 (Connections)”圈的人. 截至 2010 年第 4 季度, LinkedIn 已经在全球 200 多个国家有横跨数百个产业, 超过 8500 万的个人注册用户及超过 500 个企业用户, 公司于 2011 年 5 月 20 日在美国上市.——译注

4) MMDS 2006 于 2006 年 6 月 21—24 日在斯坦福大学和雅虎研究院举行.——译注

从历史上看, 处理此类问题有很不相同的观点. 对数据挖掘和知识发现有兴趣的计算机科学家通常把数据库中的数据看成是在特定环境下发生的每件事情的叙述或记录. 数据库可以包括一个月里所有客户的交易, 或是社交网站成员之间所有的友谊链接. 对于这种观点, 目标是要列表和处理数据来找到有趣的模式、规则和关联. 关联规则的一个例子就是著名的故事所说的“晚上 5—7 点买啤酒的人同时也买尿片”.¹⁾ 这种规则的性能或质量是通过数据库的确切满足该规则的那部分数据来判定的, 于是问题就归结为寻找经常发生的这样的事件集. 这是一个计算上很困难的问题, 许多算法研究工作专门从事在不同的数据存取模型下该问题的精确解和近似解.

在统计学家中更为普遍的很不相同的观点是把数据处理的问题看作是描述隐藏在数据中没有观察到的模式的基础过程的特定的随机例证. 这时, 其目标就是要从观察到的带噪声或不确定的数据在抽取所研究问题的信息. 为此, 可以假设模型为 $data \sim F_\theta$ 和 $\text{mean}(data) = g(\theta)$, 其中 F_θ 是描述数据的不确定性模型 $g(\theta)$ 周围数据的随机可变性的分布. 利用这个模型, 研究者可以分析数据作出有关基础过程和未来观察结果的预测的推断. 这种观点认为, 对有噪声的分量或可变性的建模与对平均结构的建模是同样重要的, 这在很大程度上是因为要了解所做出的预测的质量, 了解前者是必要的. 这种方法甚至允许作出以前没有观察到的事件的预测——例如, 给出特定用户在特定的网站上在一天的特定时刻点击所提供的特定广告的概率是可能的, 即便这个特定事件在数据库中并不存在.

当然, 有很多迹象表明这两种观点并非不相容的: 在研发矩阵问题改进的近似算法的最近的许多努力中统计和概率的思想和概念是主要的; 当对网络的参与者做了一些假设时, 另外一些难于解决的图和网络优化问题就让位给近似算法来解决了; 机器学习中心许多最新的研究工作从这两个领域吸取思想和概念; 适用于用类似的梯度下降方法使目标函数极小的加性模型²⁾的一种统计方法——提高方法 (boosting)³⁾ 中, 计算参数, 即迭代次数也可以作为一种正则化参数.

考虑到可能存在的观点的多样性, MMDs 2008 围绕 6 个一小时的辅导课程向与会者大致介绍了研讨会主要论题; 本文简要概述了每个辅导课程的内容.

2. 大规模信息学: 问题、方法和模型

卡耐基梅隆大学的 Christos Faloutsos 通过阐述自然地提出各种图的广泛应用领域, 开讲了题为“图挖掘方法: 规则、生成子和工具”的辅导课程. 他指出, 来自现代信息学应用的大规模图所具有的结构性质非常不同于传统的 Erdős-Rényi 随机图; 一个例子就是由于精细的相关性造成的度分布、本征值分布和其他统计量的重尾性态 (heavy-tailed behavior).

1) 实际上说明了关联规则要解决的常见问题如: “如果一个消费者购买了产品 A, 那么他有多大机会购买产品 B?” 以及 “如果他购买了产品 C 和 D, 那么他还将购买什么产品?” 正如大多数数据挖掘技术一样, 关联规则的任务在于减少潜在的大量杂乱无章的数据, 使之成为少量的易于观察理解的静态资料.——译注

2) additive model (AM), 是统计学中的一种非参数回归方法.——译注

3) Boosting 是一种提高任意给定学习算法准确度的方法.——译注

这些结构性质近年来一直得到广泛研究并已用来研制许多广受关注的模型;Faloutsos 还阐述了现有模型不能很好重现的从经验中观察到的性质. 例如, 多数模型预测图应该随时间变得越来越稀疏而其直径应该如 $O(\log N)$ 或 $O(\log \log N)$ 那样增大, 其中 N 是当前时间步长处的结点数; 尽管, 从经验上看, 人们观察到这些网络中的许多网络图随时间变得稠密且缩小其直径. 为解释这些现象, Faloutsos 阐述了一个基于 Kronecker (克罗内克) 积的模型和另一个模型, 其中边经由一种迭代的“森林火灾”机制增加着. 适当选择参数, 两个模型都能重现比先前的生成模型要广得多的静态和动态性质.

建立了这种建模基础, Faloutsos 还阐述了当前人们感兴趣的若干图挖掘应用: 寻找在一群个体中处于中心地位的结点的方法; 为识别时间演化图中反常模式的奇异值分解和最近研究出来的张量方法的使用; 对网志世界 (blogosphere)¹⁾ 中的信息瀑布 (information cascades) 作为病毒的传播来建模; 以及欺诈侦测的新方法.

在网络规模的数据分析中的其他进展是 Edward Chang 的题为“挖掘大规模社交网络: 挑战和可扩展的解法”的辅导课程的主题. 在评论了当我们从 Web 1.0 (网页和文件之间的链接) 向 Web 2.0 (文件、人和社交平台之间的链接) 转移时产生的诸如社交网络分析和个性化信息的检索方面形成的应用后, 谷歌研究院的 Chang 详细讲了 4 方面的应用——网络分析的谱集群 (spectral clustering)、常见消息集 (frequent-item set) 的挖掘、组合合作滤波 (combinatorial collaborative filtering) 和个性化搜索的并行支持向量机 (parallel support vector machines (SVMs)). 在所有这 4 方面, 他都强调主要的性能要求是“可扩展性 (scalability)、可扩展性、可扩展性”.

像网络搜索那样的现代信息学应用提供了容易并行化的可能性——例如, 总体指标 (overall index) 可以用以下方式分割, 即甚至单个的询问也可以使用多个处理器. 而且, 机器的峰值性能比之于价格-性能比就不那么重要了. 在这种环境中, 扩展到 petabyte 字节²⁾ 大小的数据规模意味着要在像 MapReduce 或 Hadoop 那样的能支持在几百、几千甚至几十万商用计算机族上运行数据密集分布计算的软件架构中工作. 这与科学计算中感兴趣的传统应用中产生的可扩展性问题很不相同. 在 Chang 的讲演中反复出现的论题是, 浮点运算成本昂贵但易于并行化的算法常常是比不那么昂贵但是不能并行化的算法更好的一种选择.

作为例子, Chang 讨论了 SVMs 问题: 尽管它们得到广泛的使用, 这主要是因为它们的成功经验和吸引人的理论基础, 但它们在存储使用和计算时间两方面都受到众所周知的可扩展性问题的困扰. Chang 描述了一种能处理这些困扰问题的并行化 SVM 算法, 该算法通过执行以行为基础的不完全 Cholesky 因子分解 (incomplete Cholesky factorization (ICF)) 及只在每台并行计算机上下载必不可少的数据来降低存储要求, 并通过聪明的重排计算步骤和在并行机上执行这些步骤来减少计算时间. 他指出, 传统的以列为基础的 ICF 在单台计算机的框架内运行时比较好, 但不适合于跨越许多计算机的并行化计算.

1) 也有人把 blogosphere 译为“新兴媒体生态圈”.——译注

2) 计算设备内存容量以多少字节 (B byte) 为计量单位. 1PB (Petabyte 拍字节) = 2^{50} 字节, 相当于 50% 的全美学术研究图书馆藏书信息内容.——译注

3. 网络化数据的算法步骤途径

在有关改进的数据模型的算法观点和前景的讲演中, 佐治亚工学院的 Milena Mihail 首先通过描述幂律随机图, 即在特定的输入幂律度分布下得到随机控制的图方面的丰富理论的最新发展. 然而, 随着现在可利用的大规模社交和信息网络范围的日益扩大, 需要结构上或句法上更灵活的生成模型已经成为不可避免的了. Mihail 描述了两种这样的推广: 在第一种生成模型中, 结点处的语义是用特征向量来建模的, 同时基于结点间的语义靠近程度来增加节点间的边, 而在另一种生成模型中, 关联性 / 非关联性是通过固定给定度为 d_i 有连接到度为 d_j 的趋势的概率来建模的.

生成模型的参数小的扩张当然有可能导致生成图所观察到的性质的巨大增长. 这种观察提出了一个模型过度拟合的有趣的统计学问题, 以及模型参数化的更为精细和系统方法方面的争论. 这也导致了 Mihail 报告的论题中的新算法问题.

对基本的幂律随机图模型 Mihail 提出了下列算法问题: 给定作为输入的 N 维向量规定了一个度序列, 是否能确定具有这种度序列的图是存在的, 如果确实存在, 那么就有效地生成一个这样的图 (或许是从这些图组装而成的近似一致随机的图). 在图论和理论计算机科学中这种可实现性问题有很长的历史. 因为他们的解与图匹配的理论密切相关, 这个基本问题的许多推广可以在严格的理论框架内进行处理. 例如, 受关联 / 非关联网络的启发, Mihail 描述了联合度矩阵实现问题的新进展: 给定一种结点集的具有相同度的顶点类的分划, 规定每类的度的向量以及任何两类之间边数的矩阵后, 是否能确定这样的图是存在的, 如果确实存在, 那么就构造一个这样的图. 她还描述了把这种基本问题延伸到连通图的推广, 求极小化成本的实现以及求满足这些基本约束的随机图.

4. 几何的观点: 数据的定性分析

斯坦福大学的 Gunnar Carlsson 就数据分析的几何和拓扑方法给了一个综述, 这是一种通过把几何加进数据来寻求能对数据提供洞察的方法. 在某些诸如物理学那样的应用中, 所研究的现象支持能确切地表明要用什么样的度量来量度数据点对之间距离的清晰的解释理论. 大多数 MMDS 应用不属于这种情形. 例如在高通量微阵列实验中 DNA 表达谱之间欧氏距离能抓获了基因间距离的有意义的概念这件事不是显然的. 类似地, 尽管有与任何图相关联的自然的测地距离, 但是社交和信息网络的稀疏性和噪声性质意味着在实践中测地距离不是一种特别稳健的距离概念.

因此部分问题是要定义有用的度量 —— 特别是因为在包括集群、分类和回归在内的一些应用中常敏感地依赖于度量的选择. 最近出现了两种设计目标. 第 1 个目标是不要相信大距离; 因为距离常常是从相似性测量中构造出来的, 小距离可靠地表示相似性, 但是大距离几乎没有意义. 第 2 个目标是只相信小距离一点点 —— 毕竟相似性测量仍然是很带噪声的. 这些概念是基于 Laplace (拉普拉斯) 算子的非线性降维的许多研究工作的基础, 即当前流行于调和分析和机器学习中的基于流形的方法. 更一般地, 这些概念启发了对于基础度量的伸张和收缩时稳健的分析工具的设计, 特别是在像可视化那样的应用中, 感兴趣的是数据是怎样大规模地组织起来的定性的性质.

Carlsson 的辅导课程的很多部分专门讲述这些分析工具以及在自然图像统计学和数据可视化中的应用. 拓扑性质的最粗略的量度——同调——把这些信息记录为数据中连通分量或存在各种大小的洞的数目. 重要的是, 尽管一般拓扑空间的同调计算是不可行的, 但是它常常可以用单纯复形来建模, 这时同调计算归结为某些依赖数据的矩阵的 Smith 正则形式的线性代数计算.

Carlsson 还描述了这个基本概念的一种推广, 持久同调 (persistent homology), 其中诸如最近的邻居和误差参数的数目那样的某些参数是可以变化的. 于是“条码签名 (barcode signature)”就可以和数据集关联起来. 条码中的长字节段表明在参数值很大的范围内持续的同调类的存在. 这常常可以解释为与数据中的大规模几何特征相应的表征; 比较短的字节段可以解释为噪声.

5. 统计和机器学习的观点

给定一个对象属性的一组测量值 $\mathbf{x} = (x_1, x_2, \dots, x_n)$, 基本的预测或机器学习问题就是要预测或估计其他属性的未知的值 y . 量 y 是“输出”或“响应”变量, 而 $\{x_1, x_2, \dots, x_n\}$ 都是“输入”或“预测”变量. 在回归问题中, y 是实数; 在分类问题中, y 是 (诸如类标签那样的) 离散的不可排序的范畴值 (unordered categorical values) 集的数目. 在每种情形中, 这都可以看作是一个函数估计的问题, 预测的函数形式为 $\hat{y} = F(\mathbf{x})$, 它把预测变量所有的连接值空间中一个点 $\mathbf{x}$ 映射到响应变量空间中一个点 $\hat{y}$, 而目标是产生一个 $F(\cdot)$ 使一种损失准则最小.

斯坦福大学的 Jerome Friedman 开讲题为“快速稀疏回归和分类”, 他指出通常假定一个线性模型, 其中 $F(\mathbf{x}) = \sum_{j=1}^n a_j x_j$ 作为 n 个基函数的线性组合的模型. 但是, 损失函数的经验估计显示很大的方差, 除非观察数远大于 n . 为使估计更正规, 人们通常考虑下面的约束优化问题或惩罚优化问题

$$\hat{\mathbf{a}}(\lambda) = \operatorname{argmin}_{\mathbf{a}} \hat{L}(\mathbf{a}) + \lambda P_{\gamma}(\mathbf{a}),$$

其中 $\hat{L}(\cdot)$ 是经验损失, 而 $P_{\gamma}(\cdot)$ 是惩罚项. 正则化参数 λ 的适当值的选取是一种经典模型选择问题, 对此可以采用交叉确认的方法. 惩罚项的选择有赖于对手头的问题知道什么或要假定什么. 通常的选择是 $P_{\gamma}(\mathbf{a}) = \|\mathbf{a}\|_{\gamma}^{\gamma} = \sum_{j=1}^n |a_j|^{\gamma}$. 这是在子集选择问题 ($\gamma = 0$) 和岭回归 ($\gamma = 2$) 之间做了插值, 而且包含得到很好研究的套索 (lasso) ($\gamma = 1$). 对于 ($\gamma \leq 1$) 的情形, 得到稀疏解 (感兴趣的是其极度节俭和可解释性), 而对于 ($\gamma \geq 1$), 惩罚是凸的.

尽管经由交叉确认来选择最优的 (λ, γ) 是可能的, 但是由于要在很大数量的离散对处执行计算的需求, 即使当损失和惩罚是凸的情形, 其费用也可能高得负担不起. 对这种情形, 人们研究了路径-搜索方法 (Path-seeking methods). 考虑最优解 $\{\hat{\mathbf{a}}(\lambda): 0 \leq \lambda \leq \infty\}$ 的路径, 在参数空间 $\mathbb{R}^n$ 中它是一条一维曲线. 如果损失函数是二次函数而惩罚函数是分段线性的, 就像套索的情形, 那么最优解的路径是分段线性的, 而且同调方法可以用来生成整个路径, 在时间上并不比在单个参数值处拟合单个模型所需要的时间多多少. Friedman 对更广泛的损失和惩罚函数 (包括某些非凸函数) 非常有效地解决这个问题的

推广的路径 – 搜索方法.

在题为“对足够降维情形的基于核的对照函数”的辅导课程中, 加州大学伯克利分校的 Michael Jordan 考虑了在有监督指导的学习框架中的降维问题. 诸如主成分分析、Johnson-Lindenstrauss 方法以及最近发展起来的基于拉普拉斯算子的非线性方法都经常被使用, 但是在可应用性方面有局限性——举例说, 两类间的最大判别轴不能很好地与最大方差轴保持一致. 希望在于存在能有效地找到的输入空间 X 的低维子空间 S , 而且保持 X 和响应空间 Y 之间的统计关系. 处理这种足够降维问题的传统方法要对相关变量 X 和 / 或响应 Y 的分布加上很强的建模假设. Jordan 考虑了一种半参数的表述; 非参数化地处理条件分布 $p(Y|X)$ 且目标是要估计 S , 他解释说这个问题可以根据条件独立性形成公式化表述, 并根据在再生核 Hilbert (希尔伯特) 空间 (reproducing kernel Hilbert spaces (RKHSs)) 上的算子来进行计算.

当考虑两个随机变量的变换时, 有关两个随机变量的独立性的断言可以划归为它们之间相关性的断言: 即, 对于一类适当丰富的函数空间 $\mathcal{H}$, X_1 和 X_2 是独立的, 当且仅当

$$\max_{h_1, h_2 \in \mathcal{H}} \text{Corr}(h_1(X_1), h_2(X_2)) = 0.$$

如果 $\mathcal{H}$ 是 L_2 , 因此包含 Fourier (傅里叶) 基, 于是问题就化归关于特征函数的众所周知的事实. 从计算的观点看更有趣的事——考虑到由于“再生”性质, 在一个 RKHS 中的函数计算化归为一种内积——对于适当丰富的 RKHSs 这也成立. 用 RKHS 的思想来解决足够降维问题不能看作是基础线性算法的核化, 因为当采用这种思想 (例如, 用支持向量机) 时, 这个案例通常提供回归和分类的基展开. 宁可说, 这是一个例子, 说明 RKHS 的思想怎样能够对范围更为广泛的感兴趣的统计函数的优化提供算法有效的方法.

6. 结论和未来的方向

除了辅导课程中讲到的论题, 与会者还听到了各种各样范围广泛的数据应用: 电影和产品建议 (movie and product recommendations)、快速网络搜索的预测索引 (predictive indexing for fast Web search)、在生物分子折叠中的通道分析 (pathway analysis in biomolecular folding)、功能磁共振成像 (functional MRI)、高分辨率的地形分析 (high-resolution terrain analysis)、星系的分类 (galaxy classification), 以及在计算几何、计算机图形学、计算机视觉以及多方面的学习 (manifold learning) 中的其他应用. 我们听说了为探究大规模社交和信息网络的社区结构的近似算法的新用法, 这种新用法是作为测试如下断言的一种途径, 该断言说这些数据甚至是和流形假设相容的 (他们显然是不相容的). 在所有这些情形中, 可扩展性是主要问题——启发了有关外部存储算法、像 MapReduce 那样的新的计算范式以及交流——有效的线性代数算法的讨论. 有兴趣的读者可以访问会议的网站 <http://mmds.stanford.edu>.

我们收到的反馈清楚表明 MMDS 已经引起了跨学科的强烈共鸣. 就未来的 MMDS 研讨会的思考而言, 几乎每个我们与之交谈的统计学家都希望有更多的统计学家与会; 几乎每个科学计算的研究人员希望有更多的数据 – 密集的科学计算的内容. (下转 22 页)