

社交网络数据分析中的 数学概念、方法及其应用

Desmond J. Higham Peter Grindrod Ernesto Estrada

在迅速发展的网络科学领域中的许多关键思想可以追溯到 20 世纪 50 和 60 年代,那时研究人员开始细化社会相互作用的研究. 数学的语言和工具,特别是图论和线性代数提供了很自然的研究框架,很快数学家就把社交网络分析作为一种切实可行的应用领域. 到了 1984 年,社会科学家林顿·弗里曼 (Linton Freeman) 在 [7] 中指出“有一整批各种类型真正能够提供高度驱动力的数学问题游走在社交网络领域中.”

我们把时间快速推移到 2008 年;这时弗里曼在 [8] 中断言:“当概念和工具从一个领域向另一个领域转移时,这种转移通常是从自然科学转向社会科学. 但是,近年来出现一种反方向的重要转移趋势. 中心性的概念及其度量工具原先是从社交网络分析的社会科学领域发展起来的. 然而眼下中心性的概念和工具正广泛地应用于物理学和生物学.”

为了一个链接一个链接地建立网络,社会科学家在社会科学领域中已经苦心收集了数据 (参见,例如在网站 <http://vlado.fmf.uni-lj.si/pub/networks/data/ucinet/ucidata.htm> 的 UCINET IV¹⁾ 中收集的数据集), 实验技术和计算能力的进展打开了研究和可视化自然界和技术中大规模网络的可能性. 瓦茨 (Watts) 和斯托加茨 (Strogatz) 具有里程碑意义的小世界文章 [17] 引起了社会科学界以外人们对网络科学的关注;根据弗里曼在 [8] 中所说的,“在 1998 到 2003 的 5 年里物理学家就小世界这个主题发表的出版物比社会网络界的人们在过去 45 年发表的数量还要多.”

网络正在任何地方不断地“被发现”,并被从社会科学中研制出来的工具进行分析. 链接可以表示,例如,学术上的共同作者、好莱坞共同主演的角色、万维网的超链接、互联网的连接、语言的相似性、电子电路、在线共同采购、食物网的连接、物理的蛋白质相互作用、协调的基因表达、代谢调节、氨基酸残基相似性、运输通道、电力电缆、共有街道的交汇点. 在 [4] 中可以找到许多例子的深入讨论.




图 1 一个简单的友谊网络

译自: SIAM News, Vol.44 (2011), No.1, No.2, People Who Read this Article Also Read ...: Part I and Part II, Desmond J. Higham, Peter Grindrod, and Ernesto Estrada, figure number 4. Copyright ©2011 Society for Industrial and Applied Mathematics. Reprinted with permission. All rights reserved. 美国工业和应用数学会与作者授予译文出版许可.

- 1) UCINET 是目前最流行的一种社会网络分析软件,具有强大的可视化功能. 它由加州大学欧文 (Irvine) 分校的网络分析者编写. 对该软件进行扩展的团队由斯蒂芬·博加提 (Stephen Borgatti)、马丁·埃弗里特 (Martin · Everett) 和林顿·弗里曼 (Linton Freeman) 等组成.——译注

一开始是为了识别各种类型的人类社交相互作用网络中的重要角色而发展出来的中心性概念 [8] 现在已经在几乎每个可以想到的网络场景得到广泛的应用。考虑图 1 所示的简单网络, 其中每个无向边记录了一对个人之间的友谊。谁是组织“带一瓶酒和几个朋友”派对的最佳人选? 谁是能够最有效地发出一条流言蜚语的人? 谁最有可能听到最新的流言蜚语? 我们可以通过对每个结点指派一

框 A: 中心性测度

用 k_i 表示的结点 i 的中心性度, 就是简单的结点的度——关联边的个数。

用 d_{ij} 表示的结点 i 和 j 之间的距离, 就是连接它们的最短路径的长度。¹⁾

用 s_i 表示的结点 i 的距离和, 定义为 $s_i = \sum_{j=1}^N d_{ij}$ 。

用 CC_i 表示的结点 i 的中心性靠近度 (closeness centrality), 是距离和的规范化倒数 $CC_i = (N - 1)/s_i$ 。

用 BC_i 表示的结点 i 的中心性中间度 (betweenness centrality) 的公式为

$$BC_i = \sum_{r \neq s \neq i} \frac{\rho_{rs}(i)}{\rho_{rs}},$$

其中 ρ_{rs} 是连接结点 r 和 s 的最短路径的总个数, 而 $\rho_{rs}(i)$ 是通过 i 的这种最短路径的个数。

一个中心性测度来处理这类问题。在框 A 中确切定义了某些基于路径的测度。更为全面的讨论可以在, 例如, [13, 16] 中找到。粗略地说:

- 中心性度 只是简单地记录了每个结点的度 (关联边的个数)。对于“带着你的朋友来”的这些事件来说, 高度数的结点好的。
- 中心性靠近度 记录了网络中一个结点和所有其他结点间最短路径长度的和的倒数。中心性靠近度分值高的结点是开始传播流言的聪明的起点。
- 中心性中间度 记录了与最短路径关联的一个结点的习性。中心性中间度分值高的结点更可能获悉最新的流言。

表 1 展示了图 1 中简单网络的计算结果。我们看到尽管 Bob 的中心性度最高, 但是 Sue 具有最高的中心性靠近度和中心性中间度。直观上看这是合理的, 因为 Sue 似乎占据着网络中更为中心的位置。类似地, 从中心性度和中间度的排序而言 Alf 在 Bob 之后, 就中间度而言跃至非常清楚的第 2 位; 其他结

表 1 图 1 中所示网络的中心性测度

结点 i	中心性度 k_i	中心性靠近度 CC_i	中心性中间度 BC_i
Joe	3	0.4375	0.5
Mary	2	0.4118	0
Ramona	3	0.5385	2.0
Bob	4	0.5833	6.5
Sue	3	0.6364	12.0
Alf	3	0.5385	10.0
Oscar	2	0.3889	0
Jens	2	0.3889	0

点为了形成到 Oscar 或到 Jens 的路径, 除了经过 Alf 外别无选择。

这些中心性的测度都是基于结点对之间的最短路径的概念。考虑通过网络的更一般的道路就导致一种更为宽松的观点。正如 Borgatti [3] 中讨论的, 依赖于所考虑过程的类型, 那么考虑以下的概念是合适的:

1) 有边连接的相邻两点之间的距离都为 1。——译注

- 迹 (*Trails*), 沿这样一条路的行进过程中可以重复通过结点, 但是不能重复使用边. 例如, 在图 1 中的 Mary-Bob-Sue-Ramona-Bob-Joe 就是一条迹, 但它不是一条路径. 流言蜚语通常就是沿一条迹传播的. Bob 可能既从 Mary 也从 Ramona 那里听到这个流言蜚语. 但是, 如果 Bob 确实是从 Mary 那里听到这个流言蜚语, 那么他和 Mary 不大可能互相重复传播这个流言蜚语.
- 游动 (*Walks*), 沿这样一条路的行进过程中可以多次通过结点和边. 例如, 在图 1 中的 Mary-Bob-Sue-Ramona-Bob-Mary-Joe 就是一条游动, 但不是迹或路径. 一张美元纸币可以在人-人网络沿游动流通. Mary 可以在一次交易中把这张纸币给 Bob, 而 Bob 也可以在另一次交易中把这张纸币给了 Mary.

从线性代数的观点看, 游动的情景是有吸引力的. 假定一个无向网络具有邻接矩阵 A , 其中 $a_{ij} = 1$ 若结点 i 和 j 是连接的, 否则 $a_{ij} = 0$. 那么恒等式

$$(A^n)_{ij} = \sum_{k_1=1}^n \sum_{k_2=1}^n \cdots \sum_{k_{n-1}=1}^n a_{i,k_1} a_{k_1,k_2} \cdots a_{k_{n-1},j}$$

表明 $(A^n)_{ij}$ 计算了从结点 i 到结点 j 的长度为 n 的游动的总数. 为用单个的数来综合表示这个信息, 我们可以对所有的游动长度取加权和. J. Katz 极有影响的 1953 年的文章 [11, 13]¹⁾ 建议长度为 n 的游动数可以用一个因子 a^n 来调整其度量尺度标度, 其中 $0 < a < 1$ 是某个适当选择的参数. 于是我们就可以通过把 i 和 j 之间游动的加权总数对 j 求和来构成结点 i 的一种靠近度式的中心性得分. 利用展开式 $(I + aA)^{-1} = I + aA + a^2 A^2 + a^3 A^3 + \cdots$, 我们得到了结点 i 的中心性得分

$$\sum_{j \neq i} ((I + aA)^{-1})_{ij}.$$

直观上看, 对在所有长度的游动综合, 而不是全用或全不用最短路径的传统做法, 将使这些度量对虚假或缺失的信息不那么敏感. 在大多数数据集中这种类型的不确定性是固有的. 例如, 在“谁给谁发电子邮件”的情形, 由于忽略了其他的交流形式, 或许会出现错误的否定; 当, 例如说, 经理的电子邮件被个人助理严重过滤时, 也可能出现错误的肯定 (误报).

在框 B 中我们展示了利用 [5] 中的一般方法可以怎样构成基于游动的中心性度量.

后面我们将讨论社交网络分析的最近的繁荣, 这种繁荣正由企业和政府为探索我们的数字式行为中的泄密指纹的愿望所驱动. 我们也将说明这些数据的动态性质, 例如, 伴随着电子邮件和手机通讯中的时间戳对应用数学家带来的有极大吸引力的挑战.

曾被人们强迫沿着 Linton Freeman 的单向路 [8] 的错误方式用于自然科学和工程科学的网络科学中的想法和概念经历了快速回归到人类社交相互作用领域的弯路. 对于高端、高消费用户当前感兴趣的许多最重要且令人兴奋的数据集关心的是我们的行为: 发电子邮件、打手机、发短信、卫星定位、网上社交、网上消费、电影租赁 确实, 最

1) [11] L. Katz, A new index derived from sociometric data analysis, *Psychometrika*, 18 (1953), 39-43. [13] M. E. J. Newman, *Networks: An Introduction*, Oxford University Press, Oxford, UK, 2010. 有可能 [13] 中提及了 [11].——译注

框 B: 基于游动的中心性

假定我们有一个适当的非负实数序列 $\{c_n\}_{n \geq 1}$, 其中 c_n 是我们意欲用来计算长度为 n 的游动的数目的尺度因子. 把 Maclaurin 级数 $\sum_{n \geq 1} c_n x^n$ 定义为函数 $f(x)$, 我们就可以经由邻接矩阵 A 定义如下的度量; 更多的细节可参阅 [5].

结点 i 的 f -中心性由 $f(A)_{ii}$ 给出.

结点 i 和 j 之间的 f -可交流性由 $f(A)_{ij}$ 给出.

结点 i 的 f -中间度由

$$\frac{1}{(N-1)^2 - (N-1)} \sum_{p \neq q, p \neq i, q \neq i} \sum_{p \neq q, p \neq i, q \neq i} \frac{f(A)_{pq} - f(A - E(i))_{pq}}{f(A)_{pq}}$$

给出, 其中矩阵 $E(i)$ 只在 i 行和 i 列的值不为零, 而 $E(i)$ 在 i 行和 i 列的值为 1, 如果 A 在 i 行和 i 列的取值为 1. (因此 $A - E(i)$ 就是把与结点 i 相连的全部边移去时产生的该网络的邻接矩阵.)

[6] 引进并研究了特殊情形 $c_n = 1/n!$, 而与 $f(x) = e^x$ 相应的 f -中心性称为 Estrada¹⁾指数.

近的年度网络科学会议 (美国波士顿, 2010.05.10—14) 充斥着从挤满脸谱网站中得到的网络 (数据) 的分析. 政府想知道可疑的行为. 企业想知道目标应该对准谁又要把谁摺在一边, 应开发什么样的产品, 要规划什么样的基础结构, 要部署什么样的收费系统. 社交网络分析已经成为巨大的高科技的产业, 它涉及到数学家、物理学家、计算机科学家, 当然还有社会科学家. 《经济学家》[15] 最近的一篇文章对以下事情做了量化:

“这种软件的市场正在激增. 据一种估计, 有 100 多个网络分析项目成为连接分析或预测分析的研究课题在执行. 所用到的未经加工的原始数据远远超出电话记录, 它们包括来自私人 and 政府部门以及诸如脸谱网站的互联网资源等可利用的信息. IBM 透露的信息表明 ..., 其这种软件的年销售量现在正以两位数的速率增长, 在 2015 年将超过 150 亿美元. 在过去的 5 年里, IBM 花了 110 多亿美元来购买网络分析软件制作者的产品.”

总部设在伦敦的 Market Sentinel 有限公司首席执行官 Mark Rogers, 他专长于语义搜索和社交网络分析, 告诉我们:

“大客户品牌的挑战就是要去了解被弄成许多语义和社交的 ‘语境’ 碎片那样的媒体景观. 语境可以是 ‘和我一起上大学的人’ 或 ‘也喜欢我的竞争对手的产品的 Justin Bieber²⁾ 的粉丝’. 品牌具有非常大的用户集群, 他们想要了解、有权使用、也可以推举这些品牌.”

“这种洞察极不寻常: 例如, 通过使用 Skyttle³⁾ 来看看在社交网络推特 (Twitter) 上共同发生的 # 号标签 (如果我使用了一个特定的标签, 我还打算用另外的标签吗?), 我们就能确定写微博者说他们是多么地爱他们的猫的人, 也可能写有关抑郁症的微博. 品牌可利用像推特那样的工具所导出的从产品设计到交流语言的所有事情中得到的理解.”

美国国家卫生研究院对社交网络分析这个领域也采取了非常严肃的态度, 在 2010 年就启动了名为 “社交网络分析和健康” 的项目, 其观点是 “鼓励能够产生推进社交网络分

1) Ernesto Estrada, 本文的第 3 作者, 古巴和西班牙科学家 (双重国籍), 对数学化学的发展做出贡献. — 译注

2) Justin Bieber, 1994.03.01—, 加拿大人, 是当今欧美乐坛流行音乐王子. — 译注

3) Skyttle 是 Market Sentinel 有限公司下属的一个回答问题的平台. — 译注

析的新理论；处理社交网络和健康之间的关系中的基本问题；以及能够推动和扩大社交网络分析的方法学和技术上的创新等方面的基础研究。”

总部在 Palo Alto¹⁾ 的 Palantir Technologies (一家数据挖掘和可视化公司——译注) 提供能够分析有结构的、无结构的、相互有关系的、随时间变化的以及具有地理空间数据的软件，该公司是有一些曾在 PayPal 公司²⁾ 工作过的人和斯坦福大学的计算机科学家于 2004 年创建的。没有市场部门或销售团队的该公司雇用了 250 多位工程师和科学家，并已经获得了来自美国联邦调查局和中央情报局的反恐分析合同。该公司也注目于数据的安全性和欺诈的预防；例如，美国政府的修复问责制和透明度董事会 (Recovery Accountability and Transparency Board) 就利用 Palantir 政府平台经由网络和公民共享信息以及侦测滥用的经济刺激计划基金。

当然，对世界的那种基于网络的观点，其描述也是非常笼统的。一方面是有关收集和存储数据的实际可行性和伦理道德的忧虑，就像在报告 [2] 中前陆军上校的反对意见所声称的，在伊拉克反恐目的所需要的详尽网络数据导致当地无辜百姓的羁押。另一方面，即使能存取所有相关的数据，就像任何数学建模方法一样，网络的观点也只能表示实际复杂系统的一种简化了的草图。当我们的问题变得更具探究性时，缩减结点和边的设置的好处——提供干净的数据结构、现成的算法和清楚的形象化——开始被由于过分简化所丢失的信息所抵消。即使考虑了有向或加权的边，也不能应对下面的基本问题：“结点”和“相互作用”不可能全都同等对待。

加拿大安大略省皇后大学 (Queen's University) 的计算机科学家 David Skillicorn 在他的博客 (<http://skillicorn.wordpress.com/>) 中，在引述了由“试图让人和他们老板的老板交朋友”所导致的“尴尬的失礼”后提到，可能需要区别对待由工作派生出来的连接和休闲派生的连接。作为例子，他写道：

“假定你已经进入到某些人的电子邮件并想计算出谁是他们的朋友以及谁和他们有专业接触。电子邮件地址的结构没有多少帮助，因为可能是用了朋友的工作电邮，也因为电子邮件地址往往是代理人的地址。一天在发送电子邮件的时间也不会有多大帮助，因为有许多人在工作时间发送私人电子邮件，又有许多人在下班时间发送工作电子邮件。电子邮件的内容可能有所帮助，但是很多机构都有广泛的内部非工作邮件 (例如，Enron (安然) 公司³⁾ 有许多仅在公司内部流通的有关幻想橄榄球的电子邮件)。”

那么网络科学传统的工具只能是部分解决问题的工具。确实如此，Palantir Technologies 的网站把这一点说得很清楚，即安全地整合成份复杂的数据集是一个重大的挑战：

“在试图赋予分析者能力的过程中我们要处理的可能是最主要的难题就是数据建模，

1) Palo Alto, 位于美国加州旧金山湾区南部的圣克拉拉县 (Saint Clara) 境内门罗帕克市 (Menlo Park) 与芒廷维尤市 (Mountain View) 中间。——译注

2) PayPal 公司成立于 1998 年 12 月，是美国 eBay 公司的全资子公司。PayPal 公司利用现有的银行系统和信用卡系统，通过先进的网络技术和网络安全防范技术，在全球 190 个国家为超过 1.5 亿个人以及网上商户提供安全便利的网上支付服务。——译注

3) 安然公司成立于 1930 年，总部设在美国休斯敦。在 2001 年宣告破产之前，安然拥有约 21000 名雇员，曾是世界上最大的电力、天然气以及电讯公司之一。——译注

即找出什么样的数据类型是与某个领域相关的、定义在该领域它们表示什么以及如何在该系统中表示它们的过程。”

对于这些从电信和在线社交网络中正在出现的数据集来说，网络科学范式的一个显然的局限性似乎表明数学化的时机已经成熟：网络间的相互作用不是静态，通常是随时间演化的——“谁和谁打电话”，“谁给谁发电子邮件”，“谁在脸谱网站上和谁交朋友”的信息都是内在动态的。这个问题是在 2010 年 8 月 SAMSI (Statistical and Applied Mathematical Sciences Institute)¹⁾ 的复杂网络活动安排的开班研讨会上提出来的。杜克大学的社会学家 James Moody 指出，如果 A 在上午碰到 B，而 B 在下午碰到 C，那么 A 可以感染 C，但 C 并不感染 A。然而，综合每天接触的网络将包括链 A-B-C，从而在这个水平上强加于通常的易感-感染-康复类的模型，这很可能高估了疾病的传播速率。类似地，考虑诸如图 2 展示的简单的“谁给谁打电话”的情景，图中展示了相邻 3 天的 3 个网络。我们看到 Mary 可以通过第一天的链接 Mary-Bob-Ramona-Sue-Alf 和第 2 天的链接 Alf-Oscar 给 Oscar 传递信息，但是 Oscar 在这 3 天里肯定没有办法给 Mary 传递信息。即使每个单个的网络是无向的也会出现这种非对称性。挪威电信公司 Telenor 的资深研究员 Kenth Engø-Monsen 告诉我们，掌握了时间依赖性，就有可能给出一个关键的市场营销优势：




图 2 一种简单的动态变化的相互作用网络

“什么是网络化的世界里的市场营销？这全都与结点和链接有关！在传播你的新服务或新产品时，什么是更好的结点？在什么样的链接上这种传播最有可能实现？挑战在于识别能够加速扩大传播正确的结点和链接的集合。当今电信公司使用的最新的网络分析技术构建是基于客户间 X 周或 Y 月平均化的信息流量数据的。我认为考虑客户网络的动态性质是以网络为基础的市场营销技术中要考虑的下一个有前途的事情。”

在公共领域得到广泛研究的时变相互作用数据集列举了 151 位安然公司雇员的电子邮件活动；参见 <http://www.cs.cmu.edu/~enron/>。为了产生图 3，我们首先综合在相邻的 1138 天里包括“发给”、“抄送”、“密送”在内的电子邮件相互作用。这就导致了一个 1138 个大小为 151×151 的对称邻接矩阵组成的序列，也可以把它们看作一个大小为 $1138 \times 151 \times 151$ 的张量。图 3 展示了每天的总边数。(图 3 中，纵坐标为链接的总数，横坐标为天数。——编注) 在图 4 中，为易于说明，我们把前 1080 天按照以 30 天为一个月的 12 块来考虑，

1) 统计和应用数学科学研究所 (SAMSI) 是创建于 2002 年的由杜克大学、北卡罗来纳州立大学 (NCSU)、教堂山北卡罗来纳大学 (UNC)、国家统计科学研究院 (NISS) 和 William Kenan, Jr. (1872.04.30—1965.07.28) 工程、技术和科学研究院合作建立的伙伴关系共同体。它是美国国家科学基金会 (NSF) 数学科学部的数学科学研究所项目的一部分。——译注

并展示了月邻接矩阵.

采用 [10] 中的记号, 对于给定的结点集, 与有序时间点序列 $t_0 \leq t_1 \leq \dots \leq t_M$, 我们可以对 $k = 0, 1, \dots, M$ 考虑一个对称、二进制邻接矩阵的有序序列 $A^{[k]}$. 继续沿用图 2 中网络的有关例子, 从结点 i_1 到结点 i_{w+1} 的长度为 w 的动态游动可以定义为边序列 $i_1 \leftrightarrow i_2, i_2 \leftrightarrow i_3, \dots, i_w \leftrightarrow i_{w+1}$ 和非减时间序列 $t_{r_1} \leq t_{r_2} \leq \dots \leq t_{r_w}$, 使得 $(A^{[r_m]})_{i_m, i_{m+1}} \neq 0$.

然而, 这种时变情况提供了非常丰富的不同的选择. 在某些情况下, 每个时间点最多只允许使用一条边可能是合适的, 这时对时间序列的约束应该是严格的不等号: $t_{r_1} < t_{r_2} < \dots < t_{r_w}$. 例如, 在一个正式的晚会舞会上, 每一支舞曲, 你有找一个舞伴或坐在那里不去跳舞的选择. 另一种情况, 每个时间点强迫使用正好一条边, 使得 $r_{n+1} = r_n + 1$ 可能是合适的. 例如, 假定学校每天都要让学生把宠物仓鼠带回家: 昨天的幸运学生把它带回家后, 今天交给他 (她) 现在的朋友带回家.

类似地, 我们可以定义动态路径和动态迹. 在定义动态路径时, 我们坚持访问结点不能多于一次——最近在 [14] 中研究出来这个概念, 并用来构造动态中心性度量. [12] 中讨论了在时变网络中发现连接良好的社区的问题. 我们还要指出, 超大的“时间”跨度会把我们带进张量领域, 在该领域数据挖掘是当前一个热门论题 [1]. [10] 中的动态游动的概念是通过以下观察得到的: 矩阵积 $A^{[r_1]}A^{[r_2]} \dots A^{[r_w]}$ 中的元素 i, j 算得的是从结点 i 到结点 j 的长度为 w 的动态游动的数目, 其中第 m 步游动发生在时刻 t_{r_m} . 由此得出矩阵积

$$(I - aA^{[0]})^{-1}(I - aA^{[1]})^{-1} \dots (I - aA^{[M]})^{-1} \quad (1)$$

执行了收集全部动态游动的工作: 它的元素 i, j 给出了从 i 到 j 的动态游动的总数, 其中长度为 w 的游动的度量因子为 a^w . 这就自然导致中心性的度量. 而且, 即使每个预解式 $(I - aA^{[r]})^{-1}$ 是对称的, 但是预解式的总乘积一般不是对称的, 这反映了出现在时间箭头方向的固有的非交换性. 图示在图 3 和图 4 中的安然公司的数据, 其中包括最佳播出者和接收者的信息在内的结果可以在 [10] 中找到.

为强调: 对于特定的应用这些概念必须要调整好, 我们指出, 就像在每天的电子邮件通信的情形那样, 在许多情形 $A^{[k]}$ 本身就是在在一个时间窗口上的活动的总数. 假定我们把时间窗口细化为小时、分钟、秒, $\dots$ 在某个阶段 (1) 中的积会停在一个固定值. 我们可以从以下事实直观地看到这一点, 由于每个时间周期上至多只有一个链接, 所以通




图 3 安然公司电子邮件数据中每天的链接总数




图 4 以 30 天为周期集成的安然公司电子邮件数据的演化邻接矩阵

过细化不可能创造出更多的游动. 我们还可以从 (1) 的线性代数的结构直接断言: 不会产生新的非恒同因子. 由于这种高样本率, 于是去论证一下结论是有吸引力的, 该结论说: (1) 应该由 “每个时间窗口至多一个链接” 的版本

$$(I + aA^{[0]})(I + aA^{[1]}) \cdots (I + aA^{[M]})$$

来替换, 因而就避免了像 $i \mapsto j \mapsto i$ 那样的简单、窗口内的闭游动. 但是, 就像数学金融学中的买卖差价一样, 这种 “高频率等于高精度” 的论证可能会被噪声击溃 —— 就我们的经验来说, 所讨论的电子邮件的发送次序并不和它们的到达次序匹配.

我们在本文中着重讨论了数据驱动的问题: 综合概括、排序和提取关键特征. 应用数学家也力求了解控制一个系统的机理并把它们表示为定量的预测模型. 在演化网络的情形, 什么是控制边的出现和消失的运动定律? [9] 提出了一些边动力学的基本随机模型并进行了分析, 还讨论了相关的问题: (a) 如何校准模型, 以及 (b) 如何分析发生在动态网络上的动态过程. 关于这种类型的演化数据, 存在一些非常自然、实时的问题. 考虑到网络过去的行为及其当前的状态:

- 网络是否正常运行?
- (诸如停电或计算机病毒的爆发那样的) 突发事件是否即将发生?
- 是否存在任何有可疑活动的小块区域?
- 网络中的哪些结点在当前最容易受到攻击?
- 现在是开始发出流言蜚语或接收最新流言蜚语的良好时机吗? 如果是这样, 你们找哪里?

我们是通过论证以下看法来开始本文 (SIAM News, 2011, January/February, p.1) 的, 即来自社交网络分析的定量研究领域的正在出现的概念和思想已经催生了和数学科学的有极大吸引力的双向互动. 有关我们多种行为模式的可利用数据的数量和种类的最近的激增已经转变成非常高调的追求, 增加了风险以及打开了许多新的挑战. 我们用来自 Market Sentinel 有限公司 Mark Rogers 的下列观点来结束本文, 他告诉我们:

“由于当前语义和社交搜索研发而将要出现的一些大工业正打算进入市场营销 / 通信领域. 传统的市场营销研究和产品 / 通信规划正在大规模地被替换. 当然, 市场营销只是以这种方式受到影响的一种行业, 对其他行业的影响也将随之而来.”

致谢, 参考文献 (略)

(叶其孝 译 吴庆宝 校)

(上接 88 页) 来自应用领域的实践者呼吁有更多的应用, 几乎所有的理论计算机科学家也表达了希望有更多的应用. 作为在计算机科学、统计学、应用数学以及科学和互联网数据应用的交界面处正在发展中的跨学科研究领域 MMDS 正在引起人们的兴趣.

敬请关注未来的 MMDS 研讨会!¹⁾

(叶其孝 译 吴庆宝 校)

1) 2012 年现代海量数据集的算法研讨会 (MMDS 2012) 将于 2012 年 6 月 15—18 日在斯坦福大学举行. 有兴趣的读者可以访问 www.stanford.edu/group/mmds.——译注