

无导数优化:没有免费午餐定理的真实含义

Loris Serafino

在工程和应用科学的许多领域中, 最重要的步骤之一是通过建模和使用优化技术提升产品或服务过程的质量与性能. 对于金融市场运作, 放射治疗技术, 蛋白质折叠的测定, 材料科学, 电力系统设施的设计以及很多其他领域, 这些完全不同的科技领域的进展也要依靠一些恬静而隐秘的帮手, 即优化方法的帮助. 除了似乎只是一些算法的机械式的应用外, 它还面临大量的挑战和发展机会. 文献中的术语“优化”(optimization) 通常指的是一类数学方法或算法 (及其输出结果), 它们通过对一个已知的变量集合进行操作, 在满足一系列约束的条件下计算任意一个目标函数的极值. 更严格地说, 针对一个显式目标函数的最大化问题可以一般地表示成如下数学形式:

$$\arg \max_{x \in \mathcal{H}} f(x),$$

其中 x 是一般的多维空间 $\mathcal{H}$ 的一个给定向量, $f: \mathcal{H} \rightarrow \mathbb{R}$ 是向量 x 的函数, $\mathcal{H} \subset \mathbb{R}^n$ 是多维实 Euclid (欧几里得) 空间的一个子集 (可以离散也可以连续, 但本文主要考虑连续情形). 以下我们将 $\mathcal{H}$ 称为 搜索空间 (search space).¹⁾ 在大多数现实世界的工程优化问题中, 没有解析表达式可以用来精确计算候选解的响应. 有时候, 目标函数只能通过计算仿真或实验中观察得到的输入-输出对的不同集合体现: $\mathcal{D} = \{(x_1, f(x_1)), \dots, (x_n, f(x_n))\}$. 我们这里所要考虑的正是这种 黑箱情形 (black-box scenario). 在黑箱优化中, 许多问题攸关成败. [2, 3, 4] 是这方面很好的综述文献. 此外, 工程设计及其他应用场景中的大量任务被建模成多目标问题; 这使得优化过程更为困难, 但本文将不考虑这种情形. 本文主要聚焦于以下问题: 没有免费午餐定理 (No Free Lunch Theorem, NFLT) 的实际含义及其与 Bayes (贝叶斯) 推理的自然联系. 这样选择的理由是基于以下事实: 它们都表达了优化理论与优化实践的至关重要的联系.

1. 黑箱优化

在黑箱优化中 元启发式算法 (metaheuristics) 占有统治地位. 元启发式算法描述了一种优化方法如何决定下一步要探索搜索空间的哪一部分的方式 [1]. 一般地, 每个元启发式算法可以抽象看成是在搜索空间上进行取样的过程. 它从一个取值集合开始, 然后基于当前样本和目标函数值, 一步步地按照指定的机制生成新的样本:

$$(x_1^{i+1}, \dots, x_m^{i+1}) = \text{Alg}(x_1^i, \dots, x_n^i, f(x_1^i), \dots, f(x_n^i), \Theta),$$

译自: Notices of the AMS, Vol. 61 (2014), No. 7, p. 750–755, Optimizing Without Derivatives: What Does the No Free Lunch Theorem Actually Say? Loris Serafino. Copyright ©2014 the Mathematical Association of America. Reprinted with permission. All rights reserved. 美国数学协会授予译文出版许可.

Loris Serafino 是科威特澳大利亚学院的数学讲师. 他的邮箱地址是 geoloris@gmail.com.

1) 虽然这里没有显式地提到约束条件, 这一模型仍然具有足够的一般性, 因为它们可以通过对搜索空间 $\mathcal{H}$ 进行合适的定义得以体现.——原注

这里 Θ 是一个随机变量, 而指标 i 是迭代计数器.

因此, 不同优化方法的差异在于算法用于生成和接受新样本的特定机制, 以及在这一过程中 (全局) 探索阶段与 (局部) 寻优阶段的轮替方式. 略举一例: 受自然启发的 (*nature-inspired*) 算法, 例如众所周知的遗传算法 [5], 是基于模仿某些自然现象的想法, 这些自然现象能够导致某些特定的量达到最大. 从随机生成的候选解 (通常的术语是染色体) 种群开始, 遗传算法 (GA) 基于适应值¹⁾ 执行选择和重组过程, 生成后继种群, 即生成下一代. 在重组过程中, 父代 (*parent*) 解被选中并且他们的遗传物质通过重组生成子代染色体. 在实际算法实施中, 在这一步骤之后执行变异操作. 变异操作对重组得到的解进行微小摄动, 对其直接相邻的邻居进行探索. 这些解随后进入后继种群. 随着这一过程的不断迭代, 后代序列不断进化, 染色体的平均适应值趋于增加, 直到满足某些停止准则. 通过这种方式, 遗传算法 “进化” 到一个给定问题的最好的解 (图 1). 在进化的过程中, 一个种群被另一个种群代替, 如此往复.




图 1 遗传算法: 一代代的种群收敛到一个好的解

遗传算法只是实际人员手中的工具之一. 其他例子包括: 粒子群, 蚁群, 模拟退火以及很多其他类型的算法 [6]. 一般来说, 实际经验表明, 这些方法的任何成功应用, 都依赖于依据实际问题的特点, 对具体操作过程、算法参数进行仔细调整.

有可能存在无穷多个可能的优化问题 —— 每个可能的目标函数都对应一个优化问题. 同时也存在无穷多种能想到的优化方法 —— 每种可能的全局探索和局部寻优组合都对应一种优化方法. 为一类给定的问题选择正确的元启发式算法是至关重要的, 这指引我们思考 NFLT 扮演的角色及其理论和实践的关联性.

2. 没有免费午餐定理 (NFLT) 的实际含义

我们从针对优化的 NFLT 的常用形式化表述开始 [9]. Wolpert 和 Macready 考虑一个有限的搜索空间 $\mathcal{X}$, 以及定义于该空间上的所有可能的目标函数 $f: \mathcal{X} \mapsto \mathcal{Y}$ 组成的空间, 记为 $\mathcal{F} = \mathcal{Y}^{\mathcal{X}}$. 他们定义 $P(y_k|f, k, Alg)$ 表示采用算法 Alg 对给定的目标函数 f 进行 k 次迭代后, 找到目标函数值 $y_k \in \mathcal{Y}$ 的条件概率. 这可以看成是算法的一种性能指标 —— 它在指定的迭代步数后, 找到一个给定的目标函数值的能力. 在一些很一般的条件下, 该定理指出, 对于任意一对算法 Alg_1 和 Alg_2 :

$$\sum_f P(y_k|f, k, Alg_1) = \sum_f P(y_k|f, k, Alg_2).$$

1) 在遗传算法的文献中, 目标函数值通常称为适应值. —— 原注

其中这里的求和是在所有可能的函数的集合 $\mathcal{F}$ 上进行的。

按照最通常的理解, NFLT 表明: 没有什么优化方法对所有可能的优化问题来说都优于其他方法. 对某些目标函数来说, 可能 Alg_1 能够比 Alg_2 更快地找到最大值; 但对其它目标函数来说, 可能正好相反. 对整个空间 $\mathcal{F}$ 进行平均, 性能就会是一样的. 等价地, 也可以这样说: 在整个空间 $\mathcal{F}$ 上, 没有什么算法会比纯粹的随机搜索表现得更好. Wolpert 和 Macready 采用的是概率论的框架, 如果我们假设目标函数在 $\mathcal{F}$ 上服从均匀分布, 即每种函数形式是等可能出现的, 他们的结论就成立, 并且他们针对 k 用归纳法对定理进行了证明. 为了理解这一定理对黑箱优化问题的实际含义, 让我们从另一个角度对它进行重新表述. 这个定理实质上是说:

如果对函数 $f: \mathcal{X} \mapsto \mathcal{Y}$ 没有任何先验知识, 即对每种函数形式等可能出现的情形, 那么目标函数在定义域的某些点上的取值所提供的信息, 就不能为该函数在定义域的其他区域上的取值提供任何信息.

NFLT 的这一解释如图 2 所示. 在这种情形下, 从样本数据中收集到的信息, 对于指导下一步探索找到好的搜索方向没有帮助. 从这个意义上讲, 没有什么优化方法对所有可能的优化问题来说都优于其他方法. 当然, 每个目标函数都有自己的结构; 问题在于当无法获得函数形式的先验知识时, 没有理论根据可以指导优化策略的选择, 即无法确定采用哪种优化方法以及相应的参数等.




图 2 NFLT 定理: 到目前为止所搜集到的信息不能为该函数在其它区域上的取值提供任何信息 (情形 A). 对于某些特定的函数子类, 如凸函数 (情形 B), 能够利用这种特殊结构的算法就会比其他算法表现得更好

从 NFLT 中必须认识到能够解决黑箱优化问题的合理优化策略的含义. 现在很清楚, 对于实际工作者来说, 真正的问题不是他必须使用哪种优化算法, 而首先是目标函数有什么几何特征: 这个优化问题就变成了一个推理问题, 这一点在下面的讨论中将会看得更加清晰. 如果知道目标函数图像的结构, (理论上) 就有可能对算法进行适当的调整, 在局部搜索和全局搜索之间进行权衡. 还有一点, 虽然有很多的研究正在进行, 但关于哪一类算法最适合于哪一类问题的一般性结论仍然太少. 正如我们下面将会看到的, Bayes 的概率论很可能是元启发式方法的自然的基础框架.

在 NFLT 假设的情形下, 手头问题的结构在文献中一无所知, 实际工作者倾向于根据他们掌握的背景知识, 实际可以得到的算法代码和仿真软件等决定优化方法. 如果情况不是这样, 即知道目标函数的一些知识, 例如关于函数值的下界或者函数响应面的一

些信息, 这些信息就应该相应地用来对算法和优化策略进行调整, 使之相适应. 目标函数结构的有关知识对于更好地权衡全局探索和局部寻优, 调整到有效的算法是关键所在.

概括一下: 从 NFLT 的讨论可知, 黑箱优化包含两个要素: 输入 - 输出数据和一些先验知识. 这自然地引导我们进入下一节, 探讨它与 Bayes 框架的联系.

3. NFLT 与 Bayes 哲理: 同一枚硬币的两面




图 3 欠定问题: 数据样本可以由很不同的模型来描述 (这里就是函数 A 和函数 B)

我们在黑箱优化情形下对 NFLT 的解释表明, 它与 欠定 (underdetermination) 问题有很强的联系 (图 3). 在黑箱情形下, 关于函数的响应面只有一个有限样本数据集: $\mathcal{D} = \{(x_1, f(x_1)), \dots, (x_n, f(x_n))\}$. 在这种情形下, 找到函数值 (最优值) 变成了一个纯粹的推理问题, 自然地落入 Bayes 框架中. 在优化情形下, Bayes 概率论的理论基础可以简要概述如下: 需要解决的问题是构造我们将要优化的函数的一个模型. 在 Bayes 框架下这包括两个要素: 数据集和先验知识. 函数空间上的先验分布 $P(f)$ 与似然值 $P(\mathcal{D}|f)$ 相结合, 可以生成后验分布

$$P(f|\mathcal{D}) \propto P(\mathcal{D}|f)P(f),$$

其中考虑了数据集 $\mathcal{D}$ 提供的信息. 在对函数建模时, 如果我们假定先验知识是每个函数等可能 (这等价于没有任何先验知识), 我们就正好处于 NFLT 假设的情形: 无法从数据集中提取到有用的推理信息. 如果先验知识可以把函数限定在一个真子类上, 那么利用数据集对模型进行推理就会更精确. 这正如我们所说到的 NFLT 的含义, 如果可以把问题限定在给定的函数子类, 选择一个适当的优化算法就能得到很好的结果. 对于给定的 $\mathcal{D}$, 一个优化方法能够指引在哪个区域更有希望找到最优值, 用 Bayes 的语言来讲, 等价于推理得到了目标函数的 (后验) 精炼模型. 现在就清楚了, NFLT 和 Bayes 框架有很强的联系, 它们可以被认为是同一枚硬币的两面, 表 1 对此进行了总结. NFLT 假定所有可能的目标函数均匀分布, 用 Bayes 的术语来讲, 这等价于没有关于目标函数的先验知识:

表 1 NFLT 与 Bayes 理论的对比

给定样本数据集 $\mathcal{D} = \{(x_1, f(x_1)), \dots, (x_n, f(x_n))\}$			
NFLT 的术语: 寻找最优		贝叶斯理论的术语: 生成模型	
$\mathcal{F}$ 上均匀分布	$\mathcal{F}$ 上非均匀分布	无先验知识	有先验知识
求解 $\arg \max f(x)$ 时, 不存在 Alg 优于纯粹的随机搜索	求解 $\arg \max f(x)$ 时, 存在 Alg 优于纯粹的随机搜索	不存在针对 $\mathcal{D}$ 的模型的有效推理	存在针对 $\mathcal{D}$ 的模型的有效推理

每种函数形式都是允许的. 按照 NFLT 的含义, 为了找到相适应的有效优化策略, 本质上要将可能的函数类型 (NFLT 的术语) 限制到一个真子类上. 这种对函数类型的限制代表了 Bayes 公式中的先验概率. 所以, 假定有很好的样本集 $\mathcal{D}$,¹⁾ 成功求解一个黑箱优化问题的秘诀在于对先验知识进行限定的可能性.

4. 几点蕴含

以上用 Bayes 方法解释 NFLT(反之亦然) 的讨论, 有两方面的用途: 一方面是用 NFLT 理解基于代理模型的优化技术, 另一方面是用 Bayes 框架理解元启发式方法的运行逻辑. 在黑箱优化情形下, 有大量文献讨论对目标函数进行近似的方法 (也称为元模型 (meta-models) 或代理模型 (surrogates)), 由此生成可以有效计算并很好地近似真实函数的函数模型. 它们都需要假设 (虽然经常是隐含的假设) 待建模的函数属于某个限定的子类的先验知识. 函数代理模型可以是真实问题的目标函数的代数表示. 最常用的是多项式, 在统计文献中这通常被称为响应曲面法 (response surface methodology). 目前, 一些相关的




图 4 Bayes 优化: 数据点以黑圆点表示. 用 Gauss 过程建模的分布的均值用过数据点的实线表示, 标准差用虚线表示. 表示下一个需要探索的点, 有望得到最大改进

方法也经常用于函数近似: 神经网络, Kriging 模型, 径向基函数网络和支持向量机 (更一般的参考文献见 [11, 12]). 模型建立起来以后, 就能够使用经典的基于导数的或者无导数的方法求解 [13]. 这里我们对 Bayes 优化进行了简要讨论, 它是优化实践中越来越实用的工具. 从概念上来看, 这一技术将代理模型的估计和寻找最优解结合起来 ([14, 15, 16] 对此提供了很好的介绍). 它首先使用 Bayes 理论推理出初始的函数模型. 接着根据当前的最优值以及预测方差, 在搜索空间中

有望获得最大改进的那些区域填充新的点 (图 4). 然后按 Bayes 原理进行更新. 在文献中, 先验知识通常假设是 Gauss (高斯) 过程 (GP) 的实现, 即目标函数在函数空间上的分布被建模成多变量 Gauss 分布, 因此可以认为 Gauss 过程定义了函数空间上的如下分布:

$$f(x) \sim \text{GP}(m(x), k(x_i, x_j)),$$

其含义是函数 f 的分布由均值函数为 $m(x)$, 协方差函数为 $k(x_i, x_j)$ 的 Gauss 过程决定. 协方差函数通常选择以下定义:

$$k(x_i, x_j) = \exp \left(-\frac{1}{2} (x_i - x_j)^T \text{diag}(\phi)^{-2} (x_i - x_j) \right),$$

这里 ϕ 表示一族超参数, 需要进行适当的估计.

以上概要介绍的 Bayes 优化理论的优点在于, 它求解优化问题时只需要少量的函数调用 (函数求值), 而这一点对于计算成本很高的仿真 (函数求值) 是极为重要的. 重复一遍: Bayes 理论的关键点在于先验知识的选择, 用 NFLT 的术语来讲, 就是 $\mathcal{F}$ 上的非均

1) 关于实验设计技术, 见 [11].——原注

匀分布. 选择 *Gauss* 过程 作为先验知识, 就意味着假设目标函数属于光滑, 良态的函数类; 这是一个很武断的假设. 对于不连续或跳跃的目标函数, 这样的先验知识将不会提供很好的结果. 此外, 构造代理模型本质上是设计空间的探索过程, 这与优化算法得到结果的方式完全一样. 如果搜索空间的维数很高 (超过 100 个变量), 那么在很有希望找到最优解的区域上取样的能力就会变得越来越差. Bayes 优化不能避免 维数灾 (*curse of dimensionality*): 候选解的数量随着维数指数增长 [7].

通过以上讨论, 现在很清楚 Bayes 框架可以如何用于为主要的元启发式方法的操作原理提供解释. 所有的元启发式方法都在搜索中对目标函数 假设 了一类特定的模型 (Bayes 先验知识), 并与每次迭代中的取样点结合起来, 以便为在最有希望的方向上搜索提供指导. 例如, 遗传算法以及其他很多优化方法都假定目标函数具有 很强的因果关系 (如果确实如此, 它们的表现就会很好): 即小的原因只会产生小的效应. 对于因果关系很弱的目标函数, 它们的表现就会变差 [2]. 在元启发式方法中, 函数的先验知识由所采用的搜索算子 (交叉, 变异 等) 及相应的内部工作参数集隐式地定义. 最近若干年已经研究过很多自适应策略, 即根据搜索过程中的部分结果自动改变算法的内部参数的取值 [8]. 这些 (所谓的 “聪明的”) 优化算法所做的, 正是更加明显地融合了 Bayes 操作的逻辑. 它们根据每次迭代得到的样本点以及对函数结构的某些假定 (先验知识), 生成一个 后验 模型. 它们一步步地迭代, 通过调整一系列内部参数, 更好地修正函数模型, 并 (按照 后验 模型) 在更有希望的区域上进行快速搜索.

再举一例, 协方差矩阵自适应进化策略 (CMA-ES: Covariance Matrix Adaptation Evolutionary Strategies) 是连续全局优化中最著名的算法之一. 同样, 这一算法的主要思想是使用迭代中收集到的样本点信息, 在二次函数结构的假设下, 在迭代过程中 重新生成函数模型进行优化 [17]. 这再次表明了寻找最优, 模型的确定和优化过程所针对的函数的几何特征的先验知识之间存在很强的联系. 元启发式方法的内部先验知识对全局探索和局部寻优的权衡进行了定义和约束, 所以也对搜索过程的求解能力进行了定义和约束.

小结一下: 每种优化方法的求解能力与如下几点密切相关: a) 所采用的内部先验模型与手头问题的几何特征有多匹配; b) 另一方面, 从 $\mathcal{H} \times \text{Im}(f)$ 中获得一个 好的 样本 $\mathcal{D} = \{(x_1, f(x_1)), \dots, (x_n, f(x_n))\}$ 的可能性有多大. 对于计算成本很高的函数或者高维的搜索空间, 这将会是一个问题. 正如我们说过的, 维数灾会影响生成有效的后验知识的能力, 因为随着维数的增加, 在推理过程中能得到有用信息所需要的样本点的数量会指数增加.

5. 结论

对以上讨论总结如下:

- 黑箱优化 = 函数结构的先验知识 + 样本数据集 + 算法.
- 一般来说, 关于目标函数图像的知识对设计好的优化过程是非常关键的, 这里好的优化过程是指对局部搜索和全局搜索之间的权衡更好地进行调整的可能性.
- 按照 Bayes 的逻辑, 可以更清晰地理解 NFLT 的含义. 在抽象的层次上, Bayes 方

法是有效的黑箱优化策略的一个自然的框架.

- 先验知识的选择是关键点. 如果待优化的适应值函数属于光滑函数, Bayes 优化中的 Gauss 过程是一个有效的选择.

- 所有的元启发式方法或多或少隐式地假定了特定的函数模型 (先验知识). 如果该模型与待优化问题的几何特征相匹配, 它们的计算效果就很好.

- 维数灾会影响每种优化方法的搜索能力: 在高维搜索空间, 推理过程所需要的样本点的数量会大幅增加.

参考文献

- [1] C. Blum and A. Roli, Metaheuristics in combinatorial optimization: Overview and conceptual comparison 35 (3), ACM Computing Surveys, p. 268–308, 2003.
- [2] T. Weise, M. Zapf, R. Chiong, and A. J. Nebro Urbaneja, Why is optimization difficult? Nature-Inspired Algorithms for Optimisation, Raymond Chiong (Ed.), p. 1–50, April 30, 2009.
- [3] S. Shan and G. Gary Wang, Survey of modeling and optimization strategies to solve high-dimensional design problems with computationally-expensive black-box functions, Structural and Multidisciplinary Optimization, 41 (2), p. 219–241, March 2010.
- [4] Y. Tenne, A computational intelligence algorithm for expensive engineering optimization problems, Eng. Appl. Artif. Intell. 25 (5), 1009–1021, August 2012.
- [5] M. Mitchell, An Introduction to Genetic Algorithms, MIT Press, Cambridge, MA, USA, 1998.
- [6] X. S. Yang, Review of metaheuristics and generalized evolutionary walk algorithm, J. Bio-Inspired Computation 3 (2), p. 77–84, 2011.
- [7] T. Hastie, R. Tibshirani and J. Friedman, The Elements of Statistical Learning: Data Mining, Inference, and Prediction, Springer, corrected edition, August 2003.
- [8] A. E. Eiben, Zbigniew Michalewicz, Marc Schoenauer and James E. Smith, Parameter control in evolutionary algorithms, Parameter Setting in Evolutionary Algorithms, 19–46, 2007.
- [9] D. H. Wolpert and W. G. Macready, No free lunch theorems for optimization, IEEE Transactions on Evolutionary Computation 1 (1), p. 67–82, 1997.
- [10] C. Garcia-Martinez, F. J. Rodriguez and M. Lozano, Arbitrary function optimisation with metaheuristics, Soft Computing 16 (12), p. 2115–2133, December 2012.
- [11] A. Sudjianto, K. T. Fang and R. Li, Design and Modeling for Computer Experiments (Computer Science & Data Analysis), Chapman & Hall/CRC, 2005.
- [12] Y. Jin, A comprehensive survey of fitness approximation in evolutionary computation, Soft Computing—A Fusion of Foundations, Methodologies and Applications 9 (1):312, 2005.
- [13] A. R. Conn, K. Scheinberg and L. N. Vicente, Introduction to Derivative-Free Optimization, Society for Industrial and Applied Mathematics, Philadelphia, PA, USA, 2009.
- [14] E. Brochu, V. M. Cora and N. de Freitas, A Tutorial on Bayesian Optimization of Expensive Cost Functions, with Application to Active User Modeling and Hierarchical Reinforcement Learning, CoRR abs/1012.2599, 2010.
- [15] T. Alpcan, A framework for optimization under limited information, J. Glob. Optim. 55, p. 681–706, 2013.
- [16] M. Hoffman, E. Brochu and N. de Freitas, Portfolio Allocation for Bayesian Optimization, UAI, 2011, arXiv:1009.5419v2.

(下转 258 页)

尤其是,年轻的数学家们怎样对付知识的这一爆炸并且有所创新呢?

S: 哦,是的,我在新加坡接受采访时我已经被问过这个问题,采访刊登在《数学信使(The Mathematical Intelligencer)》¹⁾上,我的回答是,当一个人真地对一个特别的问题感兴趣的时候,在现存文献中与它有关联的东西通常很少.这意味着你只能靠自己.

至于数学知识“爆炸”的感觉,我相信 Abel 在 Euler (欧拉), Lagrange (拉格朗日), Legendre (勒让德) 和 Gauss (高斯) 之后开始工作的时候,他以相同的方式感觉到了.但他发现了新的问题和新的解法.自此之后情况就是如此.无需忧虑.

R & S: 另一个流行的问题是许多年轻且有才能的人——还有公众意见的领头人物——不认为数学是非常激动人心的.

S: 是的,非常悲哀,有许多这样的例子.

几年以前,甚至法国研究部的部长被人引用说数学家现在不再有任何用处了,因为现在知道在计算机上怎样击键已经足够了.(他可能认为键入和计算机程序唾手可得...)

对年轻人发现数学和被数学吸引我仍然乐观. Abel 庆典的一个好的方面是挪威高中生的 Abel 竞赛.

7. 体育运动和文学

R & S: 您能告诉我们您数学之外的兴趣吗?

S: 体育运动!更精确一些:滑雪,乒乓球和攀岩.我从来没有真正擅长它们中的任何一项(例如,当我滑雪时,我不知道怎样回转,因此我愿意做“直线滑降”而不尝试转弯);但我很喜欢它们.

不幸的是,因为年龄的缘故,我的膝盖已经不行了(一个膝盖甚至被一个金属-塑料的东西代替了),所以我不得不停止所有的运动.我现在唯一能做的就是让别人代我攀岩:把朋友带到枫丹白露(Fontainebleau),哄他们去攀那些我10年前会去攀的岩石.还是很有趣的,但是比自己攀岩要差多了.

其他兴趣:电影(《低俗小说(Pulp Fiction)》²⁾是我的最爱之一,我还是 Altman, Truffaut, Rohmer, Coen 兄弟的一个粉丝...);国际象棋;书籍(所有种类的书,从 Giono 到 Böll,再到 Kawabata,包括童话和《哈利·波特(Harry Potter)》系列).

R & S: Serre 教授,为这次采访我们代表丹麦数学会和挪威数学会感谢您.

编注 有关 Abel 奖更多信息,请参阅 Abel 奖官方网站 <http://www.abelprize.no/>.

(赵振江 译 陆柱家 校)

(上接 239 页)

[17] N. Hansen, The CMA evolution strategy: A comparing review, Towards a new evolutionary computation Advances on Estimation of Distribution Algorithms, Springer, p. 1769-1776, 2006.

(谢金星 译 叶其孝 校)

1) An Interview with J-P. Serre, The Mathematical Intelligence 8(1986), 8-13. 也请参阅: 'Jean-Pierre Serre', in Wolf Prize in Mathematics Vol.II (eds. S. S. Chern and F. Hirzebruch), World Sci. Publ. Co. (2001) 523-551; 和 'Jean-Pierre Serre', medulla Fields' by Bilar Bayer, La Gaceta 4(1) (2001), 211-247.——原注

2) 美国 1994 年的暴力喜剧影片,由 Quentin Tarantino 导演.——校注