

# 数据的几何与生物学

Mauro Maggioni

## 1. 前言

包括统计学、工程领域、信号处理、物理学、生物学和医学在内的许多领域需要对大型高维数据集进行分析. 在统计学领域中, 虽然数据一直是被关注的焦点, 但是在过去的几十年里, 从理论和实践的角度来看, 许多数据集的性质与以往的不同, 从而我们需要新的处理方法. 现代的数据集可能很大, 但通常是以高维形式出现, 这就意味着每个数据点都有一长串的特征或坐标. 生物数据经常是这种情况 (例如: 基因图谱 (genetic profile) 动辄就有超过  $10^4$  的条目 (entries)). 当数据点的个数  $n$  很大时, 有利于统计分析, 但是如果数据的维数  $D$  很大, 这将成为困扰统计学家头上的“魔咒”. 如果对数据没有进一步的假设或建模, 要想成功运用许多经典统计推断和函数逼近技术来解决问题, 必须要求数据点的个数  $n$  相对于维数  $D$  成指数级增长. 这样的  $n$  实在是太大了 (想想  $2^{10^4}$  的有多大) [11]. 为了对付这个“魔咒”, 统计学家们给数据添加了各种类型的假设, 包括参数和非参数统计模型、几何模型. 这些方法之间并非毫无关系, 实际上它们只是使用了不同的语言来表达模型假设并提供有关数据结构的先验信息. 这些假设通常有一个几何解释, 它们其实是给数据集强加了一个内蕴的低维数, 并在学习算法和统计任务中利用这一性质, 使得其实施的结果依赖于内蕴维数  $d$ , 而不依赖于数据表面上的维数  $D$ .

## 2. 图形、几何和谱方法

我们现在探讨一种在机器学习领域被称作流形学习的几何框架. 基本思想是通过连接相邻数据点构建一个图, 然后研究这个图的几何特征, 从而获得数据的内蕴几何性质.

给定数据  $X_n := \{x_i\}_{i=1}^n \subset \mathbb{R}^D$ , 我们将集合  $X_n$  视为图的顶点集, 所有的有序点对  $(x_i, x_j)$  都视为图的边 (包括  $x_i = x_j$  的情形, 即点  $x_i$  到自己的边), 构造一个加权图  $G$ , 其中每条边  $(x_i, x_j)$  的权是

$$W_{ij} = e^{-\|x_i - x_j\|^2 / \sigma}, \quad (1)$$

或者其他相似性度量 (下面会谈及更多). 设  $D$  为顶点的次数矩阵, 也就是, 一个对角元为  $D_{x_i x_i} = \sum_{x_j} W_{x_i x_j}$  的对角矩阵. 我们考虑与 Markov (马尔可夫) 矩阵为  $P = D^{-1}W$  相伴的随机游动, 以及正规化的 Laplace (拉普拉斯) 矩阵  $\mathcal{L} = I - D^{-\frac{1}{2}}WD^{-\frac{1}{2}}$ . 这些对象在图的谱理论中被广泛研究过 [3]. 其中, 矩阵  $P$  与  $\mathcal{L}$  的本征值与本征向量的性质 (它们是密切相关的) 被用来收集有关图的几何信息.

---

译自: Notices of the AMS, Vol. 62 (2015), No. 10, p. 1185–1188, Geometry of Data and Biology, Mauro Maggioni, figure number 1. Copyright ©2015 the American Mathematical Society. Reprinted with permission. All rights reserved. 美国数学会与作者授予译文出版许可.  
作者是杜克大学的数学教授, 他的邮箱地址是 [mauro@math.duke.edu](mailto:mauro@math.duke.edu).

在扩散几何 (diffusion geometry) 领域 [7], [8], [5], [6], 我们关注于随机游动  $P$ , 并且研究它与图上的随机过程之间的关系, 以及它与高维动力学系统的关系 [4], [18], [22]. 这两种关系经常出现于生物学中. 令  $P\varphi_i = \lambda_i\varphi_i$  为  $P$  的谱分解, 它的本征值由大到小排序为:  $1 = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_i \geq \dots$ . 我们考虑扩散映射 (diffusion map)  $\Phi_{t,m}$ , 它是  $G$  到  $\mathbb{R}^m$  的一个嵌入, 对于某个  $t \geq 0$ , 某个  $m \geq 1$ , 定义为:  $\Phi_{t,m}(x) = \left(\sqrt{\lambda_i^t}\varphi_i(x)\right)_{i=1}^m$ . 这个映射的各种版本在计算机科学和微分几何中有长期的应用历史 [2], 在计算机科学中它们被用于将图嵌入到平面中. 它的一般性质到现在都不能完全被人所知, 而对于某一类图而言 (例如, 扩展图), 这个映射不具备我们想要的性质.

考虑这样一种情况,  $\mathcal{M}$  是  $\mathbb{R}^D$  中一个  $d$  维 Riemann (黎曼) 流形, 它上面赋有一个正规化的体积测度. 点集  $X_n$  是在  $\mathcal{M}$  上依据该测度独立采样得到的. 图  $G$  和在它之上构建的算子, 例如,  $P$  和  $\mathcal{L}$ , 都是样本的随机变量. 我们可以证明, 当  $n$  趋于无穷大时, 这个 (随机线性) 算子  $\mathcal{L}$  收敛于  $\mathcal{M}$  上的内蕴 Laplace-Beltrami (贝尔特拉米) 算子.<sup>1)</sup>

### 3. 谱聚类与扩散

在图的情形, 如果在图上定义一个合适的度量, 扩散映射  $\Phi_{t,m}$  或许能显示出一个好的度量性质. 我们在图  $G$  上定义时刻  $t$  时的扩散距离为:

$$d_t(x, y) = \|P^t(x, \cdot) - P^t(y, \cdot)\|_{L^2(G)},$$

其中,  $\|f\|_{L^2(G)}^2 = \sum_{x \in G} |f(x)|^2$ . 换句话说, 如果从  $x$  点和从  $y$  点开始的长度为  $t$  的随机游动很少能以相近的概率达到同一点, 则  $x, y$  两点间的扩散距离  $d_t(x, y)$  较大.

根据谱展开, 易得,

$$d_t(x, y)^2 = \sum_{i=1}^n \lambda_i^t |\varphi_i(x) - \varphi_i(y)|^2 = \|\Phi_{t,n}(x) - \Phi_{t,n}(y)\|_{\mathbb{R}^n}^2 \cong \|\Phi_{t,m}(x) - \Phi_{t,m}(y)\|_{\mathbb{R}^m}^2.$$

换句话说,  $\Phi_{t,m}$  值域上的 Euclid (欧几里得) 距离等价于  $G$  上的扩散距离. 什么时候扩散距离就真的特别有用了呢? 如果这个图包含两个聚类  $C_1, C_2$ , 并且聚类的定义是“合理的”, 我们就能预期到, 只有极少的长度为  $t$  的随机游动从点  $x \in C_1$  转换到点  $y \in C_2$  (除非  $t$  非常大), 反之亦然; 因此, 扩散距离  $d_t(x, y)$  必须比较大. 事实就是如此, 例如, 导率被用来定义聚类: 令

$$c(S) = \frac{\sum_{x \in S, y \notin S} W_{xy}}{\min\{\sum_{x, y \in S} W_{xy}, \sum_{x, y \notin S} W_{xy}\}}$$

是  $S \subseteq G$  的导率. 一个聚类可以被定义为一个具有小导率的集合  $S$ : 如果  $c(S)$  很小, 那么连接集合  $S$  与其补集的那些边的权之和小于集合  $S$  内的边的权之和, 也小于集合  $S$  补集内的那些边的权之和. 这表明, 一个开始于  $S$  中点的随机游动会以一个较高的概率长时间地困在  $S$  中. 更准确地说, 随机<sup>2)</sup>选取  $S$  中的一个点, 然后从该点开始随机游动, 则至少有  $1/2$  的概率随机游动停留在  $S$  中的时间长达  $O(1/c(S))$ . 所以, 如果这两个聚类  $C_1$  和  $C_2$  有很低的导率, 那么对于任意的  $x \in C_1$  和  $y \in C_2$  之间的扩散距离会大到时间

1) 在适当的意义下, 构建  $W$  的过程中,  $\mathcal{M}$  在合适的正规化意义下, 通过恰当的选取  $\sigma$  (把它看做是  $n$  和  $d$  的函数), 在一个比较高概率的意义下收敛 [7], [10].——原注

2) 更精确地说, 按照  $P$  的平稳分布. ——原注

$O(1/\max\{c(C_1), c(C_2)\})$ . 这表明, 映射  $\Phi_{t,m}$  会将  $C_1$  与  $C_2$  映射成 Euclid 空间中距离很远的两个集合, 在那里它们有可能被一个简单边界分隔开, 比如, 一个超平面. 聚类方法是被广泛使用的最强大的聚类算法之一, 可以追溯到 20 世纪 70 年代的工作 [12], [13] (也见 [19], [21]). 该方法也许就是受我们前面提及的思想的启发.

#### 4. 与生物学的联系

正如上面所说, 生物学中高维大数据的收集需要新的数学和统计学工具. 我们从众多和几何模型息息相关的案例中, 找出两个例子来加以说明.

第 1 个例子, 聚类 (*clustering*) 是生物学数据分析中一个非常常见的任务 (见 [14], [20], [15], [1] 及它们的参考文献, 还有许多其他文献). 首先在各个需要被聚类的对象之间 (基因, 蛋白质, 基因组, 生物进化树等) 定义一个相似性函数, 再用与这些相似性度量相关的聚类或分层聚类技术对这些感兴趣的对象进行聚类 (例如, 不同病人之间的基因应答), 从而发现它们之间的结构. 获得聚类形状的先验信息通常是很困难的, 而诸如谱聚类这样的工具则是理想的工具, 它不需要关于聚类形状的任何假设, 就能将有生物学意义的相似性度量融合到图中.

另一个例子, 也许会令人惊讶, 与 分子动力学 (*molecular dynamics*, MD) 相关. 几何模型通常用来探究生物分子的性质. 分子在溶液中的运动通常是利用大规模的随机微分方程组来建模, 这里随机性代表了溶剂对分子的影响. 且不说这种模型 (不符合条件的) 缺点, 人们得到了一个表示势阱中扩散的一阶 Langevin (郎之万) 方程:

$$dY_t = -\nabla U(Y_t) dt + \Sigma dB_t,$$

其中,  $Y_t$  是一个包含分子中  $N$  个原子的三维坐标的  $3N$  维向量,  $U$  是一个定义在状态空间  $\mathbb{R}^{3N}$  上的势函数,  $B_t$  是一个标准的 Wigner (威格纳) 过程,  $\Sigma$  为扩散张量,  $N$  通常非常大.

通常我们对这些系统的特殊特征感兴趣, 尤其发生在较大时间尺度范围内的事件, 例如, 相对能量水平或亚稳态之间的跃迁率. 分子在跃迁到另一个状态之前会长时间的停留在当前状态. 这些分子可能所处的状态构成的状态空间中的局部能量极小点被称为亚稳态. 在这种情况下, 可以很自然地假设, 在这么大时间尺度范围下, 决定分子行为的有效自由度不多. 从几何上来说, 存在本质上低维的集合, 在这些集合周围聚集了大量时间轨线; 亚稳态将会对应于不同的“聚类”中, 而产生这些聚类的根据则在于它们之间的跃迁 (期望) 时间不同.

这样的思维方式揭示了上述扩散距离、聚类和低导率集合之间的联系. 最近几篇论文从几何学角度在这个方面做出了重大贡献: 首先, [7], [8], [4] 论证了, 给定一个从长分子动力学轨线中独立抽取的样本集合, 我们可以简单修改上述图结构而得到一个图的 Laplace 算子, 该 Laplace 算子并不是用来近似流形的 Laplace 算子, 而是用来近似上述关于 Langevin 扩散的 Fokker-Plank (福克尔 - 普朗克) 方程相关的 Laplace 算子. 该 Fokker-Plank 方程描述了分子位置的概率分布的演化过程. 其次, 自然地, 我们利用扩散映射将状态空间的维数降低至  $\mathbb{R}^m$ ,  $m \ll 3N$ , 并且考虑能否直接写下或者从数据中得到  $\mathbb{R}^m$  中的 Langevin 方程, 其轨道与原轨道相一致 (图 1). 进行这类模型简化过程是为了得

到高维系统的信息,但是这至关重要的低维嵌入的选择却经常只能由物理化学家利用专业知识在实践中获得.

尽管很有发展前景,标准的扩散映射技术对于参数选择相当敏感(特别是,式子(1)权构造中的参数 $\sigma$ ).同样人们也不清楚,长时间轨道会聚集在低维集合附近的假设对于实际数据来说是否是一个好模型.一种全新的叫多尺度奇异值分解(multiscale SVD)的技术[17],被用来稳健性(robust)地估计数据的内蕴维数.其基本思想是对数据点 $z$ 为中心, $r$ 为半径的球 $B_z(r)$ 中的数据进行奇异值分解.并且,对于给定的 $z$ ,与变数 $r$ ,利用奇异值的行为确定数据的内蕴维数和一个合适的尺度( $r$ 的值),在这个尺度下, $z$ 周围的数据都是低维的.这些构造过程来自于几何测度论中的经典工作[16].这种构造方法也被推广到某些非Euclid空间中(例如,建模分子动力学中状态空间的空间,自然的定义为, $\mathbb{R}^{3N}$ 模上Galileo(伽利略)群),并且用来证明的确一般都是以上情况,尤其是在亚稳态之间的重要跃迁路径附近,长轨道的内蕴维数确实比状态空间维数小[18].而且,多尺度的奇异值分解方法可以对每一个点 $z$ 估计一个“好的局部尺度” $r^*(z)$ .粗略地说, $r^*(z)$ 是最大的能够保证 $B_z(r)$ 中的数据既

是本质上低维的又可由低维的超平面(近似平坦)来良好逼近的 $r$ .结果证明,对于分子动力学中数据来说,内蕴维数和这个“好的局部尺度”在状态空间的不同区域之间通常有很大不同.自然地,在图的构造(1)式中,利用“好的局部尺度”作为测量尺度参数 $\sigma$ (这里是 $x_i$ 的函数而非常数),这就得到了一个具有稳健性地扩散映射的推广,即局部尺度扩散映射[18],这个映射被成功用于多分子的建模简化,由此得到大分子的极为低维的有用的表示,甚至,在人们曾认为不可能有这类表示的情况下,也可能找得到[22].

实际和理论上仍存在着难以克服的挑战.例如,以上技术需要从长轨道中采样,然而这一过程可能极其昂贵.文献[9]发展了一套基于前面提到的维数估计和降维方法的新算法,用于加速分子动力学道路的模拟.该算法的使用条件只需要给定大量的短路径,即使这一计算过程仍然非常昂贵,但是可以很容易的进行并行计算了.




图1 具有 $N = 12$ 个原子的小肽(丙氨酸二肽)轮廓的扩散映射,由隐式溶剂模拟(即,不模拟所有的水分子,而是通过引入噪声和修正力场来模拟它们的“净力”),利用文献[18]描述的算法进行计算,考虑了局部维数和局部尺度,此处数据是近似“线性的”.密集点区域对应了亚稳态,作为连接部分的稀薄点区域则对应了亚稳态之间的跃迁路径.图中明显的自相交源于人为的将 $D = 36$ 维数据嵌入到 $m = 3$ 维空间,如果嵌入到 $m = 4$ 维空间,则不会出现自相交.这些点根据分子的二面角之一进行着色,二面角记为 $\phi$ ,现已知它对于分子的有效动态十分重要.显然它是前两位扩散坐标的函数,这些坐标由上述算法得到,第2个二面角(未显示)也同样由该算法得到.我们给出了两个最重要的亚稳态区域,这两个区域在第1个扩散坐标处分离;每一个亚稳态区域都有两个子区域,它们被更高维的扩散坐标分离,如[18]中所述,一维Langevin过程能在第1个扩散坐标处被估计出来,从而精确地再现了原系统在长时间时动力学行为的关键特征

## 5. 结论

生物数据集非常的庞大, 维数高, 极其多样化而且复杂: 我们需要新的数学上的、算法上的以及交互式的工具来提取信息, 帮助实现可视化, 进而解释数据. 这些数学构造和算法对于数据的作用, 相当于采集数据的设备对现实世界的作用: 它们帮助人们捕捉、量化支配它们输入对象的规律, 并激励人们发现这些规律.

致谢 (略)

## 参考文献

- [1] N. Altemose, K. H. Miga, M. Maggioni, and H. F. Willard, Genomic characterization of large heterochromatic gaps in the human genome assembly, *PLoS Comput. Biol.* 10 (2014), e1003628.
- [2] P. Bérard, G. Besson, and S. Gallot, Embedding Riemannian manifolds by their heat kernel, *Geom. Funct. Anal.* 4 (1994), 374–398.
- [3] F. R. K. Chung, *Spectral Graph Theory*, vol. 92 of CBMS Regional Conference Series in Mathematics, published for the Conference Board of the Mathematical Sciences, Washington, DC, by the Amer. Math. Soc., Providence, RI, 1997.
- [4] R. Coifman, I. Kevrekidis, S. Lafon, M. Maggioni, and B. Nadler, Diffusion maps, reduction coordinates and low dimensional representation of stochastic systems, *SIAM J.M.M.S.* 7 (2008), 842–864.
- [5] R. Coifman and S. Lafon, Diffusion maps, *Appl. Comp. Harm. Anal.* 21 (2006), 5–30.
- [6] R. Coifman and M. Maggioni, Diffusion wavelets, *Appl. Comp. Harm. Anal.* 21 (2006), 53–94 (Tech. Report YALE/DCS/TR-1303, Yale Univ., September 2004).
- [7] R. R. Coifman, S. Lafon, A. B. Lee, M. Maggioni, B. Nadler, F. Warner, and S. W. Zucker, Geometric diffusions as a tool for harmonic analysis and structure definition of data: Diffusion maps, *Proc. Natl. Acad. Sci., USA* 102 (2005), 7426–7431.
- [8] ———, Geometric diffusions as a tool for harmonic analysis and structure definition of data: Diffusion maps, *Proc. Natl. Acad. Sci., USA* 102 (2005), 7432–7438.
- [9] M. Crosskey and M. Maggioni, Atlas: A geometric approach to learning high-dimensional stochastic systems near manifolds, 2014, submitted, arXiv: 1404.0667.
- [10] M. J. Daniel Ting, Ling Huang, and Michael I. Jordan, An analysis of the convergence of graph Laplacians, arXiv: 1101.5435, 2011.
- [11] D. Donoho, High-dimensional data analysis: The curses and blessings of dimensionality, “Math Challenges of the 21st Century”, UCLA, August 7–12, 2000, organized by the Amer. Math. Soc.
- [12] W. E. Donath and A. J. Hoffman, Lower bounds for the partitioning of graphs, *IBM J. Res. Develop.* 17 (1973), 420–425.
- [13] M. Fiedler, Algebraic connectivity of graphs, *Czechoslovak Math. J.* 23 (1973), 298–305.
- [14] M. Filippone, F. Camastra, F. Masulli, and S. Rovetta, A survey of kernel and spectral methods for clustering, *Pattern Recognition* 41 (2008), 176–190.
- [15] D. J. Higham, G. Kalna, and M. Kibble, Spectral clustering and its use in bioinformatics, *J. Comput. Appl. Math.* 204 (2007), 25–37. Special issue dedicated to Professor Shinnosuke Oharu on the occasion of his 65th birthday.
- [16] P. W. Jones, Rectifiable sets and the traveling salesman problem, *Invent. Math.* 102 (1990), 1–15.
- [17] A. V. Little, M. Maggioni and L. Rosasco, Multiscale geometric methods for data sets I: Multiscale SVD, noise and curvature, tech. report, MIT-CSAIL-TR-2012-029/CBCL-310, MIT, Cambridge, MA, September 2012.

(下转 191 页)

定理 2 中所提到的例外的数目也许很大, 特别如果  $c$  充分接近于  $\frac{1}{2}$  时. 为了看到这一点, 令  $c_i \in [0, \frac{1}{2})$ ,  $\forall i \in \mathbb{N}$ , 并令  $n_i \in \mathbb{N}$  是使得

$$\frac{(n - c_i)^{1-s}}{s-1} < \sum_{k=n}^{\infty} k^{-s} < \frac{(n - \frac{1}{2})^{1-s}}{s-1}$$

对所有  $n \geq n_i$  成立的最小值. 若  $\lim_{i \rightarrow \infty} c_i = \frac{1}{2}$ , 则  $\sup n_i = \infty$ , 因为否则的话存在  $n \in \mathbb{N}$ , 对所有  $i \in \mathbb{N}$  满足  $n_i \leq n$ , 而这导致矛盾:

$$\frac{(n - \frac{1}{2})^{1-s}}{s-1} = \lim_{i \rightarrow \infty} \frac{(n - c_i)^{1-s}}{s-1} \leq \sum_{k=n}^{\infty} k^{-s} < \frac{(n - \frac{1}{2})^{1-s}}{s-1}.$$

下述推论是上述两个定理当  $\varepsilon = \frac{1}{2} - c$  时的直接后果.

**推论** 若  $s \in \mathbb{R}$ ,  $s > 1$ , 并且  $\varepsilon \in (0, \frac{1}{2}]$ , 则存在  $n(\varepsilon) \in \mathbb{N}$ , 使得

$$\frac{(n(\varepsilon) - \frac{1}{2} + \varepsilon)^{1-s}}{s-1} < \sum_{k=n(\varepsilon)}^{\infty} k^{-s} < \frac{(n(\varepsilon) - \frac{1}{2})^{1-s}}{s-1}.$$

在某些特殊情形, 比较容易得到  $n(\varepsilon)$  的好的值. 如果我们令  $\varepsilon = \frac{1}{2} - c$ , 其中  $\varepsilon \in (0, \frac{1}{2}]$ , 那么 (7) 就变为

$$\left( (k + \varepsilon)^2 - \frac{1}{4} \right)^{s-1} + \frac{k^s}{s-1} \left( \left( k + \varepsilon - \frac{1}{2} \right)^{s-1} - \left( k + \varepsilon + \frac{1}{2} \right)^{s-1} \right) > 0. \quad (8)$$

当  $s$  是自然数时, 上式左端是  $k$  的一个多项式. 作为一个例子, 令  $s = 2$ , 则 (8) 等价于

$$k > \frac{1 - 4\varepsilon^2}{8\varepsilon}.$$

这意味着, 当  $s = 2$  时, 我们不妨把  $n(\varepsilon)$  取为大于  $\frac{1-4\varepsilon^2}{8\varepsilon}$  的最小整数, 并且有

$$\frac{1}{n - \frac{1}{2} + \varepsilon} < \sum_{k=n}^{\infty} k^{-2} < \frac{1}{n - \frac{1}{2}} \quad \forall n > \frac{1 - 4\varepsilon^2}{8\varepsilon}.$$

## 参考文献

- [1] A. A. Karatsuba, S. M. Voronin, The Riemann Zeta-Function. English translation by N. Koblitz. De Gruyter Expositions in Mathematics, Vol. 5, W. de Gruyter, Berlin, 1992.
- [2] S. Lang, A First Course in Calculus. Fifth edition, Undergraduate Texts in Mathematics, Springer-Verlag, New York, 1993. (陆柱家 译 陈凌宇 校)

\*\*\*\*\*

(上接 147 页)

- [18] M. A. Rohrdanz, W. Zheng, M. Maggioni, and C. Clementi, Determination of reaction coordinates via locally scaled diffusion map, J. Chem. Phys. (2011), 124116.
- [19] D. Spielman and S. Teng, Spectral partitioning works: Planar graphs and finite element meshes, FOCS (1996), 96–105.
- [20] D. Tritchler, S. Fallah, and J. Beyene, A spectral clustering method for microarray data, Comp. Stat. Data Anal. 49 (2005), 63–76.
- [21] U. von Luxburg, A tutorial on spectral clustering, CoRR, abs/0711.0189 (2007).
- [22] W. Zheng, M. A. Rohrdanz, M. Maggioni, and C. Clementi, Polymer reversal rate calculated via locally scaled diffusion map, J. Chem. Phys. (2011), 144108.

(郑文奇 译 杨坤一 校)