

学科与专题介绍

机器学习：数学理论和科学应用

鄂维南

本文基本上是 2019 年 7 月 15 日在瓦伦西亚 (Valencia) 的国际工业与应用数学大会 (ICIAM) 所做的 Peter Henrici (亨里齐) 奖报告的文字本。这个报告的目的是给出一个关于以下内容的概括介绍：

- 用以解决多个学科中一些最具有挑战性问题的关于集成机器学习和科学建模 (例如基于物理学的建模) 的一些当前工作，
- 关于构建机器学习的数学理论的一些当前工作。

我想传达两条基本信息。第 1, 在理论和计算科学和工程中, 我们遇到的一个基本障碍是在处理高维问题时我们的有限能力。机器学习现在为处理这个问题提供了新的工具。机器学习和科学模拟的结合将给予我们前所未有的技术力量, 并且很可能将改变我们做科学和工程的方式。

第 2, 尽管直到现在机器学习还不是应用数学中最流行的领域, 但除了机器学习需要关心的是非常高维度中的问题这一事实外, 机器学习的精神和数值分析是非常一致的。为了建立机器学习的理论基础, 我们需要发展高维数值分析。

1. 偏微分方程 (组) 和物理学的基本定律

数学最重要的作用之一就是它提供了表述物理学基本定律的语言。这些定律经常用偏微分方程 (组) (PDEs) 来表达。两个最重要的这样的偏微分方程 (组) 是量子力学的 Schrödinger (薛定谔) 方程和流体力学的 Navier-Stokes (纳维-斯托克斯) 方程组。其它的例子包括动理学理论的 Boltzmann (玻尔兹曼) 方程, 线性和非线性的弹性方程, 以及电磁学的 Maxwell (麦克斯韦) 方程。

回到 1929 年量子力学刚建立时, Paul Dirac (狄拉克) 做了如下观察 [7]:

“一大部分物理学和全部化学的数学理论所需背后的物理学定律就这样完全知道了, 困难只在于这些定律的精确应用给出的方程过于复杂而很难求解。”

基本上 Dirac 说的是实际中遇到的大多数情形中, 困难已经不在于要找到基本定律的物理问题上, 而在求解表达这些定律的偏微分方程组的数学问题上。

2. 以前的成功和失败

紧接着这些基本定律建立后的那些年, 所做的努力集中在用解析方法来找到近似模型或近似解。例如, 密度泛函理论 (density functional theory, DFT), 量子力学的一个大

译自: Notices of the AMS, Vol. 66 (2019), No. 11, p. 1813–1820, Machine Learning: Mathematical Theory and Scientific Applications, Weinan E. Copyright ©American Mathematical Society 2019. All rights Reserved. Reprinted with permission. 美国数学会与作者授予译文出版许可。

Weinan E (鄂维南) 是普林斯顿大学的数学系与应用数学和计算数学项目教授, 他的邮箱地址是 weinan@math.princeton.edu.

为简化的模型，在同一年由 Fermi (费米) 和 Thomas (托马斯) [13] 提出。多年后这个理论被发展成为计算材料科学和化学的一个主力军 [13]，其主要贡献者之一 Walter Kohn 在 1998 年被授予 Nobel (诺贝尔) 化学奖。尽管它们在实际中被大量使用，很多这样的近似模型都是非常特定的，并且经常包含不受控制的近似。在应用数学界，为了寻求逼近解发展了渐近方法，结果成败参半 [15]。

2.1 数值求解微分方程组

求解这些偏微分方程组的第 1 个一般的方法在现代计算机诞生后在 20 世纪 50 年代出现。在这期间和随后的时间里，数值算法，特别是有限差分 and 有限元方法得到了发展，分析，并且应用于广泛的多种问题。这是一项很成功的活动，甚至延续到今日。这些数值方法如此强大，以致它们已经成为工程和一些科学学科中的标准工具。很多问题都得到了基本上的解决，包括气体动力学，结构分析，雷达，声纳等等中的问题。

但是很多问题还是很困难。这些问题的例子包括：经典或量子多体问题，基于第一性原理的药物和材料设计，蛋白质折叠，湍流，塑性，和非 Newton (牛顿) 流体。这些问题的一个共同特征是解以基本的方式依赖于很多变量。例如，虽然由 Navier-Stokes 方程组描述的湍流是一个三维的问题，但它的解包含很多起作用的尺度，这意味着它涉及很多自由度。使得这些问题很困难的是维数灾 (*curse of dimensionality*)。随着维数 (也就是变量数或者自由度) 增长，复杂度 (或者说计算成本) 指数地增长。这一直是众多应用中的一个基本障碍。

2.2 多尺度建模

第 2 个重要的进展是多尺度，多物理算法的发展。这里我们感兴趣的是对某些宏观尺度系统的建模，但是我们缺少在那样的尺度上的可靠的物理模型。取而代之地，我们可以在一个较细尺度上有一个可靠的微尺度模型，它包含了更多的自由度。其想法是要发展能够模拟宏观尺度系统，但是只使用微尺度模型的算法。这样方法论的重要例子包括非齐性多尺度方法 (heterogeneous multiscale method, HMM)，无方程 (equation free) 方法，和拟连续统 (quasi-continuum) 方法 [8]。HMM 从包含未知量的宏观尺度模型的一个规定的形式开始，在计算过程中使用微尺度模型来“动态地”估计这些量的值。对于宏观和微观过程间有一个尺度分离的问题，这类方法是非常成功的。但是，对于缺少尺度分离的问题，成功就非常有限了。

人们在 HMM 的早期已经意识到，困难是在于利用微尺度模拟数据估计宏观模型中的未知量，特别是对于没有尺度分离的问题。假设我们想要模拟湍流的大尺度动力学，并且我们用大涡模拟 (large eddy simulation) 模型作为我们的宏观尺度模型。这里未知量是 Leonard 应力，未分辨的自由度对平均应力的贡献，它需要从原始的 Navier-Stokes 方程组给出估计。困难来源于 Leonard 应力依赖于多个自由度这个事实；因此从 Navier-Stokes 方程组估计这个应力是一个非常难的任务。

3. 将机器学习和基于第一性原理的模拟相结合

所有这些问题中困难的主要来源在于维数灾，也就是，我们处理多变量函数的有限

能力. 近年来, 我们已经看到机器学习, 特别是深度学习, 在计算机视觉和其它人工智能 (AI) 任务解决这类问题的成功. 很自然地要问机器学习在克服上述应用, 或更一般地, 传统 AI 领域之外的应用中的类似障碍中, 是否能有帮助. 下面我们将描述在这个方向上获得初步成功的一些例子.

在继续之前, 我们应该指出我们所关心的这类应用之中的机器学习任务和传统的 AI 任务之间的一些差别. 第 1 个差别是这里我们感兴趣的是用机器学习来帮助提出可靠的并且实用的物理模型. 这些模型不能违反物理学的约束, 例如对称性和不变量. 第 2 个差别是我们多次用来训练机器学习模型的数据是由一些 (微尺度的) 物理模型产生的. 原则上我们能产生无限量的数据, 但是在实际中产生数据的过程一般都是非常昂贵的. 因此需要带来“最优数据集”的算法: 数据集应覆盖我们感兴趣的所有实际情形, 但又应尽可能地小. 这落入 主动学习 (*active learning*) 的框架. 这也可以被认为是一个适应算法, 其数据采样是适应性的. 为了开发基于机器学习的物理模型, 我们必须处理这两个一般性的问题.

3.1 分子动力学

分子动力学的目标是要通过跟踪系统中所有原子核的轨迹来模拟一个分子的或一个材料系统. 为此, 使用经典 Newton 动力学以及由所有参与的原子核的位置和相关电子结构定义的一个原子之间的势是一个合理的近似. 模拟这个原子间势函数, 一个很多变量的函数——也被称为势能面 (potential energy surface), 或者 PES——是分子模拟的一个主要困难. 有两个不同处理方法. 一个是用量子力学模型“动态地”估计这些函数, 通常是 DFT. 这被广泛地称为原始分子动力学 (*ab initio molecular dynamics*, AIMD) [8]. 第 2 个是用一个猜测的函数形式和一些有限的实验及数值数据, 经验地构造这个函数. 第 1 个方法非常精确, 但是非常昂贵, 限制了人们可以模拟的系统规模只能到几百个原子. 第 2 个方法效率高很多, 但是以精确度来说不太可靠.

有了机器学习的帮助, 我们可以展望分子动力学的一个新范式 (paradigm). 在这个新范式中, 量子力学模型作为一个数据的生成器, 由它再使用机器学习来参数化 PES. 这个新方法对于运作分子动力学能潜在提供一个方法, 其精度可与 AIMD 相提并论, 而其复杂度与经验方法类似.

关于前面提到的两个一般性的议题, 对于这个问题重要的对称性是平移的, 转动的, 和置换的对称性. 最后一个指的是如果我们重新标记相同种类的原子, 则系统不会改变这个事实; 因此 PES 应该也保持不变.

为保证这些对称性以及可伸缩性下的不变性, 对神经网络结构提出了下述设计原理 [5, 17]:

1. 整个网络是子网络的叠加, 每一个子网路对应系统中的一个核. 这保证了可伸缩性. 但是, 这类结构不适合表达长程相互作用.
2. 每一个子网络由一个编码网络和跟随的一个拟合网络组成. 编码网络保证进入拟合网络的数据满足对称性约束.

[18] 中发展的主动学习算法由 3 个主要部分组成:

- 探索：
 - 宏观上：对热力学变量的空间采样，例如，温度和压力。
 - 微观上：对热力学变量的每个固定的组，对相应的正则系综采样。

两者都可以通过标准的方法做到。

- 标记：
 - 利用一个误差估计器决定一个特定的原子构形是否应该被标记。一个简单的误差估计器如下。训练神经网络模型的一个系综 (例如，所有具有相同网络结构但是初始化训练不同的网络)，然后利用它们预测的方差作为误差估计器。误差估计器大的取值意味着当前的网络模型对于所考虑的构形不是足够精确的。因此这个构形需要被标记，并且放入到再训练的数据集中。
 - 对每一个需要被标记的构形，利用 DFT 给出其势能和作用在原子核上力的值，然后将结果放入到训练数据集中。
- 训练：通过拟合数据集中的能量和力更新网络参数。

一旦感兴趣的系统给定，人们可以从基本上没有数据开始，而算法将不断改进模型直到达到满意的精度。例子见 [18]。人们发现只有大约 .01% 被探索的构形需要被标记。

到现在这组想法已经被应用到种类繁多的系统中，包括小的和大的分子，水，半导体，表面材料，高熵合金等等。在每个例子中，人们可以获得精度与 DFT 的精度相比较的机器学习模型。一个叫做 DeePMD-kit 的通用软件已经被开发，并且已经被世界范围的多个研究组使用 [16]。

3.2 模拟气体动力学

气体的动力学由描述单粒子相空间分布函数演化的 Boltzmann 方程模拟。对于稠密气体，Boltzmann 方程可以由描述空间中密度，动量和能量演化的 Euler (欧拉) 方程精确地逼近。控制这个逼近的一个关键的量是 Knudsen 数，它是气体平均自由程 (mean-free-path) 和系统的一个典型长度尺度之间的比。当 Knudsen 数很小时，Euler 方程是一个精确的逼近。在这个情形，单粒子分布函数在所谓的局部 Maxwell 分布的附近，而 Euler 方程通过将 Boltzmann 方程投影到它的 0 阶，1 阶，2 阶矩的迹上得到 [2]。

通过在投影模式中包含更多阶的矩，人们在拓展 Euler 或类 Euler 方程对于大的 Knudsen 数的有效性方面投入了大量的努力。这些努力遭遇到了两个主要的困难 [6]：

1. 得到的矩方程不是适定的。例如，众所周知 Grad 的 13 个矩方程在态空间的某些区域不是双曲的。
2. 封闭问题：为了得到封闭的方程组，人们需要近似出现在投影系统中的高阶矩项。对于大的 Knudsen 数，人们可以不再用局部 Maxwell 分布作为使系统封闭的假设。

在 Knudsen 数的一个较宽范围内机器学习对构造一致精确的 (广义) 矩模型提供了一些希望，如 [12] 中所展示的。这通过两步做到：

1. 学习一组能最好代表分布函数的广义矩。一个做到这个的方法是通过一个极小化分布

函数重构误差的自动编码器 (auto-encoder).

2. 学习这一组广义矩的动力学. 出现在动力学方程中的项都可以用分布函数表达. 可以通过监督学习 (supervised learning) 发现对这些项的逼近.

主要的问题还是如何保持物理上的对称性以及如何通过微观模型, 这里也就是 Boltzmann 方程, 来得到数据集. 与前面的例子对比, 这里我们有一个新的动力学对称性, Galileo (伽利略) 不变性. 事实上, 用机器学习的语言, 前面的例子是一个更传统地学习一个函数的例子; 当前的例子是关于学习一个新的动力系统. 初步的测试表明这个方法非常有前景 [12]. 这也是对没有尺度分离问题的多尺度模拟的一个例子.

3.3 高维偏微分方程组

高维中求解偏微分方程组是受困于维数灾的一个经典的例子. 但在线性抛物偏微分方程中找到了一个例外. 在此情形, 我们可以利用 Feynman-Kac (费因曼-卡茨) 公式 [14] 把解表示为一个 Brown (布朗) 路径泛函的期望, 再应用蒙特卡罗方法估计这个解. 对于非线性抛物偏微分方程组, Feynman-Kac 公式的类比以向后随机微分方程组 (backward stochastic differential equations, BSDEs) 表达 [14]. 这允许我们给出一个求解非线性抛物方程的算法, 其中在一个短时间段的离散集上解的梯度是通过神经网络近似的. 然后使用 BSDE 公式 (实际上是它的离散版本) 来估计在一个指定的时-空位置的解, 而近似解和给定终止 (或初始) 条件之间的偏差被用来作为损失函数以训练网络参数 [9]. 这个算法结果是非常成功的, 可以被用于求解一类广泛的相当高维的非线性抛物偏微分方程组和向后随机微分方程组. 一个副产品是向后随机微分方程, 一个对于金融, 经济, 随机控制和其它应用的优美的数学工具, 现在已经成为一个强大的实用工具.

已经在用于期权定价 (option pricing) 的非线性 Black (布莱克)-Scholes 方程组中找到了这些想法的一个应用, 比如对违约风险 (default risk).

3.4 自然语言的数学原理

机器学习的成功触发了语言学和自然语言处理 (natural language processing, NLP) 之间的一些冲突. 一方面, NLP 在机器翻译和其它实际任务中取得了众多令人赞叹的成功这一事实, 带来了关于语言学的实用价值的质疑. 另一方面, 关于机器学习方法的效率也产生了很多怀疑, 因为它需要海量的训练数据, 看起来远远比人类需要的多. 而且, NLP 算法的黑箱性质也是一个令人担心的问题. 因此发展能帮助弥合语言学和 NLP 之间的差异的自然语言定量的结构模型是值得做的.

除此之外, 自然语言的一个数学模型有它自己的价值. 例如, NLP 和语言学共同的一个重要的问题是语义学的定义. 为了处理这样的问题, 人们最终需要借助数学模型.

语言显示出若干尺度, 如词, 句子和段落. 不同的尺度需要不同的结构模型. 对如词和句子的这样较小的尺度, 不同的语言展现出宽泛的多样性和不规则性. 但是, 在较大尺度上, 不同的语言展现出显著的通用性. 这通用性是以语言之间可以被相互翻译这一事实为基础的 [11].

一个数学上吸引人的语义学的定义是, 它是翻译后不变的. 如果我们将翻译看成是不同语言之间的算子, 语义在翻译之后保持不变意味着不同语言的生成元都是相似的:

$$\mathbf{P}_A \mathbf{T}_{A \rightarrow B} = \mathbf{T}_{A \rightarrow B} \mathbf{P}_B.$$

这里 $\mathbf{P}_A$ 和 $\mathbf{P}_B$ 象征性地分别是语言 A 和 B 的生成元, $\mathbf{T}_{A \rightarrow B}$ 是翻译算子. 因此 $\mathbf{P}_A$ 和 $\mathbf{P}_B$ 的谱必定相同.

挑战在于把这些直觉上吸引人的陈述转换成数学模型. [11] 中做了最初的尝试. 除了确认上面描述的不变性的性质之外, 它还提供了一个看起来有可能抓住某些句际 (intersentence) 尺度的动力学的定量结构模型. 一个副产品是人们可以使用这个结构模型来发展具有最先进的性能, 但使用少得多训练样本的机器翻译算法 [11].

4. 机器学习的数学理论

我们将关注监督学习的问题, 对它们来说一个合理地清晰的数学图像正在出现. 但是我们相信这里讨论的思想应该能够应用到无监督 (unsupervised) 学习和加强 (reinforcement) 学习中.

简单地说, 监督学习的问题是用一个函数值的有限样本逼近一个给定的目标函数. 记目标函数为 $f^*: \mathbb{R}^d \rightarrow \mathbb{R}^1$, 并且令 $\{\mathbf{x}_j\}_{j=1}^n$ 为从 $\mathbb{R}^d$ 上的分布 μ 独立取样的一个数据集. 令 $y_j = f^*(\mathbf{x}_j)$, $j = 1, \dots, n$. 因为加入测量噪声一般不会本质上改变这个论证, 我们将为了叙述的清晰而忽略掉它. 我们的任务是要用 $S = \{\mathbf{x}_j, y_j\}_{j=1}^n$ 逼近 f^* . 这是通过如下步骤做到的:

1. 构造某“假设空间”(它是一组函数) $\mathcal{H}_m = \{f(\cdot, \theta)\}$. 这里 m 大致上是 $\mathcal{H}_m$ 的维数, θ 表示相应于 $\mathcal{H}_m$ 中一特定函数的参数.
2. 在假设空间上极小化“经验风险 (empirical risk)”:

$$\hat{\mathcal{R}}_n(\theta) = \frac{1}{n} \sum_j (f(\mathbf{x}_j, \theta) - y_j)^2 = \frac{1}{n} \sum_j (f(\mathbf{x}_j, \theta) - f^*(\mathbf{x}_j))^2.$$

假设空间典型的例子包括:

- 线性回归: $f(\mathbf{x}, \theta) = \beta \cdot \mathbf{x} + \beta_0$, $\theta = (\beta, \beta_0)$.
- 广义线性模型: $f(\mathbf{x}, \theta) = \sum_{k=1}^m c_k \phi_k(\mathbf{x})$, $\theta = \{c_1, c_2, \dots, c_m\}$, 其中 $\{\phi_k\}$ 是一组线性无关的函数.
- 两层神经网络: $f(\mathbf{x}, \theta) = \sum_k a_k \sigma(\mathbf{b}_k \cdot \mathbf{x} + c_k)$, $\theta = \{a_k, \mathbf{b}_k, c_k\}$, 其中 σ 是某非线性标量函数, 例如, $\sigma(z) = \max(z, 0)$.
- 深度神经网络 (DNN): 以上形式函数的复合.

函数逼近是经典数值分析和逼近论中研究得很好的课题. 标准的处理流程如下:

- 定义一个“适定的”数学模型. 这包括规定假设空间和损失函数. 例如, 在一维三次样条的情形, 假设空间由 C^1 分段三次多项式组成, 损失函数定义为

$$I_n(f) = \frac{1}{n} \sum_{j=1}^n (f(x_j) - y_j)^2 + \lambda \int |f''(x)|^2 dx.$$

- 认定正确的函数空间, 例如, Sobolev/Besov (索伯列夫 / 别索夫) 空间. 这些组成直接逼近定理和逆逼近定理 (又称为 Bernstein (伯恩斯坦) 和 Jackson (杰克逊) 型定理) 成立的函数空间; 也就是, 一个函数在某个函数空间内当且仅当它能够用一个具有一个指定精度的给定逼近方案所逼近.

- 推导最优误差估计. 有两种误差估计. 在先验估计中, 误差界依赖于目标函数的范数. 在后验估计中, 误差界依赖于数值逼近的范数. 例如, 分段线性有限元, 典型的先验估计和后验估计有如下的形式 ($\alpha = 1/d, s = 2$):

$$\|f_m - f^*\|_{H^1} \leq C m^{-\alpha} \|f^*\|_{H^s},$$

$$\|f_m - f^*\|_{H^1} \leq C m^{-\alpha} \|f_m\|_h.$$

这里 $\|\cdot\|_{H^s}$ 是 s 阶 Sobolev 范数, $\|\cdot\|_h$ 一般是一个网格依赖的范数 [1].

在这个经典设定和机器学习的设定之间有两个主要的差别. 第 1 个是, 在机器学习中, 我们必须处理非常高的维数. 我们已经可以看到上面的估计遭遇到了维数灾. 我们感兴趣的是没有这个问题的机器学习模型. 第 2 个是, 在机器学习中, 我们只有有限量的数据. 因而我们只能对经验风险做事. 但是我们所真正感兴趣的是总体风险 (population risk):

$$\mathcal{R}(\theta) = \mathbb{E}(f(\mathbf{x}, \theta) - f^*(\mathbf{x}))^2 = \int_{\mathbb{R}^d} (f(\mathbf{x}, \theta) - f^*(\mathbf{x}))^2 d\mu.$$

两者之间的差别, 有时被叫做泛化鸿沟 (generalization gap), 它是我们需要处理的另外一个关键问题. 事实表明, 维数灾的问题也出现在这里.

为理解领会这些问题, 让我们仔细检查广义线性模型的一个简单例子. 在这个例子中假设空间是

$$f(\mathbf{x}, \theta) = \sum_{k=1}^m a_k \phi_k(\mathbf{x}), \quad \theta = (a_1, a_2, \dots, a_m),$$

其中 $\{\phi_k\}$ 是一组线性无关函数. 我们来看 $m > n$ 时的情形. 在这个情形, 为了拟合数据, 即将经验风险降低到 0 (它的全局极小值), 只须选择参数 θ 满足

$$G\theta^T = \mathbf{y},$$

其中 $G = (\phi_k(\mathbf{x}_j))$, $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$. 这是未知数多于方程数的一个线性系统. 除非 G 是退化的, 否则它就有无限多个解. 但是你可以证明, 如果 θ 被选为上述系统具有最小 Euclid (欧几里得) 范数的解 [4], 则

$$\sup_{\|f\|_{\mathcal{B}_1} \leq 1} \inf_{h \in \mathcal{H}_m} \|f - h\|_{L^2(D_0)} \geq \frac{C}{dm^{1/d}},$$

显示出维数灾. 这里 $\mathcal{B}_1$ 是 [10] 中定义的 Barron 空间. 在这个情形, 尽管经验风险是 0, 总体风险还是可以相当大.

对于高维问题, 一个重要的基准是积分问题. 假设我们想要近似地估计积分

$$I(g) = \int g(\mathbf{x}) d\mu.$$

众所周知像 Simpson (辛普森) 法则这样的求积法则遇到了维数灾. 但是, 蒙特卡罗方法没有这个问题. 令 $\{\mathbf{x}_j, j = 1, 2, \dots, n\}$ 为一组从 μ 中抽取的独立随机变量, 并令

$$I_n(g) = \frac{1}{n} \sum_{j=1}^n g(\mathbf{x}_j).$$

则我们有恒等式

$$\mathbb{E}(I(g) - I_n(g))^2 = \frac{1}{n} \text{var}(g), \quad (1)$$

其中 $\text{var}(g) = \int_X g^2(\mathbf{x})d\mu - (\int_X g(\mathbf{x})d\mu)^2$. 注意到指数 n 不依赖于 d . 当然在典型的应用中, 比如说, 在统计物理学中, $\text{var}(g)$ 在高维中可以是非常大的. 由于这个原因, 在蒙特卡罗方法领域主要关注的是降低方差.

再回到泛化鸿沟, 有

$$\mathcal{R}(\hat{\theta}) - \hat{\mathcal{R}}_n(\hat{\theta}) = I(g) - I_n(g), \quad g(\mathbf{x}) = (f(\mathbf{x}, \hat{\theta}) - f^*(\mathbf{x}))^2,$$

其中 $\hat{\theta} = \text{argmin} \hat{\mathcal{R}}_n(\theta)$. 注意到在这个情形中, 函数 g 和数据是高度关联的; 因此恒等式 (1) 不成立. 一个限定泛化鸿沟的方法是估计 $I(g) - I_n(g)$ 在假设空间的上确界. 很自然, 这个量的尺度依赖于假设空间. 例如, 我们有:

- 对 Lipschitz (利普希茨) 函数 (这和 Wasserstein 距离有关)

$$\sup_{\|h\|_{Lip} \leq 1} |I(h) - I_n(h)| \sim \frac{1}{n^{1/d}},$$

- 对 [10] 中定义的 Barron 空间中的函数,

$$\sup_{\|h\|_{B_1} \leq 1} |I(h) - I_n(h)| \sim \frac{1}{\sqrt{n}}.$$

可以看到, 维数灾以另外一种形式 (也就是, 数据集的规模) 显示出来.

估计泛化鸿沟的一个重要的概念是 Rademacher (拉德马赫) 复杂度 [3]. 令 $\mathcal{H}$ 为一组函数, 并令 $S = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$ 为一组数据点. 那么 $\mathcal{H}$ 关于 S 的 Rademacher 复杂度定义为

$$\hat{\mathcal{R}}_S(\mathcal{H}) = \frac{1}{n} \mathbb{E}_\xi \left[\sup_{h \in \mathcal{H}} \sum_{i=1}^n \xi_i h(\mathbf{x}_i) \right],$$

其中 $\{\xi_i\}_{i=1}^n$ 是独立同分布的随机变量, 以等概率取值 ± 1 .

例如, 我们有

- 如果 $\mathcal{H} =$ Lipschitz 空间的单位球: $\hat{\mathcal{R}}_S(\mathcal{H}) \sim O(1/n^{1/d})$,
- 如果 $\mathcal{H} = C^0$ (连续函数空间) 中的单位球: $\hat{\mathcal{R}}_S(\mathcal{H}) \sim O(1)$,
- 如果 $\mathcal{H} =$ Barron 空间的单位球: $\hat{\mathcal{R}}_S(\mathcal{H}) \sim O(1/\sqrt{n})$.

最后一条是对于假设空间的 Rademacher 复杂度我们所能期望的最优尺度.

Rademacher 复杂度的重要性在于它从下和从上界定了我们所感兴趣的上确界 [3]: 给定一个函数类 $\mathcal{H}$, 对任意 $\delta \in (0, 1)$, 至少以概率 $1 - \delta$ 在随机样本 $S = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$ 上, 有

$$\begin{aligned} \sup_{h \in \mathcal{H}} \left| \mathbb{E}_{\mathbf{x}}[h(\mathbf{x})] - \frac{1}{n} \sum_{i=1}^n h(\mathbf{x}_i) \right| &\leq 2\hat{\mathcal{R}}_S(\mathcal{H}) + \sup_{h \in \mathcal{H}} \|h\|_\infty \sqrt{\frac{\log(2/\delta)}{2n}}, \\ \sup_{h \in \mathcal{H}} \left| \mathbb{E}_{\mathbf{x}}[h(\mathbf{x})] - \frac{1}{n} \sum_{i=1}^n h(\mathbf{x}_i) \right| &\geq \frac{1}{2}\hat{\mathcal{R}}_S(\mathcal{H}) - \sup_{h \in \mathcal{H}} \|h\|_\infty \sqrt{\frac{\log(2/\delta)}{2n}}, \end{aligned}$$

有了这些基础知识, 我们现在可以将所有的机器学习模型分为两类:

1. 有维数灾问题的模型: 泛化误差 $\geq O(m^{-\alpha/d})$ 或 $O(n^{-\beta/d})$. 维数灾可以来源于逼近误差 (右边第 1 项) 或泛化鸿沟 (右边第 2 项). 分段多项式逼近和固定基小波属于这一类.
 2. 没有维数灾问题的模型: 泛化误差 $\leq O(\gamma_1(f^*)/m + \gamma_2(f^*)/\sqrt{n})$.
- 3 个机器学习模型被认定在这一类:

- 随机特征模型 (random feature models): 令 $\{\phi(\cdot, \omega), \omega \in \Omega\}$ 为一组随机“特征”, 并以 π 表示随机变量 ω 的概率分布. 给定 ω 的任意独立同分布的实现 $\{\omega_j\}_{j=1}^m$, 有

$$\mathcal{H}_m(\{\omega_j\}) = \left\{ f_m(\mathbf{x}, \theta) = \frac{1}{m} \sum_{j=1}^m a_j \phi(\mathbf{x}; \omega_j) \right\}.$$

- 两层神经网络 (two-layer neural networks):

$$\mathcal{H}_m = \left\{ \frac{1}{m} \sum_{j=1}^m a_j \sigma(\mathbf{b}_j^T \mathbf{x} + c_j) \right\}.$$

- 残差神经网络 (residual neural networks): $\mathcal{H}_m = \{f(\cdot, \theta) = \alpha \cdot \mathbf{z}_{L,L}(\cdot)\}$:

$$\mathbf{z}_{l+1,L}(\mathbf{x}) = \mathbf{z}_{l,L}(\mathbf{x}) + \frac{1}{L} U_l \sigma \circ (w_l \mathbf{z}_{l,L}(\mathbf{x})), l = 0, \dots, L-1, \quad \mathbf{z}_{0,L}(\mathbf{x}) = V\mathbf{x}.$$

这里 L 是神经网络的深度.

为了识别这些模型, 我们按以下步骤做 [10]:

1. 通过某个大数定律将目标函数表达为一个期望. 对随机特征模型和两层神经网络模型这是直接的. 对于残差网络模型, 这是 [10] 中建立的“复合的大数定律 (compositional law of large numbers)”.
2. 通过证明相应的中心极限定理对逼近误差建立收敛速率. 再次, 对于前两个模型这是标准的, 但是对于残差神经网络还需要一些工作.
3. 估计 Radamacher 复杂度. 事实表明对于所有的 3 个模型, Radamacher 复杂度作为数据集规模的一个函数具有最优尺度.

在这个过程中, 也就识别出了相应于机器学习模型正确的函数空间. 对于随机特征模型, 这是相应的再生核 Hilbert (希尔伯特) 空间. 对于两层神经网络和残差神经网络模型, 这分别是 [10] 中定义的 Barron 空间和复合函数空间 (compositional function space).

一个推论是人们可以很容易地证明, 对这些模型适当正则化的形式, 泛化误差的先验误差估计是维数无关的 (类蒙特卡洛的).

要为机器学习建立一个坚实的数学基础, 还有非常多的工作要做. 但是, 很清楚的是这些问题的本质主要在数值分析. 新的曲折在于维数很高, 并且模型可能在参数多于数据的意义下被过分参数化.

5. 结论

我所提及的只是正来临的巨大冰山的一角. 我们正处在一场新的科学革命的边缘, 它将不只影响科学, 还将根本性地影响数学和应用数学. 特别地,

- 将机器学习 (代表 Kepler (开普勒) 范式) 和基于第一性原理的物理学模型 (代表 Newton 范式) 相结合, 为科学研究开辟了新的和强有力的范式. 应用数学是这种结合最自然的平台.
- 要建立机器学习的理论基础, 人们必须发展高维数值分析.

如果对于这些断言的例证还不是足够有力, 更有力的例证将以惊人的速度不断展现. 很难想象还有比摆在我们面前的机会更好的发展应用数学的机遇了.

致谢 (略)

参考文献

- [1] Ainsworth M and Oden JT, *A Posteriori Error Estimation in Finite Element Analysis*, Wiley, 2000. MR1885308
- [2] Bardos C, Golse F and Levermore D, Fluid dynamic limits of kinetic equations. I. Formal derivations, *J. Statist. Phys.*, Vol. 63, No. 1/2, 1991. MR1115587
- [3] Bartlett PL and Mendelson S, Rademacher and Gaussian complexities: risk bounds and structural results, *J. Mach. Learn. Res.*, 3(Nov): 463–482, 2002. MR1984026
- [4] Barron AR, Universal approximation bounds for superpositions of a sigmoidal function, *IEEE Trans. Inform. Theory* 39(3): 930–945, 1993. MR1237720
- [5] Behler J and Parrinello M, Generalized neural-network representation of high-dimensional potential-energy surfaces, *Phys. Rev. Lett.* 98, 146401, 2007.
- [6] Cai ZN, Fan YW and Li R, Globally hyperbolic regularization of Grad’s moment system in one dimensional space, *Comm. Math. Sci.* 11(2), 2012, pp. 547–571. MR3002565
- [7] Dirac PA, Quantum mechanics of many-electron systems, *Proc. Roy. Soc. London. Series A*, Vol. 123, No. 792, 1929.
- [8] E W, *Principles of Multiscale Modeling*, Cambridge University Press, 2011. MR2830582
- [9] E W, Han J, and Jentzen A, Deep learning-based numerical methods for high-dimensional parabolic partial differential equations and backward stochastic differential equations, *Comm. Math. Stats.*, vol. 5, no. 4, pp. 349–380, 2017. MR3736669
- [10] E W, Ma C, and Wu L, Barron spaces and the compositional function spaces for neural network models, [arXiv.org/abs/1906.08039](https://arxiv.org/abs/1906.08039), 2019.
- [11] E W and Zhou Y, A mathematical model for linguistic universals, [arXiv.org/abs/1907.12293](https://arxiv.org/abs/1907.12293), 2019.
- [12] Han J, Ma C, Ma Z, and E W, Uniformly accurate machine learning based hydrodynamic models for kinetic equations, [arXiv:1907.03937](https://arxiv.org/abs/1907.03937), 2019.
- [13] Parr RG and Yang W, *Density-Functional Theory of Atoms and Molecules*, Oxford Science Publications, 1989.
- [14] Pardoux E and Peng SG, Adapted solution of a backward stochastic differential equation, *Systems Control Lett.*, Vol. 14, Issue 1, 1990. MR1037747
- [15] Van Dyke M, *Perturbation Methods in Fluid Mechanics*, annotated edition, Parabolic Press, 1975. MR0416240
- [16] Wang H, Zhang LF, Han J, and E W, DeePMD-kit: A deep learning package for many-body potential energy representation and molecular dynamics, *Comput. Phys. Comm.*, vol. 228, p. 178–184, 2018. <https://github.com/deepmodeling/deepmd-kit>.
- [17] Zhang L, Han J, Wang H, Saidi W, Car R, and E W, Endto- end symmetry preserving inter-atomic potential energy model for finite and extended systems, NIPS, 2018.
- [18] Zhang L, Wang H, Car R, and E W, Active learning of uniformly accurate inter-atomic potentials for materials simulation, [arXiv:1810.11890](https://arxiv.org/abs/1810.11890), 2018.

(龚雪飞 译 陆柱家 校)