

统计数值逼近

Houman Owhadi Clint Scovel Florian Schäfer

虽然传统上认为数值逼近 (numerical approximation) 和统计推理 (statistical inference) 是两个完全不同的学科, 但它们通过使用部分信息进行估计这个共同目标被紧密相连. 当前, 这个共同的目标激发我们对求解偏微分方程的统计推理 / 机器学习方法 [8, 13], 线性代数中随机化算法的使用 [2], 不确定性量化中数值误差与建模误差的融合 [3] 越来越感兴趣. 虽然这些兴趣可能被认为是最近的一种现象, 但是数值逼近和统计推理之间的相互影响由来已久. 事实上, 它们可以追溯到 Poincaré (庞加莱) 的概率论课程 (1896) 和 Sul'din [19], Palasti 和 Rényi (雷尼) [12], Sard (萨德) [14], Kimeldorf 和 Wahba [4] (关于 Bayes (贝叶斯) 估计与样条平滑 / 插值之间的对应关系) 以及 Larkin [5] (关于 Gauss (高斯) 过程回归与数值逼近之间的对应关系) 的开创性研究. 虽然他们的研究最初“很少引起数值分析家的注意” [5], 但其在基于信息的复杂度 (IBC) [20], Bayes 数值分析 [1], 以及最近的概率数字 [3] 中得到复兴. 这篇简短的综述邀请大家从 [10] 中提出的对策 / 决策论的结合视角来探讨这些联系. 其动机来自这些交叉不仅仅是好奇的研究对象, 而且构成了一条简单解决这两个领域的基本问题的途径.

1. 将已知函数建模为随机过程的实例

在 [1] 中, Diaconis 提出了数值分析和 Bayes 推理之间简单但引人注目的关系: 对于给定的函数 u (如 $u(t) = te^{\sin \sqrt{t}}$), 考虑计算问题

$$\int_0^1 u(t) dt. \quad (1)$$

虽然函数 u 是完全已知的, 但它没有简明的原函数, 且该函数的积分需通过在有限点 (如 $t_i = \frac{i}{N}, i \in \{0, 1, \dots, N\}$) 上估计 u 和利用求积公式 (如 $\int_0^1 u(t) dt \approx \sum_{i=1}^N \frac{u(t_i) + u(t_{i-1})}{2} \Delta t$, $\Delta t = 1/N$) 进行数值逼近. 意外的是, 如果我们假设 u 是由 Brown (布朗) 运动 B_t 生成的, 使用条件期望 $\mathbb{E}[\int_0^1 B_t dt | B_{t_i} = u(t_i), \forall i]$ 逼近 $\int_0^1 u(t) dt$, 我们重新发现梯形求积法则. 此外, 假设 u 由 Brown 运动的积分所生成, 则得到高阶求积法则.

虽然这种将一个完全已知的函数建模为随机过程样本的方法似乎违反常理, 但是可以在基于信息的复杂度 (information-based complexity, 缩写 IBC) [20] 中找到能够理解它的自然框架, 计算复杂度的分支建立在数值实现需要在部分信息和有限资源下进行计算这一观察结论上. 在 IBC 中, 对不完全信息操作的算法的性能可以在关于缺失信息的最坏情况

译自: Notices of the AMS, vol. 66 (2019), no. 10, p. 1608–1617, Statistical Numerical Approximation, Houman Owhadi, Clint Scovel, and Florian Schäfer, figure number 15. Copyright © the American Mathematical Society 2019. All rights reserved. Reprinted with permission. 美国数学会与作者授予译文出版许可.

Houman Owhadi 是加州理工学院应用与计算数学以及控制与动力系统的教授, 他的邮箱地址是 owhadi@caltech.edu.

Clint Scovel 是加州理工学院的助理研究员, 他的邮箱地址是 clintscovel@gmail.com.

Florian Schäfer 是加州理工学院应用与计算数学的研究生, 他的邮箱地址是 Florian.Schaefer@caltech.edu.

或平均情况 (随机化) 设置下进行分析. 此外, 正如 Packel [11] 所观察到的, 平均情况设置可以解释为对抗性对策中的混合策略, 该对抗性对策通过将 (最坏情况) 极小化极大问题提升为混合 (随机化) 策略上的极小化极大问题来得到的. 这一观察结果开启了 [9, 10] 数值逼近和 Wald (瓦尔德) 决策论之间的自然联系, 显然其受到 von Neumann (冯·诺伊曼) 对策论的影响.

2. 最优恢复和 Gauss 过程回归

Micchelli 和 Rivlin [7] 的最优恢复框架从对策论的视角为展示数值逼近 (numerical approximation, 缩写 NA) 和 Gauss 过程回归 (Gaussian process regression, 缩写 GPR) 之间的对应关系提供一个自然环境. 考虑 Banach (巴拿赫) 空间 $\mathcal{B}$, 记 $[\cdot, \cdot]$ 为 $\mathcal{B}$ 和其对偶空间 $\mathcal{B}^*$ 的对偶乘积. 当 $\mathcal{B}$ 为无限 (或者高) 维时, 不能用 $u \in \mathcal{B}$ 直接计算, 只能用 u 的有限个特征 (features) 来计算. 我们在这里考虑的特征类型被表示为向量 $\Phi(u) := ([\phi_1, u], \dots, [\phi_m, u])$, 它对应 m 个线性无关的测量 (measurements) $\phi_1, \dots, \phi_m \in \mathcal{B}^*$. 其目的是从特征 (feature) 向量 $\Phi(u)$ 包含的部分信息中恢复 / 近似 u . 为了量化恢复中的误差, 令 $Q: \mathcal{B}^* \rightarrow \mathcal{B}$ 是一个对称且正的一一映射, 即对于 $\phi, \varphi \in \mathcal{B}^*$, 有 $[\phi, Q\varphi] = [\varphi, Q\phi]$ 且 $[\phi, Q\phi] \geq 0$, 赋予 $\mathcal{B}$ 由 $\|u\|^2 := [Q^{-1}u, u]$ 定义的二次范数 $\|\cdot\|$. 然后, 利用 $\|\cdot\|$ -范数中的相对误差作为损失, 经典的数值分析方法是用

$$\min_{\nu} \max_u \frac{\|u - \nu(\Phi(u))\|}{\|u\|} \quad (2)$$

的最小化子 $\nu^\dagger$ 来近似 u . m 个线性测量所有可能函数的极小值为

$$\nu^\dagger = \sum_{i=1}^m [\phi_i, u] \psi_i, \quad (3)$$

其中 $\mathcal{B}$ 的元素

$$\psi_i := \sum_{j=1}^m \Theta_{i,j}^{-1} Q\phi_j, \quad i \in \{1, \dots, m\}, \quad (4)$$

称为最优恢复样条函数, 它是利用由 $\Theta_{i,j} := [\phi_i, Q\phi_j]$ 定义的 Gram (格拉姆) 矩阵 Θ 的逆矩阵 Θ^{-1} 的元素 $\Theta_{i,j}^{-1}$ 来定义的.

极小化极大问题 (2) 可以看作是对抗性的零和对策

$$\begin{array}{ccc} \text{(Player I)} & u \in \mathcal{B} & \\ & \searrow & \swarrow \\ & \max & \min \\ & \searrow & \swarrow \\ & \frac{\|u - \nu(\Phi(u))\|}{\|u\|} & \end{array} \quad \begin{array}{c} v \text{ (Player II)} \\ \\ \\ \\ \end{array} \quad (5)$$

其中局中人 (Player) I 选择线性空间 $\mathcal{B}$ 中的一个元素 u , 局中人 II (他 / 她看不到 u) 必须根据看到的 u 的有限个线性测量 $\Phi(u)$ 来逼近局中人 I 的选择.

函数 $(u, \nu) \mapsto \frac{\|u - \nu(\Phi(u))\|}{\|u\|}$ 没有鞍点, 因此, 就像 von Neumann 的对策论那样, 我们可通过引入混合/随机化策略, 以及将问题提升到局中人 I 和局中人 II 所有可能选择的概率测度, 来将极小化极大解确定为鞍点. 为阐明最优策略, 观察到具有协方差算子 Q 的中心 Gauss 场 ξ (记 $\xi \sim \mathcal{N}(0, Q)$) 从 $\mathcal{B}^*$ 映射到中心 Gauss 随机变量的空间是等距映射, 使得

$$[\phi, \xi] \sim \mathcal{N}(0, \|\phi\|_*^2), \quad \phi \in \mathcal{B}^*,$$

其中 $\|\cdot\|_*$ 是 $\|\cdot\|$ 的对偶范数, 通过 $\|\phi\|_* = \sup_{\nu \in \mathcal{B}} [\phi, \nu] / \|\nu\| = [\phi, Q\phi]^{\frac{1}{2}}$ 定义. 对于对策 (5) 的升级版, 局中人 I 的最优策略为中心 Gauss 场 $\xi \sim \mathcal{N}(0, Q)$, 局中人 II 的最优策略为由其条件期望

$$\nu^\dagger = \mathbb{E}[\xi | [\phi_i, \xi] = [\phi_i, u] \text{ 对所有 } i] \quad (6)$$

定义的纯 (确定性) 策略, 该条件期望等于最优恢复解 (3). 最优恢复样条函数 (4) 也可以被解释为对策中的基本赌博 / 赌注

$$\psi_i = \mathbb{E}[\xi | [\phi_j, \xi] = \delta_{i,j} \text{ 对所有 } j], \quad (7)$$

我们称之为参加竞争的 对策基 (gamblets). 这里局中人 II 的最优策略之所以是纯策略是因为 $\|\cdot\|$ 是凸的, 而局中人 I 的最优策略之所以是 Gauss 的是因为 $\|\cdot\|$ 是二次的.

作为对此方法的说明, 再次考虑与计算 $\int_0^1 u(t)dt$ 相关的数值求积问题. 取 $\mathcal{B} = \mathcal{H}^1[0, 1]$, 它具有二次范数 $\|u\|^2 := (u(0))^2 + \int_0^1 \left(\frac{du(t)}{dt}\right)^2 dt$, 利用 $\|\cdot\|$ -范数的相对误差作为损失, 考虑从不完全测量 $u(t_i) (= \int_0^1 u\phi_i, \phi_i = \delta(\cdot - t_i))$ 中恢复 $u \in \mathcal{B}$ 的问题. 则由范数 $\|\cdot\|$ 定义的 Gauss 场 ξ 是缩放和平移的 Brown 运动, 且 (6) 产生一个在最优恢复 (最坏情况) 意义和对策论意义上都是最优的近似值, 用最优估计 u 的积分确定 [7] 积分的最优恢复估计. 通过观察到样条函数 (7) 为一般的分段线性三角基函数和 (6) 为 u 的分段的线性插值, 利用

$$\int_0^1 u(t)dt \approx \int_0^1 \mathbb{E}[\xi | [\phi_i, \xi] = [\phi_i, u] \text{ 对所有 } i],$$

这重新得到了梯形法则.

3. Sobolev 空间的设置

这些相互作用为数值逼近和 Gauss 过程回归中的经典问题提供了简单的求解方法, 我们将在线性算子

$$\mathcal{L} : \mathcal{H}_0^s(\Omega) \rightarrow \mathcal{H}^{-s}(\Omega) \quad (8)$$

的设置中说明这一点, 该算子将 Sobolev (索伯列夫) 空间 $\mathcal{H}_0^s(\Omega)$ 映射到其对偶空间 $\mathcal{H}^{-s}(\Omega)$, 其中 $s, d \in \mathbb{N}^*$, $\Omega \subset \mathbb{R}^d$ 是正则且有界域. 设 $\mathcal{L}$ 是一个任意对称的 ($\int_\Omega u\mathcal{L}\nu = \int_\Omega \nu\mathcal{L}u$), 正的 ($\int_\Omega u\mathcal{L}u \geq 0$) 和局部的 (若 u 和 ν 有不相交支集, 则 $\int_\Omega u\mathcal{L}\nu = 0$) 线性一一映射. 记 $[\phi, u] := \int_\Omega \phi u$ 为 $\phi \in \mathcal{H}^{-s}(\Omega)$ 和 $u \in \mathcal{H}_0^s(\Omega)$ 的对偶乘积. 设 $\mathcal{B}$ 为 Sobolev 空间 $\mathcal{H}_0^s(\Omega)$, 它具有二次能量范数 $\|u\|^2 := [\mathcal{L}u, u]$. 当 $s > d/2$ 时, $\mathcal{L}$ 的 Green (格林) 函数 G 是一个定义明确的连续对称正定核, 我们可以考虑具有协方差函数 G 的中心 Gauss 过程 ξ (图 1).

根据未知元素 $u \in \mathcal{H}_0^s(\Omega)$ 在诸点 $x_1, \dots, x_m$ (图 2) 处的值, 考虑寻找其近似值的问题. 然后, 利用 $\|\cdot\|$ 中的相对误差, 如同 (2), 作为损失, 可以通过调节 Gauss 过程 ξ 关于 u 在点 $x_1, \dots, x_m$ 的值, 在 (6) 中获得 u 的极小化极大恢复, 最优解 (3) 对应公式

$$\nu^\dagger(x) = \sum_{i,j=1}^m u(x_i) \Theta_{i,j}^{-1} G(x_j, x), \quad (9)$$

其中 $\Theta_{i,j}^{-1}$ 是由 $\Theta_{i,j} := G(x_i, x_j)$ 定义的核矩阵 Θ 的逆矩阵




图 1 对于 $s > d/2$, ξ 为 Ω 上一个具有协方差函数 $\mathbb{E}[\xi(x)\xi(y)] = G(x, y)$ 的中心 Gauss 过程, 其中 G 为算子 $\mathcal{L}$ 的 Green 函数 [10]

Θ^{-1} 的第 (i, j) 项. 出人意料的是, 由于

$$|u(x) - \nu^\dagger(x)| \leq \sigma(x) \|u\|, \quad \text{对所有 } x, \quad (10)$$

诸点 x_i 处的加在 ξ 值上条件的 $\xi(x)$ 的标准偏差 $\sigma(x)$ 也界定了确定性插值误差 ($\sigma(x)$ 用 $\sigma^2(x) := G(x, x) - \sum_{i,j=1}^m \Theta_{i,j}^{-1} G(x, x_j) G(x, x_i)$ 表示). 在径向基函数插值 (radial basis function interpolation) 中 (其中条件方差 $\sigma^2(x)$ 被称为功效函数 (power function)), 通过将 $(\mathcal{H}_0^s(\Omega), \|\cdot\|)$ 确认为具有再生核 G 的一个再生核 Hilbert (希尔伯特) 空间 (reproducing kernel Hilbert space, 缩写 RKHS) 获得了如 (10) 的估计. 在 RKHS 框架中, $\nu^\dagger$ 被确定为 $\nu \in \mathcal{H}_0^s(\Omega)$ 上且对所有 i 满足 $\nu(x_i) = u(x_i)$ 的 $\|\nu\|$ 的极小化子, 由表示定理, 可以表示为 (3) (即 $\nu^\dagger(x) = \sum_{j=1}^m c_j G(x_j, x)$, c_i 由强加的插值约束对所有 i 有 $\nu^\dagger(x_i) = u(x_i)$ 来获得). 在正则化和学习理论中, 通过在 $\nu \in \mathcal{H}_0^s(\Omega)$ 上极小化 $\sum_{i=1}^m (y_i - \nu(x_i))^2 + \lambda \|\nu\|^2$, 这种恢复方法自然被推广到数据 $u(x_i)$ 的有噪声观测值 y_i 中 (相当于在 $y_i = u(x_i) + Z_i$ 上调节 ξ , 其中 Z_i 是具有方差 λ 的独立同分布 (i.i.d.) 的中心 Gauss 随机变量).

当 $s \leq d/2$ 时, $\mathcal{L}$ 的 Green 函数 G 在分布意义上存在, 且 $\xi \sim \mathcal{N}(0, \mathcal{L}^{-1})$ 在弱意义上定义为 Gauss 场; 也就是说, 对检验函数 $\phi \in \mathcal{H}^{-s}(\Omega)$ 的积分后, 有 $\int_\Omega \xi \phi \sim \mathcal{N}(0, \int_{\Omega^2} \phi(x) G(x, y) \phi(y) dx dy)$. 图 3 展示了具有一致椭圆的, 有界的和粗糙传导率 $a(x)$ 的散度型椭圆算子 $\mathcal{L} := -\text{div}(a \nabla \cdot)$ 的 ξ 的实例.

4. 数值均匀化

考虑确定 m 个基函数的问题, 使得 (i) 尽可能精确地逼近 $\mathcal{L}$ 的解空间 $\mathcal{L}^{-1}(L^2(\Omega))$ 和 (ii) 尽可能地局部化. 这个被称为数值均匀化的问题并非无足轻重, 因为条件 (i) 和 (ii) 是相悖的. 事实上, 关于精确度的最优基函数是与 $\mathcal{L}$ 的最小本征值相关的本征函数, 它们是非局部的. 调整 (7) 中的 Gauss 过程 ξ , 与粗糙多调和样条函数和变分多尺度 /LOD 基函数 [6] 的推广 [8] 一起, 对该问题提供了一个简单的解决方法 [9, 10].

给定 $h > 0$ 和 $\delta \in (0, 1)$, 划分 Ω 为子集 $\tau_1, \dots, \tau_m$, 使得每个子集 τ_i 被包含于一个以 x_i 为球心, 以 $\delta^{-1}h$ 为半径的球中, 且包含一个以 δh 为半径的球 (图 4). 令 $\phi_i := 1_{\tau_i} / \sqrt{|\tau_i|}$




图 4 τ_i 和 x_i . h 与 τ_i 的大小有关, δ^{-2} 和它们的纵横比有关 [10]




图 5 左图: ψ_i . 右图: ψ_i 的 x 轴的切片 [10]




图 2 Ω 和 $x_1, \dots, x_m$ [10]




图 3 模拟 Gauss 场 ξ [10]

是 τ_i 的加权指示函数, 其中 $|\tau_i|$ 是 τ_i 的体积, 或者, 对于 $s > d/2$, 令 $\phi_i := h^{d/2}\delta(\cdot - x_i)$ 是在 x_i 处标度的 Dirac (狄拉克) δ 函数. 在 (4) 和 (7) 中定义和图 5 所展示的样条函数 ψ_i 与 m 个最小本征值相关的 $\mathcal{L}$ 的本征函数在相差一个乘性常数¹⁾的意义下达到相同的精度, 即对于 $f \in L^2(\Omega)$ ($h \approx m^{-\frac{1}{d}}$), 有

$$\inf_{v \in \text{span}\{\psi_1, \dots, \psi_m\}} \|\mathcal{L}^{-1}f - v\|_{\mathcal{H}_0^s(\Omega)} \leq Ch^s \|f\|_{L^2(\Omega)},$$

并且它们是指数局部化的, 即

$$\|\psi_i\|_{\mathcal{H}^s(\Omega \setminus B(x_i, nh))} \leq Ch^{-s}e^{-n/C}. \tag{11}$$

当 $\mathcal{L}$ 是 Laplace (拉普拉斯) 算子的幂 (即 $\mathcal{L} = \Delta^s$), 且 ϕ_i 是 (未标度的) Dirac δ 函数时, ψ_i 给出了 Harder 和 Desmarais (1972) 以及 Duchon (1977) 的多调和样条函数和 Schoenberg [16] 的基数 (cardinal) 样条函数的推广. 事实上, 当 $d = 1$ 且诸 x_i 在实直线的网格 $\mathbb{Z}$ 上, 表达式 (4) 用基数样条 [16] 来确定 ψ_i (基数样条函数由在诸点 x_i 的补集上 $\psi_i(x_j) = \delta_{i,j}$, $\frac{d^{2s}\psi_i}{dx^{2s}} = 0$ 和 ψ_i 的 $2s - 2$ 阶导数的连续性所刻画). 此外, 当 $d \geq 1$ 时, 最优恢复样条函数 (4) 的一般变分表述

$$\psi_i = \text{极小化论证} \begin{cases} \text{极小化 } \|\psi\|, \\ \text{满足 } \psi \in \mathcal{B} \text{ 和 } [\phi_j, \psi] = \delta_{i,j}, \quad \forall j \end{cases} \tag{12}$$

用多调和样条函数确定 ψ_i , 并且, 正如 Madych 和 Nelson (1990) 所观察到的, 也将多调和样条函数视为基数样条函数的多元推广.

5. 屏蔽效应

上述指数衰减的一些结果还提供了一种已知现象的证明, 在 Kriging 和地质统计学中该现象称为 屏蔽效应 (screening effect) [17]. 启发式的观点 (对于 $s > d/2$) 是, 尽管由于 Green 函数 $G(x, y)$ 对 x 和 y 之间的距离而言缓慢衰减, 导致 $\xi(x)$ 和 $\xi(y)$ 显著相关 (图 1), 但调整点之间的场值之后, 它们几乎是独立的. 对于均匀间隔的点, 这种效应是由以下的对策基指数衰减得到的. 记 $\text{Cor}(X, Y | \cdot)$ 为随机变量 X 和 Y 之间的条件相关性, 以及 $\langle u, v \rangle := \int_{\Omega} u \mathcal{L} v$ 为能量标量积. 那么利用 $\phi_i := \delta(\cdot - x_i)$, 一般恒等式

$$\text{Cor}([\phi_i, \xi], [\phi_j, \xi] | [\phi_l, \xi] \text{ 对 } l \neq i, j) = -\frac{\langle \psi_i, \psi_j \rangle}{\|\psi_i\| \|\psi_j\|}$$

即为随机变量 $\xi(x_i)$ 和 $\xi(x_j)$ 的相关性, 该相关性取决于对所有 $l \neq i, j$ 的 $\xi(x_l)$ 值 (图 6) 以及对策基 ψ_i 和 ψ_j 夹角的负余弦. 结合指数衰减 (11), 这就导致

$$|\text{Cor}(\xi(x_i), \xi(x_j) | \xi(x_l) \text{ 对 } l \neq i, j)| \leq Ce^{-C^{-1} \frac{|x_i - x_j|}{h}}.$$

6. 算子适应小波

考虑在下述意义下识别适应于算子 $\mathcal{L}$ 的小波的问题, 即在这些小波形成的基中, $\mathcal{L}$ 的矩阵表示是具有一致良态 (uniformly well-conditioned) 和稀疏块 (sparse blocks) 的对角块




图 6 对任意 $l \neq i, j$, 给定 $\xi(x_l)$, 考虑 $\xi(x_i)$ 和 $\xi(x_j)$ 的相关性 [10]

1) 全文中, 记 C 为仅依赖 $\Omega, s, d, \delta, h, \|\mathcal{L}\|$ 和 $\|\mathcal{L}^{-1}\|$ 的常数. —— 原注

的 (图 7). 这些小波具有的 3 个相应性质为:

(i) 能量量级跨标度正交性; (ii) 每个子带 (sub-band) 内算子条件数的一致有界性, 即能量范数下一致 Riesz (里斯) 稳定性; (iii) 指数衰减. 如 [18] 所述, 尽管已构造了实现其中两个性质的适应小波, 但“在一般情形, 是否有一种实用的技术同时保证这 3 个性质”尚不可知 [18, 第 83 页].




图 7 $\mathcal{L}$ 在全适应小波有限元基中矩阵表示 [10]

我们现在利用对策 (5) 的基本投注的构造, 提出这个问题的一个解 [9, 10, 15], 如图 8 所示. 首先, 构造 $\mathcal{H}^{-s}(\Omega)$ 的线性嵌套元素的一个分层

$$\phi_i^{(k)} = \sum_{j \in \mathcal{I}^{(k+1)}} \pi_{i,j}^{(k,k+1)} \phi_j^{(k+1)}, \quad (13)$$




图 8 算子适应小波结构纵览 [10]

用于表示复杂性水平在一个分层上的计算过程. 图 8 展示了当这些元素被选择为图 9 的 Haar (哈尔) 预小波 $\phi_i^{(k)} := 1_{\tau_i^{(k)}} / \sqrt{|\tau_i^{(k)}|}$ 时的这个解.

为了构造这些 Haar 预小波, 设 $q \in \mathbb{N}^* \cup \{\infty\}$ 和 $h, \delta \in (0, 1)$. 用 k 作为尺度的指标和 $i \in \mathcal{I}^{(k)}$ 作为位置的指标, 并令诸 $\tau_i^{(k)}$ 是 Ω 的一些子集, 使得 (a) 每个 $\tau_i^{(k)}$ 包含一个半径为 δh^k 的球, 并被包含于一个半径为 $\delta^{-1} h^k$ 的球中, (b) $(\tau_i^{(k)})_{i \in \mathcal{I}^{(k)}}$ 形成 Ω 的一个划分, 以及 (c) $(\tau_i^{(k+1)})_{i \in \mathcal{I}^{(k+1)}}$ 形成 $(\tau_i^{(k)})_{i \in \mathcal{I}^{(k)}}$ 的一个子划分. 现在考虑一个降级 (downscaling) 对




图 9 子集 $\tau_i^{(k)}$. 选取 $h := \frac{1}{2}$ 和 $\delta := \frac{1}{2}$ [10]

1) 令用于标记嵌套子集 $(\tau_i^{(k)})_{i \in \mathcal{I}^k, k \in \{1, \dots, q\}}$ 的标签集 $\mathcal{I}^{(k)}$, 被选择为形如 $i = (i_1, \dots, i_k)$ 的 k 维数组的有限集. —— 原注

策, 局中人 I 选择一个未知元素 $u \in \mathcal{H}_0^s(\Omega)$, 而局中人 II 在看到 k 层测量 $([\phi_i^{(k)}, u])_{i \in \mathcal{I}^{(k)}}$ 后必须近似 u . 利用 $\|\cdot\|$ 范数中的相对误差作为损失, 通过调节 $\xi \sim \mathcal{N}(0, \mathcal{L}^{-1})$ 和这些分层测量所产生的滤过下形成的鞅, 得到了局中人 II 的最优投注序列 $u^{(k)} = \mathbb{E}[\xi | [\phi_i^{(k)}, \xi] = [\phi_i^{(k)}, u], \forall i \in \mathcal{I}^{(k)}]$. 关于基本测量 $[\phi_i^{(k)}, \xi] = \delta_{i,j}$ 调节 ξ (图 8 的上半部分从左到右的转换中表示) 产生基本投注分层或对策基

$$\psi_i^{(k)} := \sum_{j \in \mathcal{I}^{(k)}} \Theta_{i,j}^{(k),-1} \mathcal{L}^{-1} \phi_j^{(k)}, \quad i \in \mathcal{I}^{(k)}, \quad (14)$$

它作为适应 $\mathcal{L}$ 的预小波而作用, 在图 10 中更详细地被展示. 在 (14) 中, $\Theta_{i,j}^{(k),-1}$ 是其元素为 $\Theta_{i,j}^{(k)} = \int \phi_i^{(k)} \mathcal{L}^{-1} \phi_j^{(k)}$ 的 $\Theta^{(k)}$ 的逆 $\Theta^{(k),-1}$ 的第 (i, j) 个系数.

$\phi_i^{(k)}$ 的嵌套意味着 $\psi_i^{(k)}$ 的嵌套. 更具体地说, 我们得到

$$\psi_i^{(k)} = \sum_{j \in \mathcal{I}^{(k+1)}} R_{i,j}^{(k,k+1)} \psi_j^{(k+1)}, \quad i \in \mathcal{I}^{(k)}, \quad (15)$$

其中插值矩阵 $R^{(k,k+1)}$ 有元素

$$R_{i,j}^{(k,k+1)} = \mathbb{E}[[\phi_j^{(k)}, \xi] | [\phi_l^{(k-1)}, \xi] = \delta_{i,l}, l \in \mathbb{R}^{\mathcal{I}^{(k-1)}}],$$

在升级 (upscaling) 对策中, 对 $l \in \mathcal{I}^{(k-1)}$, 给定 $[\phi_l^{(k-1)}, u] = \delta_{i,l}$, 被确定为局中人 II 在 $[\phi_j^{(k)}, u]$ 上的最优投注. 由于对应的线性空间

$$\Psi^{(k)} := \text{span}\{\psi_i^{(k)} | i \in \mathcal{I}^{(k)}\}$$

满足嵌套关系 $\Psi^{(k)} \subset \Psi^{(k+1)}$, 在需要讨论的条件下, $\Psi^{(k-1)}$ 在 $\Psi^{(k)}$ 中的 $\langle \cdot, \cdot \rangle$ 正交补

$$\Psi^{(k)} = \Psi^{(k-1)} \oplus \mathfrak{X}^{(k)}$$

与算子适应小波

$$\mathcal{X}_i^{(k)} := \sum_{j \in \mathcal{I}^{(k)}} W_{i,j}^{(k)} \psi_j^{(k)}, \quad i \in \mathcal{J}^{(k)} \quad (16)$$

的张成

$$\mathfrak{X}^{(k)} = \text{span}\{\mathcal{X}_i^{(k)} | i \in \mathcal{J}^{(k)}\}$$

相同, 这些小波是通过取预小波 $\psi_i^{(k)}$ 的局部差而得到的. 从最优恢复样条 $\psi_i^{(k)}$ 到算子适应小波 $\mathcal{X}_i^{(k)}$ 的转变由图 8 右半部分从上到下的转变所表示, 在图 11 中有更详细的说明. 在这里, 使用 $\mathcal{J}^{(k)}$ 来标记 ¹⁾ 元素 $\mathcal{X}_i^{(k)}$, $W^{(k)}$ 是 $\mathcal{J}^{(k)} \times \mathcal{I}^{(k)}$ 矩阵 (具有正交行), 使得 $\text{Ker}(\pi^{(k-1,k)}) = \text{Im}((W^{(k)})^T)$, 以及对 $(i_1, \dots, i_{k-1}) \neq (j_1, \dots, j_{k-1})$, 有 $W_{i,j}^{(k)} = 0$. 为




图 10 对 $1 \leq k \leq 7$ 的对策基 $\psi_i^{(k)}$ [10]




图 11 对固定 i 和 $2 \leq k \leq 7$, $\psi_i^{(1)}$ 和尺度正交的对策基 $\mathcal{X}_i^{(k)}$ [10]

1) 令 $(\mathcal{J}^{(k)})_{2 \leq k \leq q}$ 是形如 $j = (j_1, \dots, j_k)$ 的 k 维数组的有限集, 使得 $(j_1, \dots, j_{k-1}) \in \mathcal{I}^{(k-1)}$ 和 $|\mathcal{J}^{(k)}| = |\mathcal{I}^{(k)}| - |\mathcal{I}^{(k-1)}|$. — 原注

了简单起见, 用 $\mathcal{X}_i^{(1)}$ 表示 $\psi_i^{(1)}$, 用 $\mathfrak{X}^{(1)}$ 表示 $\Psi^{(1)}$. 那么 (i) 诸 $\mathcal{X}_i^{(k)}$ 关于能量标量积 $\langle \cdot, \cdot \rangle$ 对于 k 是尺度正交的, (ii) 它们是指数局域化的, 以及 (iii) $\mathcal{L}$ 在每个子带 $\mathcal{X}^{(k)}$ 中在下述意义都是良态的, 即加在具有元素

$$B_{i,j}^{(k)} := \langle \mathcal{X}_i^{(k)}, \mathcal{X}_j^{(k)} \rangle \quad (17)$$

的刚度 (stiffness) 矩阵 $B^{(k)}$ 上的条件数关于 k 是一致有界的:

$$\text{条件数}(B^{(k)}) \leq Ch^{-2}, \quad \forall k.$$

7. 快速求解器

由于 $\mathfrak{X}^{(k)}$ 是尺度正交的, 因此线性组

$$\mathcal{L}u = f \quad (18)$$

可以在每个子带 $\mathfrak{X}^{(k)}$ 中独立求解 (利用 $\mathcal{X}_i^{(k)}$ 作为有限个元素; 图 12 展示了相应的子带解 $u^{(k)} - u^{(k-1)}$), 并且这个对策基变换将 (18) 转化为了一组可独立求解的一致良态的稀疏线性组. 对策基 $\mathcal{X}_i^{(k)}$ 可以根据 3 个性质以 $O(N \log^{2d+1} N)$ 复杂度计算, 3 个性质为:

(i) 嵌套 $\psi_i^{(k)} = \sum_j R_{i,j}^{(k,k+1)} \psi_j^{(k+1)}$ 可以对 $\psi_i^{(k)}$ 进行分层计算, (ii) $\psi_i^{(k)}$ 的指数衰减意味着插值矩阵 $R^{(k-1,k)}$ 和刚度矩阵 $B^{(k)}$ 的近 (near) 稀疏性, 以及 (iii) 条件数 $(B^{(k)})$ 的一致有界性. 一旦计算出这些对策基, 线性组 (18) 即能在 $O(N \log^{d+1} N)$ 复杂度中解出.

8. Green 函数的稀疏和秩揭示的多分辨率表示

对于 $q = \infty$, 我们有以下解空间的多分辨率正交直和分解

$$\mathcal{H}_0^s(\Omega) = \bigoplus_{k=1}^{\infty} \mathfrak{X}^{(k)}, \quad (19)$$

以及 $\mathcal{L}$ 的 Green 函数 G 的多分辨率分解

$$G(x, y) = \sum_{k=1}^{\infty} \sum_{i,j \in \mathcal{J}^{(k)}} B_{i,j}^{(k),-1} \mathcal{X}_i^{(k)}(x) \mathcal{X}_j^{(k)}(y). \quad (20)$$

诸估计¹⁾

$$C^{-1} h^{2sk} J^{(k)} \leq B^{(k),-1} \leq Ch^{2sk} J^{(k)} \quad (21)$$

和

$$B_{i,j}^{(k),-1} \leq Ch^{2sk} e^{-\frac{d_{i,j}}{Ch^k}} \quad (22)$$

蕴涵着表达式 (20) 是: (i) 按下述意义秩揭示的 (rank-revealing), 即 G 的主子矩阵截断

$$G^{(k)}(x, y) = \sum_{k'=1}^k \sum_{i,j \in \mathcal{J}^{(k')}} B_{i,j}^{(k'),-1} \mathcal{X}_i^{(k')}(x) \mathcal{X}_j^{(k')}(y)$$

是 G 的低秩近似, 相差一个乘性常数它是最优的, 即 $\|Gf - G^{(k)}f\|_{\mathcal{H}_0^s(\Omega)} \leq Ch^{ks} \|f\|_{L^2(\Omega)}$, 和

(ii) 按下述意义稀疏的 (sparse), 即对 $i, j \in \mathcal{J}^{(k)}$ 和 $f \in \mathcal{H}^{-s}(\Omega)$, $\|B_{i,j}^{(k),-1} \mathcal{X}_i^{(k)}[f, \mathcal{X}_j^{(k)}]\|_{\mathcal{H}_0^s(\Omega)} \leq Ce^{-\frac{d_{i,j}}{Ch^k}} \|f\|_{\mathcal{H}^{-s}(\Omega)}$.




图 12 $\mathcal{L}u = f$ 在 $f \in L^2(\Omega)$ 中的解 u 的多重预解分解 [10]. 子带投影下的 % 数对应于该子带的相对能量含量

1) 记 $J^{(k)}$ 为 $\mathcal{J}^{(k)} \times \mathcal{J}^{(k)}$ 单位矩阵. 对于 $i, j \in \mathcal{J}^{(1)}$, 记 $d_{i,j}$ 为 $\phi_i^{(1)}$ 和 $\phi_j^{(1)}$ 支集之间的距离. 对于 $k \geq 2$ 和 $i, j \in \mathcal{J}^{(k)}$, 记 $d_{i,j}$ 为 $\phi_{i^{(k-1)}}^{(k-1)}$ 和 $\phi_{j^{(k-1)}}^{(k-1)}$ 支集之间的距离. —— 原注

9. Gauss 场 ξ 的多分辨率表示

Green 函数的多分辨率分解 (20) 自然地对应于 Gauss 场 $\xi \sim \mathcal{N}(0, \mathcal{L}^{-1})$ 的多分辨率分解. 令 $(Y^{(k)})_{k \geq 1}$ 是独立 Gauss 向量 $Y^{(k)} \sim \mathcal{N}(0, B^{(k)}, -1)$, 其中 $B^{(k)}$ 在 (17) 中定义, 那么我们分解 Gauss 场 ξ

$$\xi = \sum_{k=1}^{\infty} \sum_{i \in \mathcal{J}^{(k)}} Y_i^{(k)} \mathcal{X}_i^{(k)} \quad (23)$$




图 13 模拟 Gauss 场 $\xi^{(1)}$ 和 $(\xi^{(k)} - \xi^{(k-1)})_{k \geq 2}$ [10]

到以不同的尺度振荡的模式 $\xi^{(k)} - \xi^{(k-1)} = \sum_{i \in \mathcal{J}^{(k)}} Y_i^{(k)} \mathcal{X}_i^{(k)}$ (图 13). 将 Gauss 场 ξ 解释为 u 的随机化, 可以得到 $\mathcal{L}u = f$ 的解 u 的诸子带分量 $u^{(k)} - u^{(k-1)}$, 如图 12 所示, 就是 k 层和 $k-1$ 层测量间差异所包含信息上模式 $\xi^{(k)} - \xi^{(k-1)}$ 的条件实现.

10. 稠密核矩阵的 Cholesky 分解

现在, 我们阐述 NA 和 GPR 在初等线性代数运算中的汇合. 令 $x_1, \dots, x_N$ 为 Ω 的 N 个均匀分布的点. 对于 $s > d/2$, 考虑由

$$\Theta_{i,j} = G(x_i, x_j) \quad (24)$$

定义的 $N \times N$ 对称正定稠密核矩阵 Θ . 由于 Θ 是稠密的, 因此简单线性代数运算 (常规方法) 的计算复杂度如下: (i) 存储: $\mathcal{O}(N^2)$, (ii) $\Theta v : \mathcal{O}(N^2)$, (iii) $\Theta^{-1} v : \mathcal{O}(N^3)$, (iv) $\det(\Theta) : \mathcal{O}(N^3)$, 以及 (v) Θ 的主成分分析: $\mathcal{O}(N^3)$.

在 (i) 计算物理学, (ii) Gauss 过程统计 (其中 Θ 是相应于具有协方差函数 G 的中心 Gauss 过程 ξ 的向量 $(\xi(x_1), \dots, \xi(x_N))$ 的协方差矩阵), 以及 (iii) 机器学习的核方法 (如支持向量机) 中, 打破这些复杂度瓶颈具有重要实际意义.

在这里, 利用 NA 和 GPR 之间的联系, 可以推出一个简单的不完全 Cholesky (楚列斯基) 分解算法, 使上述运算在近似线性复杂度 [15] 中得以实现. 该算法 (i) 选择 Θ 的 $\mathcal{O}(N \log N \log^d(N/\epsilon))$ 数量级元素和用置换矩阵 P 表示的 $x_1, \dots, x_N$ 序; (ii) 根据这些元素和置换, 在空间复杂度 $\mathcal{O}(N \log N \log^d(N/\epsilon))$ 和时间复杂度 $\mathcal{O}(N \log^2 N \log^{2d}(N/\epsilon))$ 下, 计算出一个稀疏下三角矩阵 L , 使得 L 的非零元素数为 $\mathcal{O}(N \log N \log^d(N/\epsilon))$, 并且

$$\|P^T \Theta P - LL^T\|_F \leq \epsilon, \quad (25)$$

其中 $\|\cdot\|_F$ 是 Frobenius (弗罗贝尼乌斯) 范数.

该算法的思想是首先将 $x_1, \dots, x_N$ 分解为嵌套的分层 $\{x_i\}_{i \in \mathcal{I}^{(1)}} \subset \{x_i\}_{i \in \mathcal{I}^{(2)}} \subset \dots \subset \{x_i\}_{i \in \mathcal{I}^{(q)}}$ (图 14), 并将点从 $\mathcal{J}^{(1)} = \mathcal{I}^{(1)}$, $\mathcal{J}^{(2)} = \mathcal{I}^{(2)}/\mathcal{I}^{(1)}$ 到 $\mathcal{J}^{(q)} = \mathcal{I}^{(q)}/\mathcal{I}^{(q-1)}$ 排序. 于是, 相应地按顺序排列 Θ 的行和列, 我们就得到 $P^T \Theta P$.

下一步是利用这个分层排序定义对应于矩阵 Θ 诸元素的一个稀疏子集的稀疏模式 $S := \{i, j \in \mathcal{I}^{(q)} \mid i \in \mathcal{J}^{(k)}, j \in \mathcal{J}^{(l)}, |x_i - x_j| \leq \ln \frac{N}{\epsilon} 2^{-\min(k,l)}\}$ (图 15). 然后在算法 1 中计算 $P^T \Theta P$ 的不完全 Cholesky 分解 LL^T , 作为对经




图 14 将 $x_1, \dots, x_N$ 分解为一个嵌套分层 [15]

算法 1 [15] 的不完全 稀疏 Cholesky 分解

输入: $N \times N$ 对称正定矩阵 $A \leftarrow P^T \Theta P$ 的诸元素 $(i, j) \in S$

输出: $N \times N$ 下三角矩阵 L

1. 对于 $i = 1$ 到 N 执行
 2. $L_{:,i} \leftarrow A_{:,i} / \sqrt{A_{i,i}}$
 3. 对于 $j \in \{i+1, \dots, N\} : (i, j) \in S$ 执行
 4. 对于 $k \in \{j, \dots, N\} : (k, i), (k, j) \in S$ 执行
 5. $A_{k,j} \leftarrow A_{k,j} - \frac{A_{k,i} A_{i,j}}{A_{i,i}}$
 6. 结束
 7. 结束
 8. 结束
-

典算法的一个小改进: 跳过所有在稀疏模式 S 之外 $(k, i), (k, j), (i, j)$ 的操作.

它为什么会起作用? Cholesky 分解计算一个满足 $P^T \Theta P = LL^T$ 的下三角矩阵 L . 由此产生的因子 L 取决于诸点 $x_1, \dots, x_N$ 的顺序 (用 P 来表示). 虽然因子 L 在字典序下是稠密的, 但在图 14 的分层序下, 它们是近稀疏的, 即近似稀疏的. 虽然这是个新的观察结论, 但从 GPR 的角度有一个简单的解释. 为了简化符号, 假设 Θ 的行和列按分层序排列, 并记 $\Theta_{1:l,1:l}$ 为 Θ 的 $\{1, \dots, l\} \times \{1, \dots, l\}$ 子矩阵. Cholesky 分解算法迭代计算 $\Theta_{1:l,1:l}$ 在 Θ 中的 Schur (舒尔) 补 $S^{(l)}$ (从 $l = 1$ 到 $l = N$), 其概率解释为条件协方差矩阵

$$S_{i,j}^{(l)} = \text{Cov}(\xi(x_i), \xi(x_j) | \xi(x_k), k \leq l),$$

其中 ξ 是具有协方差函数 G 的中心 Gauss 过程. 屏蔽效应蕴涵着, 当 l 达到较细的分层水平时, ξ 的条件相关长度减小, Schur 补 $S^{(l)}$ 变得越来越稀疏, 导致 Cholesky 因子 L 的近稀疏性.

L 的近稀疏性也与对策基的指数衰减有关. 选择线性嵌套测量函数的分层 (13) 为子样本 Dirac 函数: 对于 $i \in \mathcal{I}^{(k)}$, $\phi_i^{(k)} := \delta(\cdot - x_i)$. 令 $X_i^{(k)}$ 为通过 (16) 用 $W_{i,j}^{(k)} = \delta_{i,j}$ 得到的相对应的算子适应小波, 并令 $B^{(k)}$ 如 (17) 中所示. 那么 Θ 可以 Cholesky 块分解

$$\Theta = \bar{L} D \bar{L}^T,$$

其中 D 是块对角矩阵, $\mathcal{J}^{(k)} \times \mathcal{J}^{(k)}$ 对角块等于 $B^{(k), -1}$, 对于 $i \in \mathcal{J}^{(k)}, j \in \mathcal{J}^{(k')}$, $\bar{L}_{i,j}$ 定义为:

$$\bar{L}_{i,j} = \begin{cases} 0, & k < k', \\ \delta_{i,j}, & k = k', \\ [\phi_i^{(k)}, \mathcal{X}_j^{(k')}], & k > k'. \end{cases}$$




图 15 稀疏模式 S [15]. 对于 k 层的指标 i , 例如红点, 与半径为 $\sim 2^{-k} \ln \frac{1}{\epsilon}$ 的球内点所对应的诸指标 j 包含红色的第 i 列

$\bar{L}$ 的近稀疏性来自于 $\mathcal{X}_j^{(k')}$ 的指数衰减和测量函数 $\phi_i^{(k)}$ 是 Dirac 测度的事实. 估计式 (21) 和估计式 (22) 蕴涵着 D 的 Cholesky 因子 $\hat{L}$ 的近稀疏性, 因此 $L = \bar{L}\hat{L}$. 然后将稀疏集 S 与 L 的近稀疏结构进行匹配, 则得到近似误差估计 (25). 此外, 对策基的秩揭示性质 (20) 蕴涵着 Cholesky 分解不仅是稀疏的, 而且是秩揭示的, 即

$$\|P^T\Theta P - L^{(k)}L^{(k),T}\| \leq C\|\Theta\|k^{-\frac{2s}{d}},$$

其中 $L^{(k)}$ 是由 Θ 的 Cholesky 因子 L 的前 k 列定义的 k 秩矩阵, $\|\Theta\|$ 是 Θ 的算子范数.

致谢 (略)

参考文献

- [1] Diaconis P. Bayesian numerical analysis. Statistical Decision Theory and Related Topics, IV, Vol. 1 (West Lafayette, Ind., 1986), Springer, New York, 1988, 163–175. MR927099
- [2] Halko N, Martinsson PG, Tropp JA. Finding structure with randomness: probabilistic algorithms for constructing approximate matrix decompositions, SIAM Rev., no. 2(53): 217–288, 2011, dx.doi.org/10.1137/090771806. MR2806637
- [3] Hennig P, Osborne MA, Girolami M. Probabilistic numerics and uncertainty in computations, Proc. Roy. Soc. A., no. 2179 (471): 20150142, 2015, dx.doi.org/10.1098/rspa.2015.0142. MR3378744
- [4] Kimeldorf GS, Wahba G. A correspondence between Bayesian estimation on stochastic processes and smoothing by splines, Ann. Math. Statist. (41): 495–502, 1970. MR254999
- [5] Larkin FM. Gaussian measure in Hilbert space and applications in numerical analysis, J. Math., no. 3 (2), 1972. MR0303193
- [6] Målqvist A, Peterseim D. Localization of elliptic multiscale problems, Math. of Comp., no. 290 (83): 2583–2603, 2014. MR3246801
- [7] Micchelli CA, Rivlin TJ. A survey of optimal recovery. Optimal Estimation in Approximation Theory, Springer, 1977, 1–54. MR0617931
- [8] Owhadi H. Bayesian numerical homogenization, Multiscale Model. Simul., no. 3 (13): 812–828, 2015, dx.doi.org/10.1137/140974596. MR3369060
- [9] Owhadi H. Multigrid with rough coefficients and multiresolution operator decomposition from hierarchical information games, SIAM Rev., no. 1 (59): 99–149, 2017. MR3605827
- [10] Owhadi H, Scovel C. Operator Adapted Wavelets, Fast Solvers, and Numerical Homogenization from a Game Theoretic Approach to Numerical Approximation and Algorithm Design, Cambridge Monographs on Applied and Computational Mathematics, Cambridge University Press, 2019.
- [11] Packel EW. The algorithm designer versus nature: a game-theoretic approach to information-based complexity, J. Complexity, no. 3 (3): 244–257, 1987, dx.doi.org/10.1016/0885-064X(87)90014-8. MR919675
- [12] Palasti I, Renyi A. On interpolation theory and the theory of games, MTA Mat. Kat. Int. Kozl (1): 529–540, 1956.
- [13] Raissi M, Perdikaris P, Karniadakis GE. Inferring solutions of differential equations using noisy multi-fidelity data, J. Comput. Phys. (335): 736–746, 2017. MR3612520
- [14] Sard A. Linear Approximation, Vol. 9, Amer. Math. Soc., 1963. MR0158203
- [15] Schäfer F, Sullivan TJ, Owhadi H. Compression, inversion, and approximate PCA of dense kernel matrices at near-linear computational complexity, arXiv: 1706.02205, 2017. (下转 192 页)

始, 我们已经表明了用 $f(x)/x$ 的积分, 我们如何可以发现 $\zeta(3)$ 的带有对数项的一个级数 (19), 然后用对数函数的幂级数来得到 $\zeta(3)$ 的某个快速收敛级数 (21) 和 (22). $\zeta(3)$ 的级数表达式 (23) 是熟知的 [8, p.585]. 类似于 (22) 的一个级数表达式被包含在 Euler 1772 年的文章里 [2, p.1084–1085], 其后, 于 2000 年又由他人重新发现 [8, p.571]. $\zeta(3)$ 的其它几个已知的级数表达式, 以及更一般地, $\zeta(2n+1)$, $n \in \mathbb{N}$ 的其它几个已知的级数表达式可以在 [8] 中找到. 对于 $\zeta(2n+1)$, $n = 1, 2, 3, \dots$, 还有一些有意义的积分表达式, 可以在关于奇函数的 Fourier 级数的文献 [4] 和 [6] 中找到.

致谢 (略)

参考文献

- [1] Tom M. Apostol, A primer on Bernoulli numbers and polynomials, Math. Mag. 81 (2008) 178–190.
- [2] Raymond Ayoub, Euler and the zeta function, Amer. Math. Monthly 81 (1974) 1067–1086.
- [3] Robin Chapman, Evaluating $\zeta(2)$, http://pictor.math.uqam.ca/~plouffe/OEIS/archive_in.pdf/zeta2.pdf 2003
- [4] D. Cvijović and J. Klinowski, Integral representations of the Riemann zeta function for odd-integer arguments, J. Comput. Appl. Math. 142 (2002) 435–439. doi:10.1016/S0377-0427(02)00358-8
- [5] William Dunham, Euler: The Master of Us All, Mathematical Association of America, Washington, DC, 1999.
- [6] J. Duoandikoetxea, A sequence of polynomials related to the evaluation of the Riemann zeta function, Math. Mag. 80 (2007), 38–45.
- [7] A. van der Poorten, A proof that Euler missed... Apéry's proof of the irrationality of $\zeta(3)$, Math. Intelligencer 1 (1979) 195–203. doi: 10.1007/BF03028234
- [8] H. M. Srivastava, Some families of rapidly convergent series representations for the zeta functions, Taiwanese J. Math. 4 (2000) 569–599; available at <http://www.math.nthu.edu.tw/~tjm/abstract/0012/tjm0012.3.pdf>.
- [9] H. M. Srivastava, M. L. Glasser, and V. S. Adamchik, Some definite integrals associated with the Riemann zeta function, Journal for Analysis and Its Applications 19 (2000) 831–846.
- [10] G. P. Tolstov, Fourier Series, Dover, New York, 1976.

(陆柱家 译 陆昱 校)

(上接 164 页)

- [16] Schoenberg IJ. Cardinal Spline Interpolation, Vol. 12, SIAM, 1973. MR0420078
- [17] Stein ML. The screening effect in Kriging, Ann. Statist.: 298–323, 2002. MR1892665
- [18] Sudarshan R. Operator-adapted finite element wavelets: Theory and applications to a posteriori error estimation and adaptive computational modeling. Thesis (Ph.D.)-Massachusetts Institute of Technology, 2005, ProQuest LLC, Ann Arbor, MI. MR2717264
- [19] Sul'din AV. Wiener measure and its applications to approximation methods. I, Iz. Vysš. Učebn. Zaved. Matematika. (6): 145–158, 1959. MR0157489
- [20] Traub JF, Wasilkowski GW, Woźniakowski H. Information-Based Complexity, with contributions by A. G. Werschulz and T. Boulton, Computer Science and Scientific Computing, Academic Press, Inc., Boston, MA, 1988. MR958691

(张宏根 译 梁燕姣 校)